# Tõenäosusteooria ja matemaatiline statistika

## MTMS.00.059, ainekonspekt

Krista Fischer

Tartu, 2024-2025

# Sissejuhatus

Tänapäeval räägime me üha enam infoühiskonnast ja suurandmete ajastust. Tõepoolest, pea igapäevaselt puutume me kokku andmepõhise infoga ja vajadusega sellest endale kasulik välja selekteerida. Ja teistpidi – igal sammul jätame me endast jälje mõnda andmebaasi. Seetõttu on ka oskus andmetes orienteeruda ehk teisisõnu **statistiline kirjaoskus** olulisem kui kunagi varem.

Üks olulisemaid statistilise kirjaoskuse komponente on arusaam juhuslikkusest ja oskus seda arvestada andmete tõlgendamisel. Juhuslikkust kohtame me igal sammul, tihti seda isegi teadvustamata. Juhuslikud on detailid meist igaühe tavalises päevas, kuid samas saavad ka suured ja olulised maailmasündmused tihti alguse erinevate juhuslike asjaolude kokkulangevusest. Selles juhuslikus maailmas peame siiski suutma oma elu planeerida ja võtta vastu mõistlikke otsuseid. Otsuste aluseks on tavaliselt hinnangud nii võimalikule kasule kui riskidele, mis võiksid järgneda sellele, kas toimime ühel või teisel moel. Teisisõnu, suur osa meie mõttetegevusest seisneb erinevate tõenäosuste hindamises ja võrdlemises, ilma neid küll enamasti arvuliselt esitamata.

Võib kõlada veidi paradoksaalselt, et juhuslikkus järgib siiski ka teatud seaduspärasusi, mida on võimalik matemaatiliselt kirjeldada. Ajalugu on näidanud, et paljudes valdkondades on edu saatnud inimesi kes neid seaduspärasusi ehk **tõenäosusteooriat** tunnevad ning seetõttu oskavad nii tõenäosusi ja ka sündmuste omavahelisi seoseid süstemaatiliselt hinnata. Sellisteks valdkondadeks on nii suurem osa teadusharusid kui ka majandus ja rahandus ning samuti poliitikas. Just seda väidab ka Uppsala ülikooli teadlane David Sumpter oma raamatus "Kümme valemit mis juhivad maailma", kus on välja toonud kümme äärmiselt kasulikku tõenäosusteooria ja matemaatilise statistika valdkonna valemit, mis keerulistes olukordades kasulikke otsuseid teha aitavad. Seejuures toob ta näiteid nende valemite kasulikkusest paljudest erinevatest valdkondadest, spordiennustustest sotsiaalmeediani.

Ka käesoleva kursuse eesmärgiks on anda osalejatele elementaarne matemaatiline "tööriistakast", mis koosneb tõenäosusteooria ja matemaatilise statistika põhitõdedest ja mida kasutades on võimalik senisest targemaid otsuseid teha. (Eelmainitud kümnest "maailma juhtivast" valemist puutume siin kokku viiega.) Samuti annab see kursus vajalikud baasteadmised edasiste statistika, andmeanalüüsi ja andmeteadusega (need kolm terminit pole küll sünonüümid, aga nende valdkondade vahel on väga suur ühisosa) seotud õppeainete omandamiseks.

Loengukonspekti esimene, tõenäosusteooriat käsitlev osa on suures osas kaetud ka Kalev Pärna (tõenäosusteooria emeriitprofessor) poolt kirjutatud õpikus:

Kalev Pärna, Tõenäosusteooria algkursus *Tartu Ülikooli Kirjastus*, 2016, ISBN 9789949322183

Raamat on kättesaadav paberväljaandena TÜ Matemaatika ja statistika instituudi kantseleis (Delta, ruum 4104), Delta raamatukogus ning e-õpikuna TÜ raamatukogus, vt. http://hdl.handle.net/10062/55539

# Peatükk 1

# Tõenäosuse mõiste ja põhiomadused

## 1.1 Juhuslikud katsed ja juhuslikud sündmused, tehted sündmustega

Tõenäosustest saame rääkida siis, kui mängus on juhuslikkus, ehk siis sündmuste puhul, mille toimumises või mittetoimumises me alati kindlad ei saa olla. Tegelikult on meie igapäevaelus vist juhuslikkust rohkemgi kui ettemääratust. Vähemalt Eestimaa kliimas ei saa ühelgi hommikul kindel olla selles, milliseks muutub ilm juba sama päeva õhtuks. Samuti me ei tea täpselt, kes on need inimesed keda me päeva jooksul kohtame.

**Juhuslik sündmus** on sündmus, mille toimumine ei ole üheselt määratud (täringuviske tulemus; mikrofoni patareide tühjakssaamine loengu ajal, jne.). Selle kursuse raames tähistame juhuslikke sündmusi enamasti suurtähtedega, nagu $A$, $B$, $C$ jne. (nt: $A$ võib tähistada sündmust, et 23. juuni õhtul sajab Tartus vihma) Juhuslikke sündmusi võib vaadelda ka kui juhusliku katse tulemusi.

**Juhuslik katse** on igasugune tegevus, mille tulemus ei ole antud tingimustega üheselt määratud. Näiteks:

- Mündi/täringu vise;
- Loteriid jm loosimised;
- Kaardi tõmbamine kaardipakist. Juhusliku inimese valimine nimekirjast;
- Juhuslikult valitud inimese pikkuse mõõtmine;
- Spordivõistluse tulemus.

Selles kursuses ja ka muudes tõenäosusteooria kursustes ja õpikutes kasutame tihti näiteid järgmist tüüpi juhuslikest katsetest:

- Mündivise. Mündi ühel küljel on "kiri" (tavaliselt number) ja teisel küljel "vapp" (vahel öeldakse ka "kull"). Münt visatakse õhku ja vaadatakse, kumb külg jääb ülespoole kui ta alla kukub. Juttu tuleb nii "ausatest" müntidest, kus kummalegi küljele maandumine juhtub ühesuguse tõenäosusega (0,5 ehk 50%) kui "ebaausatest" ehk nihkega müntidest, mis ühele küljele kukuvad suurema tõenäosusega kui teisele. Lihtsa juhusliku katse korral visatakse ühte münti ühe korra, kuid kui münte/viskeid on rohkem, siis tekivad juba keerulisemad olukorrad.
- Täringud. Kui ülesande/näite juures pole mainitud teisi võimalikke täringuid, siis on jutt tavalisest 6-tahulisest täringust, mille igal küljel on 1-6 punkti. Juhuslikuks katseks on täringu veeretamine, kus vaadatakse, mitu punkti on täringu pealmisel tahul siis kui täring paigale jääb.

- Mängukaardid. Enamasti kasutame klassikalise 52 kaardiga mängukaartide paki näidet. Mängukaardi olulisteks tunnusteks on "mast" (ärtu, ruutu, poti, risti) ja kaardil olev number või pilt (2,3,. . . , 10, soldat/poiss, emand, kuningas, äss). Juhuslikuks katseks võib olla näiteks ühe või mitme kaardi juhuslik tõmbamine kaardipakist.
- Urn. Urni all mõtleme enamasti mingit mitte-läbipaistvat anumat, kust on sees hulk kuule (või ka teisi objekte), mis võivad olla erinevat värvi: näiteks 10 musta ja 10 valget kuuli (või ka punased, kollased sinised, vms). Juhuslikuks katseks on kuuli võtmine urnist – saame eeldada, et kõigil kuulidel on ühesugune tõenäosus välja võetud saada. Keerukamates näidetes võib olla mängus ka mitu urni (nt võetakse ühest üks kuul ja pannakse teise, siis võetakse teisest).

Selliste "mängunäidete" abil saadud teadmisi võime tihti kasutada päriseluliste probleemide juures – näiteks kui peame valima juhusliku valimi inimestest.

## 1.2 Tõenäosuse mõiste

**Tõenäosus.** Sündmuse toimumise tõenäosus on arv skaalal 0-st 1-ni, mis iseloomustab sündmuse toimumise võimalikkust.

(NB! See ei ole veel matemaatiliselt korrektne definitsioon – korrektsest definitsioonist on juttu selle peatüki lõpus).

Olgu $A$ üks juhuslik sündmus. Siis:

- Sündmuse $A$ tõenäosuse tähistuseks on $P(A)$.
- Kui $P(A) = 0$, siis see tähendab, et A on võimatu sündmus, ehk tema toimumine on välistatud (tooge näide!).
- Vastupidi, kui $P(A) = 1$, siis on A kindel sündmus – tema toimumises pole mingit kahtlust (näide?)

Enamasti pakuvad huvi siiski sündmused, mille tõenäosus jääb 0 ja 1 vahele. Sellistel juhtudel võime tihti kuhutada tõenäosust ette suhtelise sagedusena – sündmuse $A$ tõenäosus on sündmuse $A$ toimumise osakaal juhusliku katse kõigi võimalike tulemuste seas.

## 1.3 Peamised viisid tõenäosuse leidmiseks

### 1.3.1 Klassikaline tõenäosus

**Klassikaline tõenäosus.** Kui juhuslikul katsel on kokku $N$ võrdvõimalikku tulemust ja nende hulgas on $N_A$ sellist, mille korral saame sündmuse $A$ toimunuks lugeda, siis sündmuse $A$ tõenäosus avaldub suhtena:

$$P(A) = \frac{N_A}{N}.$$

Lihtne on näha, et klassikaline tõenäosus on alati 0 ja 1 vahel.

**Näide 1.** Ausat täringut visatakse 1 kord. Kui suur on tõenäosus, et tulemus on suurem kui 4?

**Lahendus:**
Tähistame: $A$ = "saadakse 5 või 6 silma"

Kokku on täringuviskel 6 võrdvõimalikku tulemust, neist 2 vastavad sündmusele A.
Seega $N = 6$ ja $N_A = 2$ ning:

$$P(A) = \frac{2}{6} = \frac{1}{3}$$

**Näide 2.** Urnist kus on 4 valget ja 2 musta kuuli, võetakse juhuslikult üks kuul. Kui suur on tõenäosus, et saadakse must kuul?

**Lahendus:**
Tähistame: $A =$ "saadakse must kuul"

See näide on põhimõtteliselt identne eelmisega – meil on samuti kokku 6 võrdvõimalikku tulemust, millest 2 vastavad sündmusele A ja seega:

$$P(A) = \frac{2}{6} = \frac{1}{3}$$

**Näide 3.** Ausat täringut visatakse 2 korda. Kui suur on tõenäosus, et vähemalt üks tulemus on suurem kui 4?

**Lahendus:**
Esimesel korral on 6 võrdvõimalikku tulemust ning ükskõik millise esimese korra tulemuse korral on ka teiseks tulemuseks 6 võrdse tõenäosusega varianti. Seega $N = 6^2 = 36$.
$N_A$ leidmiseks on siin kaval leida, mitu tulemust on meile ebasoodsad, ehk siis sellised, kus mõlemal täringul on 1-4 silma: neid on kokku $4 \cdot 4 = 16$. Seega kõiki ülejäänud (soodsaid) võimalusi on $N_A = 36 - 16 = 20$ ja

$$P(A) = \frac{20}{36} = \frac{5}{9} \approx 0{,}56.$$

**Näide 4.** Kui suur on tõenäosus, et kahe täringuviske silmade summa tuleb 5?

**Lahendus:**
Siin on katsetulemuseks paarid $i; j$, kus $i$ on silmade arv esimesel ja $j$ teisel täringul. Näiteks $i; j = 3; 4$ tähendab seda, et esimesel täringul tuleb 3 ja teisel 4. Katsetulemused saab esitada tabelina, kuhu võime otse kanda kahe viske summa.
Näeme, et $N = 6 \times 6 = 36$ ja $N_A = 4$.
Järelikult on otsitav tõenäosus:

$$P(A) = P(\text{kahe täringuviske summa on 5}) = \frac{4}{36} = \frac{1}{9} \approx 0{,}11$$

| | 2. täring | | | | | |
|---|---|---|---|---|---|---|
| 1. täring: | 1 | 2 | 3 | 4 | 5 | 6 |
| 1 | 2 | 3 | 4 | 5 | 6 | 7 |
| 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| 3 | 4 | 5 | 6 | 7 | 8 | 9 |
| 4 | 5 | 6 | 7 | 8 | 9 | 10 |
| 5 | 6 | 7 | 8 | 9 | 10 | 11 |
| 6 | 7 | 8 | 9 | 10 | 11 | 12 |

Tabel 1.1: Kahe täringuviske tulemused ja saadud silmade summad.

| | 2. kuul | | | | | |
|---|---|---|---|---|---|---|
| 1. kuul: | V | V | V | V | M | M |
| V | | VV | VV | VV | VM | VM |
| V | VV | | VV | VV | VM | VM |
| V | VV | VV | | VV | VM | VM |
| V | VV | VV | VV | | VM | VM |
| M | MV | MV | MV | MV | | MM |
| M | MV | MV | MV | MV | MM | |

Tabel 1.2: Võimalikud tulemused kahe kuuli võtmisel urnist, kus on neli valget ja kaks musta kuuli.

**Näide 5.** Urnist kus on 4 valget ja 2 musta kuuli, võetakse juhuslikult kaks kuuli. Kui suur on tõenäosus, et saadakse vähemalt üks must kuul?

**Lahendus:**
Paneme tähele, et nüüd meil enam ei ole samasugune olukord nagu eelmises näites, sest meil on tegemist tagasipanekuta valikuga.

Iga kord kui urnist on üks kuul välja võetud, jääb sinna veel 5 kuuli. Seega $N = 6 \cdot 5 = 30$. Mõeldes jälle esmalt meile ebasoodsatele sündmustele leiame, et esimesel korral on meil 4 võimalust valge kuuli võtmiseks ja kui üks valge kuul on välja võetud, siis on meil veel 3 valget alles, seega on $4 \cdot 3 = 12$ võimalust kahe valge kuuli võtmiseks ja järelikult $30 - 12 = 18$ sellist võimalust, kus vähemalt üks kuul on must.

$$P(A) = \frac{18}{30} = \frac{3}{5} = 0{,}6.$$

(vt ka võimalikke tulemusi tabeli kujul esitatuna Tabelis 1.2)

Arvude $N$ ja $N_A$ leidmine võib aga mõnikord olla siinsetest näidetest märksa keerulisem. Sellisel juhul on vahel abi kombinatoorika reeglitest. Kellel need meeldetuletamist vajavad, võivad lugeda peatükki 1.5.

**Näide 6.** Ausat täringut visatakse 5 korda. Kui suur on tõenäosus, et täpselt kahel korral saadakse rohkem kui 4 silma?

**Lahendus:**
Tähistame: $A =$ "täpselt kahel korral viiest saadakse 5 või 6 silma"

Esmalt paneme tähele, et $N = 6^5$. Kuidas aga leida $N_A$?
Vaatame esmalt juhtu, kus kahel esimesel viskel saadakse üle 4 silma: selleks on $2 \cdot 2 = 4$ võimalust. Et aga ülejäänud kolmel täringul tuleks kuni 4 silma, selleks on $4^3$ võimalust.
Seega selliseid tulemusi, kus kaks esimest viset on 5 või 6 ja kolm järgmist on alla 5, on kokku $4 \cdot 4^3 = 4^4$.
Sobivad tulemused võivad aga olla ka teistsuguses järjestuses. Seega peaksime leidma, mitu võimalikku järjestust on – ehk mitu erinevat võimalust on kahe täringu väljavalimiseks viiest (need kaks, kus tulemus on üle 4). Seda saame teada kombinatoorika valemi abil – kombinatsioonide arv 5-st elemendist 2 kaupa on: $\binom{5}{2} = \frac{5!}{2! \cdot 3!} = 10$

(alternatiivne tähistus $C_5^2$). Pannes kõik kokku, saame $N_A = 10 \cdot 4^4$ ja

$$P(A) = \frac{10 \cdot 4^4}{6^5} \approx 0{,}329.$$

Hiljem näeme, et seda viimast ülesannet saaks kiiremini lahendada Bernoulli valemi (ehk binoomjaotuse valemi) abil.

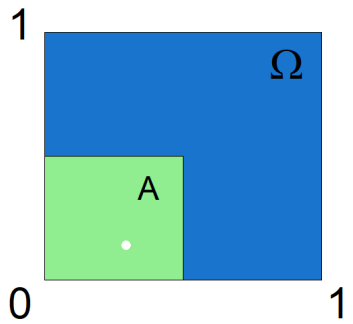
### 1.3.2 Geomeetriline tõenäosus

Geomeetriline tõenäosus tuleb kõne alla siis, kui katseks on juhusliku punkti valimine mingist ruumi piirkonnast (lõik, ristkülik, ring jne). Eeldatakse, et kõik sama suured alampiirkonnad on võrdvõimalikud. Kui ruumi piirkonda $\Omega$ visatakse juhuslik punkt nii, et kõik $\Omega$ punktid on "võrdvõimalikud"), siis tõenäosus, et juhuslik punkt satub alampiirkonda A, on võrdne nende piirkondade suuruste suhtega.

Geomeetriline tõenäosus:

$$P(A) = \frac{m_A}{m_\Omega}$$

kus $m$ tähistab (olenevalt ruumist) piirkonna pikkust, pindala või muud mõõtu.

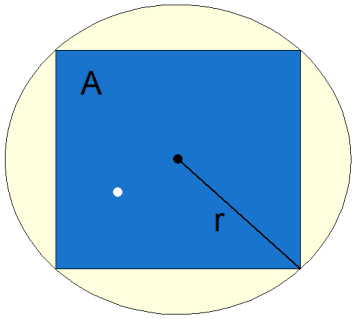



**Näide 7.** Ruutu küljepikkusega 1m visatakse üks juhuslik punkt. Kui ruut on jagatud 4 võrdseks sektoriks küljepikkusega 0,5m, siis kui suur on tõenäosus, et see punkt kukub alumisse vasakusse sektorisse (vt joonist).

**Lahendus:**
$m_\Omega = 1m^2$, $m_A = 0{,}25m^2$, seega $P(A) = \frac{0{,}25}{1} = 0{,}25 = \frac{1}{4}$.

**Näide 8.** Juku kõnnib 1km ja pärast teekonna läbimist avastab, et tal on teekonna jooksul telefon taskust välja kukkunud. Juku asub teed uuesti läbi kõndima, et telefoni otsida. Kui suur on tõenäosus, et ta ei pea kõndima üle 200 meetri, eeldades et ta võis võrdse tõenäosusega kukkuda ükskõik millisesse punkti sellel teekonnal?

**Lahendus:**
$m_\Omega = 1000m$, $m_A = 200m$, seega $P(A) = \frac{200}{1000} = \frac{1}{5} = 0{,}2$.




**Näide 9.** Ringi raadiusega r visatakse juhuslik punkt nii, et ringi kõik punktid on võrdvõimalikud. Leida tõenäosus, et punkt satub ringi joonistatud maksimaalsesse ruutu A.

**Lahendus:**
Ruudu pindala: $m_A = 2r^2$
Ringi pindala: $m_\Omega = \pi r^2$

$$P(A) = \frac{2r^2}{\pi r^2} = \frac{2}{\pi} \approx 0.64$$

### 1.3.3 Statistiline tõenäosus

Sündmuse $A$ statistiliseks tõenäosuseks (ehk suhteliseks sageduseks) nimetatakse suhet

$$P(A) = \frac{n_A}{N}$$

kus $N$ tähistab sooritatud katsete arvu ja $n_A$ $A$ esinemiste arv $N$ katses.

**Näide 10.** Uuringu tulemusena leitakse, et 100 jalgratturist 45 kandis kiivrit. Seega on tõenäosus, et juhuslikult valitud jalgrattur kannab kiivrit *hinnanguliselt* $\frac{45}{100} = 0{,}45$.
Pane tähele, et see on hinnang tegelikule tõenäosusele, mitte aga selle tõenäosuse täpne väärtus. Ainekursuse teises pooles tutvume viisidega, kuidas selliste hinnangute täpsust hinnata.

### 1.3.4 Subjektiivne tõenäosus

Vahel räägitakse ka tõenäosusest, mis on saadud n-ö eksperthinnanguna, ilma konkreetseid arvutusi tegemata. Sellisel juhul saab rääkida subjektiivsest tõenäosusest Subjektiivset tõenäosust kasutatakse palju Bayesi statistika koolkonnas

**Näide 11.** Tudeng Tiina arvab enne eksamit, et tõenäosusega 75% (ehk 0,75) sooritab ta eksami edukalt. See on Tiina subjektiivne hinnang tõenäosusele, mille puhul ta tugineb varasemale kogemusele ja “sisetundele”.

Subjektiivseid tõenäosusi kasutame me enamasti olukordades, kus puudub võimalus tõenäosus otse välja arvutada või ka statistiliselt hinnata. Tihti kasutatakse subjektiivsete tõenäosuste hindamiseks *eksperthinnanguid* antud valdkonnas pädevate isikute poolt. Nii näiteks võib arst anda hinnangu patsiendi paranemise tõenäosusele, tuginedes oma varasemale kogemusele teiste sarnaste patsientidega. Samuti võib subjektiivselt hinnata ka näiteks planeeritava turunduskampaania edukust või mõne planeeritava finantstehingu kasumlikkust. Siiski tuleb arvestada, et erinevalt klassikalisest, geomeetrilisest või ka statistilisest tõenäosusest võib subjektiivne hinnang sõltuda ka hindaja isikust, mis võib tuua kaasa ka süstemaatilise vea.

## 1.4 Tõenäosuse omadused

### 1.4.1 Sündmused ja tehted sündmustega: definitsioonid ja tähistused

Elementaarsündmuste hulk, tähistus $\Omega$ – antud juhusliku katse kõikvõimalike tulemuste hulk.

Üksikuid katsetulemusi nimetatakse elementaarsündmusteks ja tähistatakse $\omega$.

$$\Omega = \{\omega_1,\omega_2,\ldots,\omega_N\}$$

Mõnikord $\Omega = \{\omega_1,\omega_2,\ldots\}$, ehk lõpmatu hulk.

Näiteid:

- Mündivise: $\Omega = \{\text{vapp, kiri}\} = \{\text{v, k}\} = \{\omega_1, \omega_2\}$
- Täringuvise: $\Omega = \{1, 2,3, 4, 5, 6\}$
- Kaardipakist kaardi tõmbamine: $\Omega = \{\omega_1, \omega_2, \ldots,\omega_{52}\}$

**Sündmusteks** nimetatakse väiteid elemetaarsündmuste kohta.

Tõenäosuse matemaatilises käsitluses on sündmus defineeritud kui $\Omega$ alamhulk, st $A$ on sündmus, kui:

$$A \subset \Omega.$$

Seega võib üks sündmus koosneda mitmest elementaarsündmusest.

Sageli on võimalik sama katse korral kasutada mitmeid erinevaid elementaarsündmuste hulki. Milline on parim, sõltub uuritavast küsimusest.

**Näide 12.** Visatakse kaks münti korraga

**a)** $\Omega = \{\text{vv, vk, kv, kk}\}$ – siin me peame oskama münte eristada (1. münt, 2. münt)

**b)** $\Omega = \{\text{2 vappi, 1 vapp, 0 vappi}\}$ – kui me ei oska münte eristada

Juhul a) on kõik elementaarsündmused on võrdvõimalikud, juhul b) see nii ei ole. Seega juhul b) on klassikalise tõenäosuse põhimõtte kasutamine keeruline.

**Näide 13.**

- Mündivise kuni esimese vapi tulekuni:

$$\Omega = \{\text{v, kv, kkv, kkkv, } \dots\}$$

ehk

$$\Omega = \{1, 2, 3, 4, \dots\}$$

- Siin on lõpmatult palju elementaarsündmusi. Siiski saab neid naturaalarvudega nummerdada, st $\Omega$ on loenduv hulk.
- Siin elementaarsündmused ei saa olla võrdvõimalikud (miks?)

**Näide 14.** Juhusliku punkti viskamine ühikruutu [0, 1] x [0, 1]

$$\Omega = \{(x,y) : 0 \le x \le 1,\ 0 \le y \le 1\}$$

Siin on lõpmata palju elementaarsündmusi. Me ei saa neid nummerdada, st tegemist on mitteloenduva hulgaga.

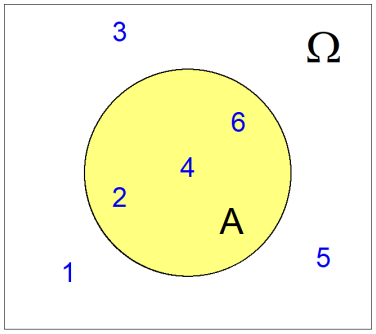
### 1.4.2 Sündmustega seotud mõisted: seosed sündmuste vahel, operatsioonid sündmustega, jne.

**Sündmustega seotud mõisted:**

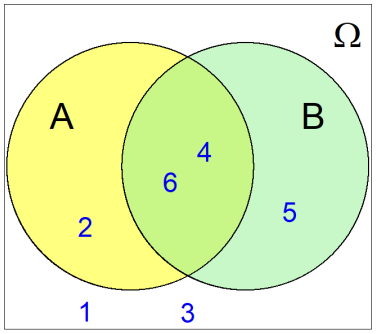
- Kindel sündmus: $\Omega$ (toimub katse tulemusel alati)
- Võimatu sündmus: $\emptyset$ (tühihulk)
- Sündmuse $A$ vastandsündmus: $\bar{A}$ on sündmus "$A$ ei toimu".
- Sündmuste summa ehk ühend $A \cup B$: toimub kas $A$ või $B$.
- Sündmuste vahe $A \backslash B$: toimub $A$, aga $B$ ei toimu.
- Sündmuste korrutis ehk ühisosa $A \cap B$: toimuvad nii $A$ kui $B$.
- Teineteist välistavad sündmused: sündmused mis ei saa korraga toimuda, ehk $\text{A} \cap \text{B} = \emptyset$
- Sündmusest B järeldub sündmus A: sündmuse B toimumise korral toimub kindlasti ka sündmus A, ehk $\text{B} \subset \text{A}$

**Näide 15.** Olgu meil katse, kus tavalist 6-tahulist täringut visatakse üks kord. Selle katse kontekstis teame:

- Kindel sündmus: tulemuseks saadud silmade arv kuulub hulka: $\Omega = \{1,2,3,4,5,6\}$.
- Võimatu sündmus: tulemuseks saadud silmade arv ei kuulu hulka $\Omega$. (Näiteks on võimatu sündmus, et tulemuseks tuleb 7)
- Olgu sündmus $A =$ "tuleb paarisarv silmi", $A = \{2,4,6\}$. (vt ka diagrammi 1.1)
- $A$ vastandsündmus $\bar{A} =$ "tuleb paaritu arv silmi", $\bar{A} = \{1,3,5\}$.




Joonis 1.1: Venni diagramm, mis kujutab täringuviske võimalikke tulemusi ja sündmust $A =$ "tuleb paarisarv silmi", $A = \{2,4,6\}$.




Joonis 1.2: Venni diagramm, mis kujutab täringuviske võimalikke tulemusi ja sündmusi $A =$ "tuleb paarisarv silmi", $A = \{2,4,6\}$ ning $B =$ "saadud silmade arv on suurem kui 3", $B = \{4,5,6\}$.

**Näide 16.** Jätkame eelmist näidet kus ausat 6-tahulist täringut visatakse üks kord, kuid nüüd defineerime kaks sündmust:
$A =$ "tuleb paarisarv silmi", $A = \{2,4,6\}$ ja
$B =$ "saadud silmade arv on suurem kui 3", $B = \{4,5,6\}$.
Paneme tähele, et need sündmused võivad toimuda samaaegselt, kuid on võimalikud ka sellised katsetulemused, kus kumbki sündmus ei toimu. Nende kahe sündmuse illustreerimiseks võib näiteks kasutada Venni diagrammi, mille abil on lihtne veenduda, et:
$A \cup B = \{2; 4; 5; 6\}$
$A \cap B = \{4; 6\}$
$A \backslash B = \{2\}$

Kasutades Venni diagrammi (Joonis 1.2) on ka lihtne näha, et:

$A \backslash B = A \cap \bar{B}$

$\overline{A \cup B} = \bar{A} \cap \bar{B}$

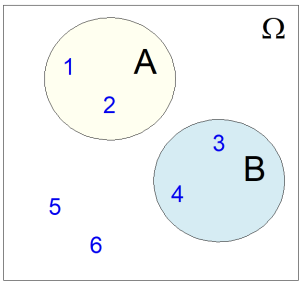
$\overline{A \cap B} = \bar{A} \cup \bar{B}$.

Eelnevates näidetes vaatlesime sündmuseid, mis võisid toimuda ka samaaegselt. Oluline on aga eristada ka sündmuste paare (või hulki), mis on **teineteist välistavad**.

Sündmused $A$ ja $B$ on teineteist välistavad, kui nende samaaegne toimumine antud olukorras on võimatu, ehk:

$$A \cap B = \emptyset$$

**Näide 17.** Kui täringut visatakse 1 kord, siis sündmused "Tulemuseks on kas 1 või 2" ja "Tulemuseks on kas 3 või 4" on teineteist välistavad. (joonis 1.3)




Joonis 1.3: Venni diagramm, mis kujutab täringuviske võimalikke tulemusi ja teineteist välistavaid sündmusi $A = \{1, 2\}$ ning $B = \{3, 4\}$.

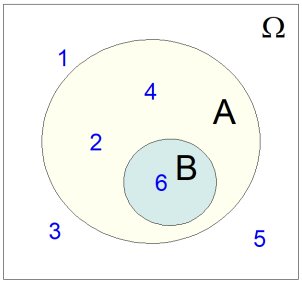
Pane tähele, et sündmus ja tema vastandsündmus ($A$ ja $\bar{A}$) on alati teineteist välistavad.

**Näide 18.** Jätkame täringuviske näidet juba tuttava sündmusega $A$ (paarisarv silmi), kuid nüüd defineerime sündmuse $B$, et tuleb 6 silma (joonis 1.4):
$A =$ "tuleb paarisarv silmi", $A = \{2,4,6\}$ ja
$B =$ "tuleb 6 silma", $B = \{6\}$.
Nüüd näeme, et kui $B$ on toimunud, siis on kindlasti toimunud ka $A$, seega sündmuse $B$ toimumisest järeldub sündmus $A$, ehk võime kirjutada:

$$B \subset A.$$

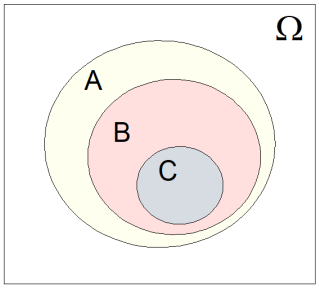
Võib ka öelda, et sündmus $B$ "sisaldub" sündmuses $A$.
Kui $B \subset A$, siis sündmuse $B$ toimumise korral toimub kindlasti ka sündmus $A$, kuid vastupidine ei pruugi kehtida – sündmus $A$ saab toimuda ka nii, et $B$ ei toimu.

*Kui täringut visatakse 1 kord, siis sündmusest "Tulemuseks on 6" järeldub sündmus "Tulemuseks on paarisarv"*




Joonis 1.4: Venni diagramm, mis kujutab täringuviske võimalikke tulemusi ja sündmusi $A =$ "tuleb paarisarv silmi", $A = \{2,4,6\}$ ning $B =$ "saadi 6 silma", $B = \{6\}$. Näeme, et $B \subset A$, ehk sündmuse $B$ toimumisest järeldub sündmus $A$.

Edaspidi tutvume ka olukordadega, kus üksteisest järelduvate sündmuste jada on pikem – nt kolm või rohkem (joonis 1.5).




Joonis 1.5: Venni diagramm, mis kujutab olukorda $C \subset B \subset A$.

### 1.4.3 Omadused mis defineerivad tõenäosuse

Tõenäosuse formaalseks (matemaatiliselt korrektseks) defineerimiseks ja tõenäosusteooria teoreetilisemate tulemuste mõistmiseks oleks esmalt vaja tutvuda mõõduteooriaga. Käesoleva kursuse raames me kasutame veidi lihtsustatud käsitlust (huvi korral võib lugeda peatükki 1.6) ja seal viidatud materjale mujalt.

Käesolevas kursuses on oluline on teada, et tõenäosus on defineeritud kui **funktsioon** $P()$, mis seab igale sündmusele (ehk igale $\Omega$ alamhulgale) vastavusse arvu lõigul $[0; 1]$.

Funktsiooni $P()$ saab aga nimetada tõenäosuseks siis, kui kehtivad järgmised omadused:

**P1.** $P(A) \geq 0, \ \forall A$

**P2.** $P(\Omega) = 1, \ P(\emptyset) = 0,$

**P3.** Kui sündmused $A_1, A_2, \ldots$ on üksteist välistavad, siis

$$P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i).$$

Omadusest P3 järeldub ka tõenäosuse lõplik aditiivsus: kui $A_i \cap A_j = \emptyset$ $(i \neq j)$, siis $P(\cup_{i=1}^{n} A_i) = \sum_{i=1}^{n} P(A_i)$.
(Selle tõestamiseks vt juhtu, kus sündmused $A_{n+1}, A_{n+2} \ldots$ on kõik tühjad hulgad, st $A_{n+i} = \emptyset$, $\forall i \geq 1$.)

Et omadused P1, P2 ja P3 on osaks tõenäosuse definitsioonist, siis neid ei pea tõestama – kui leidub funktsioon $P()$, mis mõnda neist ei rahulda, siis $P()$ ei saa olla tõenäosus.

### 1.4.4 Omadused, mis järelduvad definitsioonist

**Om. 1** Kui $A \cap B = \emptyset$, siis $P(A \cup B) = P(A) + P(B)$

*Tõestus.* See omadus järeldub lõplik-aditiivsusest, kui $n = 2$.

**Om. 2** Tõkestatus: iga sündmuse $A$ korral $P(A) \leq 1$

**Om. 3** Vastandsündmuse tõenäosus: $P(\bar{A}) = 1 - P(A)$

*Tõestus.* Omadused 2 ja 3 järelduvad omadusest 1 ja faktist, et suvalise sündmuse $A$ korral: $\Omega = A \cup \bar{A}$, ning $A \cap \bar{A} = \emptyset$, millest saame võrduse $P(A) + P(\bar{A}) = 1$.

**Om. 4** Monotoonsus: kui $B \subset A$, siis $P(B) \leq P(A)$

*Tõestus.* Paneme tähele, et $A$ saab jagada kaheks teineteist välistavaks sündmuseks: $B$ ja $A \backslash B$. Seega:

$$P(A) = P[B \cup (A \backslash B)] = P(B) + P(A \backslash B) \geq P(B)$$

**Om. 5** Vahe tõenäosus: $P(A \backslash B) = P(A) - P(A \cap B)$

*Tõestus.* Paneme tähele, et $A \backslash B$ ja $A \cap B$ on teineteist välistavad sündmused ning $A = (A \backslash B) \cup (A \cap B)$. Seega $P(A) = P(A \backslash B) + P(A \cap B)$ ja $P(A \backslash B) = P(A) - P(A \cap B)$.

**Om. 6** Suvalise kahe sündmuse summa tõenäosus: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

*Tõestus.* Paneme tähele, et sündmused $A \backslash B$ ja $B$ on teineteist välistavad ning $A \cup B = (A \backslash B) \cup B$. Liitmisreegli kohaselt: $P(A \cup B) = P(A \backslash B) + P(B)$. Et $P(A \backslash B) = P(A) - P(A \cap B)$, siis saamegi $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

**Om. 7** Boole'i võrratus: $P(A \cup B) \leq P(A) + P(B)$

*Tõestus.* Järeldub omadusest 6.

**Om. 8** Üldine liitmislause:

$$P(\bigcup_{i=1}^{n} A_i) = \sum_{i=1}^{n} P(A_i) - \sum_{i<j} P(A_i \cap A_j) + \sum_{i<j<k} P(A_i \cap A_j \cap A_k) - \ldots + (-1)^{n-1} P(A_1 \cap \ldots \cap A_n)$$

**Om. 9** Üldine Boole'i võrratus:

$$P(\bigcup_{i=1}^{\infty} A_i) \leq \sum_{i=1}^{\infty} P(A_i)$$

Omaduste 8 ja 9 tõestamiseks saab kasutada matemaatilist induktsiooni, kasutades baasina omadusi 6 ja 7.

**Näide 19.** Täringut visatakse 6 korda. Leida tõenäosus, et kuue viske jooksul vähemalt üks kord tulevad nii 1, 2, kui ka 3.

**Lahendus:**

Mõnikord on lihtsam leida vastandsündmuse tõenäosus ja seejärel kasutada omadust, et $P(A) = 1 - P(\bar{A})$

Meid huvitava sündmuse vastandsündmus on see, et kuue katse jooksul jääb tulemata kas 1, 2 või 3, ehk siis $A_1 \cup A_2 \cup A_3$, kus $A_i$ $(i = 1,2,3)$ on sündmus, et kordagi ei tule $i$.

Seega on meil vaja leida tõenäosus:

$$P(\overline{A_1 \cup A_2 \cup A_3}) = 1 - P(A_1 \cup A_2 \cup A_3)$$

Eelnevalt nägime, et:

$$P(A_1 \cup A_2 \cup A_3) = P(A_1) + P(A_2) + P(A_3) - P(A_1 \cap A_2) - P(A_1 \cap A_3) - P(A_2 \cap A_3) + P(A_1 \cap A_2 \cap A_3)$$

Tõenäosus, et ühel viskel ei tule tulemuseks 1 silm, on $\frac{5}{6}$

Tõenäosus, et kuuest viskest mitte ühelgi ei tule tulemuseks 1 silm, on

$$P(A_1) = \left(\frac{5}{6}\right)^6 = P(A_2) = P(A_3)$$

(miks?)

$P(A_1 \cap A_2)$ on tõenäosus, et 6 viskel ei tule 1 ega 2. On lihtne (?) näha, et:

$$P(A_1 \cap A_2) = \left(\frac{4}{6}\right)^6 = P(A_1 \cap A_3) = P(A_2 \cap A_3)$$

Samamoodi saab leida, et:

$$P(A_1 \cap A_2 \cap A_3) = \left(\frac{3}{6}\right)^6$$

Saame ,et:

$$P(A_1 \cup A_2 \cup A_3) = 3 \cdot \left(\frac{5}{6}\right)^6 - 3 \cdot \left(\frac{4}{6}\right)^6 + \left(\frac{3}{6}\right)^6 \approx 0{,}76$$

ja

$$P(\overline{A_1 \cup A_2 \cup A_3}) = 1 - P(A_1 \cup A_2 \cup A_3) = 1 - 0{,}76 = 0{,}24.$$

Seega ligikaudu 24%-l viskeseeriatest on tulemuste seas nii 1, 2 kui ka 3.

## 1.5 Lisa: kombinatoorika reeglid.

Kõik kombinatoorika reeglid ja valemid tulevad ühest põhireeglist.

**Kombinatoorika põhireegel.** Kui esimesele kohale on võimalik valida $n_1$ elemendi vahel, pärast ükskõik millise esimese elemendi saamist on teisele kohale võimalik valida $n_2$ elemendi vahel jne, ning pärast ükskõik millise eelviimase elemendi saamist on viimasele kohale võimalik valida $n_k$ elemendi vahel, siis kokku on võimalik saada $n_1 \cdot n_2 \cdot \ldots \cdot n_k$ erinevat k-elemendilist järjestatud kogumit.

**Näide 20.** Ausat 6-tahulist täringut veeretatakse kaks korda. (a) Kui palju on erinevaid võimalikke tulemuste paare, kui arvestame visete järjestust (Nt loeme tulemused 1; 2 ja 2; 1 erinevaks)? (b) kui palju on tulemusi, kus kahe viske skooride summeerimisel saadakse 6?

**Lahendus:**
(a) Kummagil viskel on 6 võimalikku tulemust, seega on erinevaid tulemusi $6 \cdot 6 = 36$;
(b) Esimese viske jaoks on 5 võimalust, sest kui saadaks kuus silma, siis ei saaks kahe viske summa 6 olla. Teise viske puhul on alati täpselt üks selline võimalik tulemus, mille puhul on summa 6. Seega on kokku $5 \cdot 1 = 5$ tingimusele vastavat tulemust.

**Näide 21.** Karbis on 6 eri värvi pliiatsit. Kui palju on erinevaid võimalusi: (a) kolme erineva pliiatsi väljavõtmiseks, järjekorda arvestades; (b) kuue erineva pliiatsi väljavõtmiseks, järjekorda arvestades; (c) kolme erineva pliiatsi väljavõtmiseks, järjekorda arvestamata (st kui palju on erinevaid 3-värvilisi komplekte)?

**Lahendus:**
(a) Esimese pliiatsi võtmiseks on 6 võimalust. Kui esimene pliiats on välja võetud, siis on veel 5 võimalust teise pliiatsi võtmiseks ja teise võtmise järel on veel 4 võimalust kolmanda võtmiseks. Seega on $6 \cdot 5 \cdot 4 = 120$ võimalust.
(b) Sarnaselt eelmisele ülesandele saame, et kokku on $6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 6! = 720$ võimalust. NB! Sisuliselt on see võimalike järjestuste arv 6 erineva elemendi korral.

(c) Osas (a) leitud arv 120 sisaldab iga 3-elemendilise komplekti kõiki võimalikke järjestusi. Erinevate järjestuste arv 3 elemendi korral on $3! = 6$. Seega on erinevaid komplekte kokku $120/6 = 20$.

Järeldused kombinatoorika põhireeglist:

1. $k-$ elemendiliste järjestatud komplektide moodustamisel nii, et kordused on lubatud, on võimalik saada $n^k$ erinevat komplekti.
   *(Näide 20 (a))*
2. $n$ elemendi kõikvõimalikke järjestusi ehk permutatsioone on $1 \cdot 2 \cdot \ldots \cdot n = n!$.
   *(Näide 21 (b))*
3. Variatsioonideks $n$ elemendist $k$ kaupa nimetatakse $k$-elemendilisi (kordusi mittesisaldavaid) järjestatud komplekte $n$-st erinevast elemendist. Variatsioonide arvuks on:
$$V_n^k = (n)_k = n \cdot (n-1) \cdot \ldots \cdot (n-k+1) = \frac{n!}{(n-k)!}$$
   *(Näide 21 (a))*
4. $n$-elemendilise hulga $k$-elemendilisi alamhulki (järjestust ei eristata) nimetatakse kombinatsioonideks $n$ elemendist $k$ kaupa ja võimalike kombinatsioonide arv on:
$$C_n^k = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$
   *(Näide 21 (c))*

## 1.6 Lisa: Tõenäosuse formaalne definitsioon Kolmogorovi aksiomaatika kaudu.

Elementaarsündmuste hulga $\Omega$ alamhulkade süsteemi $\mathcal{F}$ nimetatakse sündmuste ruumiks, kui ta rahuldab järgmisi nõudeid:

1. $\mathcal{F}$ sisaldab tühihulka ja koguhulka: $\emptyset, \Omega \in \mathcal{F}$
2. Kui $A_i \in \mathcal{F}, i = 1,2,\ldots$, siis ka $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$ (süsteem $\mathcal{F}$ on kinnine loenduva ühendi võtmise suhtes);
3. Kui $A \in \mathcal{F}$, siis $\bar{A} \in \mathcal{F}$ (süsteem $\mathcal{F}$ on kinnine täiendi võtmise suhtes);

Sündmuste ruumi $\mathcal{F}$ nimetatakse ka $\sigma$-algebraks (sigma-algebra).

Sündmusteks loeme ainult neid $\Omega$ osahulki, mis on $\mathcal{F}$ elemendid.

Kehtib järgmine tulemus:
**Lemma.** Kui $A$ ja $B$ on sündmused (st $A$,$B \in \mathcal{F}$), siis ka hulgad $A \cup B$, $A \cap B$ ja $A \backslash B$ on sündmused ($\in \mathcal{F}$).

Seega $\mathcal{F}$ on kinnine erinevate operatsioonide suhtes.

**Näide 22.** Visatakse täringut, $\Omega = \{(1,2,3,4,5,6)\}$. Sündmuste ruumiks $\mathcal{F}$ võime võtta $\Omega$ kõigi alamulkade hulga:

$$\mathcal{F} = \{\emptyset, \{1\},\{2\},\ldots,\{6\},\{1,2\},\ldots,\{5,6\},\{1,2,3\},\{1,3,4\},\ldots.\{4,5,6\},\ldots,\Omega\}$$

Kui aga täringuviskel huvitab meid ainult see, kas tuleb paarisarv või paaritu arv, siis võime piirduda palju väiksema sündmuste süsteemiga:

$$\mathcal{F} = \{\emptyset, \{1,3,5\}, \{2,4,6\}, \Omega\}$$

**Tõenäosuseks** nimetatakse funktsiooni $P$, mis igale sündmusele $A \in \mathcal{F}$ seab vastavusse arvu $P(A)$ nii, et on täidetud järgmised tingimused ehk **aksioomid**:

**P1.** $P(A) \geq 0,\ \forall A \in \mathcal{F}$

**P2.** $P(\Omega) = 1,\ P(\emptyset) = 0,$

**P3.** Kui sündmused $A_1, A_2, \ldots$ on üksteist välistavad, siis

$$P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$$

Kolmikut $(\Omega, \mathcal{F}, P)$ nimetatakse tõenäosusruumiks.

Need aksioomid sõnastas esmakordselt vene teadlane A. Kolmogorov aastal 1933 (nn Kolmogorovi aksioomid).

Vt ka K. Pärna õpikust lk 29-33 või ka mõõduteooriast lähtuvat käsitlust aines “Tõenäosusteooria 2” (https://courses.ms.ut.ee/2023/tnt2/fall).

# Peatükk 2

# Tinglik tõenäosus ja sellega seotud olulised valemid.

## 2.1 Tinglik tõenäosus, tõenäosuslik sõltuvus ja sõltumatus

### 2.1.1 Tingliku tõenäosuse definitsioon

Väga suur osa statistilisest andmeanalüüsist ja andmeteadusest tegeleb seoste otsimisega andmetes. Teoreetilise baasi statistiliste seoste defineerimiseks ja uurimiseks annab aga tõenäosusteooria – seetõttu on oluline tutvuda tõenäosusliku seosega kahe või enama sündmuse vahel ja sellega seotud olulisemate reeglite ja valemitega.

**Näide 1.** Vaatleme juba varasemalt tuttavat juhuslikku katset, kus visatakse kahte ausat kuuetahulist täringut. Olgu sündmus $A$, et vähemalt ühel täringul saadakse 6 silma ja olgu sündmus $B$, et kahe täringu silmade summa on suurem kui 9 (ehk siis 10, 11 või 12). Vaadates eelmise peatüki tabelit 1.1 näeme, et $P(A) = \frac{11}{36}$ ja $P(B) = \frac{6}{36} = \frac{1}{6}$. Oletame nüüd et on teada, et sündmus $B$ on toimunud – st kahe täringu silmade summa suurem kui 9. Seega pidid täringutel nähtud silmad moodustama ühe 6-st kombinatsioonist $\{(4;6),(5;5),(5;6),(6;4),(6;5),(6;6)\}$. Näeme, et ainult üks neist on selline, kus sündmus $A$ ei ole toimunud $(5;5)$. Seega kui on juba teada, et $B$ on toimunud, siis tõenäosusega $\frac{5}{6}$ on toimunud ka $A$, ehk saame kirjutada, et:

Sündmuse $A$ tinglik tõenäosus tingimusel, et sündmus $B$ on toimunud, on $P(A|B) = \frac{5}{6}$.

Oletame nüüd, et vastupidiselt eelnevale on teada hoopis, et toimus sündmus $\bar{B}$, st kahe täringu silmade summa jäi väiksemaks kui 10. Sama tabeli abil näeme nüüd, et sündmusele $\bar{B}$ vastab 30 võimalikku tulemustepaari ja neist 6 on sellised, kus saadi vähemalt üks 6. Seega: $P(A|\bar{B}) = \frac{6}{30} = \frac{1}{5}$.

Eelmises näites nägime, et sündmuse $A$ tõenäosus sõltus sündmuse $B$ toimumisest või mittetoimumisest. Nagu hiljem näeme, saame sellisel juhul öelda, et tegemist on sõltuvate sündmustega. Esmalt aga tutvume tingliku tõenäosuse definitsiooniga.

**Definitsioon.** Sündmuse $A$ tinglikuks tõenäosuseks tingimusel, et $B$ on toimunud ($P(B) > 0$), nimetatakse suhet:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}. \tag{2.1}$$

**Tingliku tõenäosuse leidmine klassikalise tõenäosuse põhimõttel.**
Kui võrdvõimalikest katsetulemustest $n_A$ vastab sündmusele $A$, $n_B$ sündmusele $B$ ning $n_{AB}$ on sellised, mille puhul on nii $A$ kui $B$ toimunud, st toimus $AB$ (ehk $A \cap B$), siis tinglik tõenäosus $P(A|B)$ avaldub kui:

$$P(A|B) = \frac{n_{AB}}{n_B}.$$

Näeme, et see on kooskõlas tingliku tõenäosuse definitsiooniga, sest kui me leiame valemis 2.1 lugejas ja nimetajas olevad tõenäosused klassikalise tõenäosuse põhimõttel, eeldusel et kõigi võrdvõimalike katsetulemuste koguarv on $N$, saame:

$$\frac{P(A \cap B)}{P(B)} = \frac{n_{AB}/N}{n_B/N} = \frac{n_{AB}}{n_B}.$$

Seega näeme, et tingliku tõenäosuse leidmisel ei ole meil vaja katsetulemuste koguarvu $N$.

**Näide 2.** Karbis on 6 musta, 4 valget ja 58 punast kuuli. Sealt võetakse juhuslikult üks kuul. Leida tõenäosus, et see on valge, kui on teada, et see kuul pole punane.

**Lahendus:**
Leiame valgete kuulide osakaalu kõigi "mittepunaste" kuulide seas:

$$P(A|B) = \frac{n_{AB}}{n_B} = \frac{4}{10} = \frac{2}{5} = 0{,}4.$$

Näeme, et selle ülesande vastust ei mõjuta see, kui palju on karbis punaseid kuule (või kui palju on kuule kokku) – tingimus kitsendab võimalike sündmuste arvu 10-ni.

Paneme tähele, et tingliku tõenäosuse korral võib tingimust vaadelda ka kui kõikvõimalike sündmuste hulga kitsendust. Seega **kehtivad kõik tõenäosuse omadused ka tinglike tõenäosuste korral**, eelguseks et tingimuseks oleval sündmusel on postiivne tõenäosus. Näiteks:

- $P(\bar{A}|B) = 1 - P(A|B)$, eeldusel et $B \neq \emptyset$
- $P(A \cup B|C) = P(A|C) + P(B|C) - P(A \cap B|C)$, eeldusel et $C \neq \emptyset$.

Toodud omaduste kehtivuses on lihtne veenduda, kasutades tingliku tõenäosuse definitsiooni:

$$P(\bar{A}|B) = \frac{P(\bar{A} \cap B)}{P(B)} = \frac{P(B \backslash A)}{P(B)} = \frac{P(B) - P(A \cap B)}{P(B)} = 1 - \frac{P(A \cap B)}{P(B)} = 1 - P(A|B),$$

$$P(A \cup B|C) = \frac{P[(A \cup B) \cap C]}{P(C)} = \frac{P[(A \cap C) \cup (B \cap C)]}{P(C)} = \frac{P(A \cap C) + P(B \cap C) - P(A \cap B \cap C)}{P(C)} =$$
$$= P(A|C) + P(B|C) - P(A \cap B|C).$$

Mõnikord võib aga teatud seos $A$ ja $B$ vahel (nt teineteist välistavus või üksteisest järeldumine) kehtida vaid tinglikuna.

**Näide 3.** Vaatleme jälle kahe täringu viskamise näidet. Olgu nüüd sündmused $A$: "esimesel täringul saadi 6 silma", $B$: "teisel täringul saadi 6 silma" ja $C$: "kahe täringu silmade summa on väiksem kui 10".
Pane tähele, et sündmused $A$ ja $B$ ei ole teineteist välistavad, sest 6 võib tulla ka mõlemal täringul korraga. Kui aga sündmus $C$ on toimunud, siis ei ole $A$ ja $B$ samaaegne toimumine võimalik (sest muidu ei oleks summa alla 10), ehk tingimusel $C$ on tegemist teineteist välistavate sündmustega. Seega siin näites:

$P(A \cup B) \neq P(A) + P(B)$, aga $P(A \cup B|C) = P(A|C) + P(B|C)$.

### 2.1.2 Tõenäosuste korrutamise lause.

Vaatleme kahte sündmust $A$ ja $B$ ning kehtigu, et $P(B) > 0$ ja $P(A) > 0$. Kasutame tingliku tõenäosuse definitsiooni 2.1 ja korrutame selle võrduse mõlemat poolt läbi sündmuse $BS$ tõenäosusega $P(B)$:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \Longrightarrow \quad P(A \cap B) = P(A|B)P(B).$$

Kui ka $P(A) > 0$, siis saame tõenäosuse $P(B|A)$ definitsioonist samamoodi tuletada ka seose $P(A \cap B) = P(B|A)P(A)$. Seega kehtib:

$$P(A \cap B) = P(A|B)P(B) = P(B|A)P(A). \tag{2.2}$$

Omadust 2.2 tuntakse tõenäosuste korrutamise lausena (lihtsal juhul).

Tõenäosuse korrutamise lausest on lihtne aru saada klassikalise tõenäosuse peale mõeldes. Näiteks kui me küsime, kui suur on tõenäosus et juhuslikult valitud inimene on naine, kes kannab prille, siis meil on vaja esmalt teada naiste osakaalu kõigi inimeste seas ($P(A)$) ja seejärel prillikandjate osakaalu naiste seas ($P(B|A)$). Inimeste koguarvu korrutamine avaldisega $P(A)P(B|A)$ on sisuliselt samaväärne protsendi võtmisega kaks korda järjest.

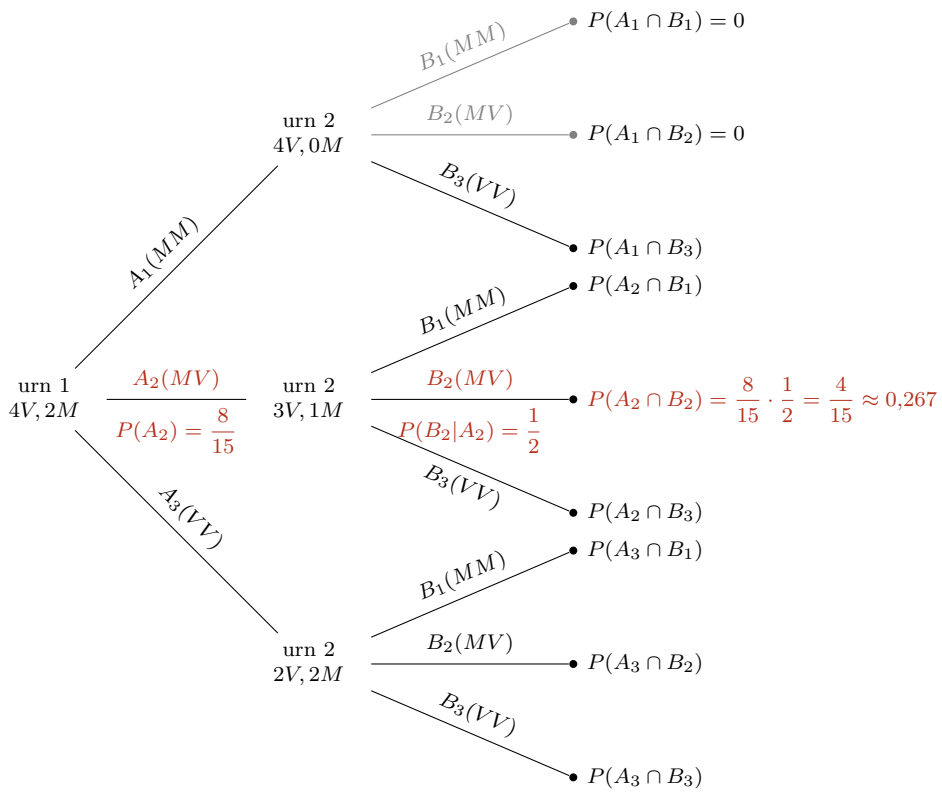
**Näide 4.** Urnist kus on 4 valget ja 2 musta kuuli, võetakse juhuslikult kaks kuuli ja pannakse kõrvale. Seejärel võetakse urnist veel kaks kuuli. Kui suur on tõenäosus, et mõlemal korral saadakse üks must ja üks valge kuul?

**Lahendus:**
Olgu sündmus $A$, et esimesel korral saadi must ja valge kuul ning sündmus $B$ et teisel korral saadi must ja valge kuul. Nii nagu eelmise peatüki näites 5 oli näidatud (vt ka tabelit 1.2), on tegu tagasipanekuta valikuga ja saame leida, et $P(A) = \frac{16}{30} = \frac{8}{15}$.
Kui sündmus $A$ on toimunud, siis on urnis järel veel 3 valget ja 1 must kuul. Saame leida tõenäosuse $P(B|A) = \frac{6}{12} = \frac{1}{2}$, sest kokku on 12 võimalust neljast kuulist kahe väljavõtmiseks ja neist 6 korral võetakse kaks eri värvi kuuli. Seega:

$$P(A \cap B) = P(A)P(B|A) = \frac{8}{15} \cdot \frac{1}{2} = \frac{4}{15} \approx 0{,}267.$$

*Seda ülesannet saaks lahendada ka ilma tõenäosuste korrutamise reeglit kasutamata, klassikalise tõenäosuse põhimõtet kasutades. Siis peaksime leidma, mitu võimalust on nelja kuuli järjestikuseks võtmiseks urnist ja mitmel juhul neist on toimunud sündmus $A \cap B$. Selline lähenemine tundub aga keerukam ja aeganõudvam – tõenäosuste korrutamise reegli kasutamine teeb ülesande märksa lihtsamaks.*

Tõenäosuste korrutamise lauset saab illustreerida ka otsusepuu abil – iga järjestikuse sündmuse toimumine või mittetoimumine tekitab hargnemise, ja kord juba ühel harul olles ei paku kõrvalharude tõenäosused enam huvi. Näitamaks puul kõiki võimalikke sündmuseid, mis antud katses toimuda saavad, tähistame diagrammil sündmusi veidi teisiti kui üleltoodud lahenduses.




Osutub, et tõenäosuste korrutamise lauset saame laiendada ka juhule, kus toimub rohkem kui 2 sündmust.

Kasutame siin lihtsuse mõttes kahe sündmuse korraga toimumise (ühisosa ehk korrutise) $A \cap B$ tähistamiseks tähistust $AB$. Olgu ka $n$ sündmuse, $A_1, A_2, \ldots, A_n$) korraga toimumise tõenäosuse tähistuseks $P(A_1 A_2 \ldots A_n)$.

Üldine tõenäosuste korrutamise lause: $n$ sündmuse, $A_1, A_2, \ldots, A_n$, korrutise (korraga toimumise ehk ühisosa) tõenäosus avaldub kui:

$$P(A_1 A_2 \ldots A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 A_2) \cdot \ldots \cdot P(A_n|A_1 A_2 \ldots A_{n-1}) \tag{2.3}$$

Selle kehtivuses on lihtne veenduda, kui defineerime sündmuse $B = A_1 A_2 \ldots A_{n-1}$, ning kasutame lihtsat tõenäosuste korrutamise lauset 2.2:
$P(A_1 A_2 \ldots A_n) = P(BA_n) = P(A_n|B)P(B) = P(A_n|A_1 A_2 \ldots A_{n-1})P(A_1 A_2 \ldots A_{n-1})$.
Näeme, et samamoodi saame avaldada:
$P(A_1 A_2 \ldots A_{n-1}) = P(A_{n-1}|A_1 A_2 \ldots A_{n-2})P(A_1 A_2 \ldots A_{n-2})$, jne. Nii jätkates jõuamegi valemini 2.3.

**Näide 5.** Peetri sahtlis on 4 valget ja 6 musta sokki. Iga tööpäeva hommikul võtab ta sealt juhuslikult kaks sokki ja paneb jalga (õhtul ei pane ta neid sinna tagasi). Kui suur on tõenäosus, et nii esmaspäeval, teisipäeval kui kolmapäeval on tal jalas kaks eri värvi sokki?

**Lahendus:**
Defineerime sündmused $A$, $B$ ja $C$, et Peeter võttis vastavalt esmaspäeval, teisipäeval ja kolmapäeval sahtlist kaks eri värvi sokki.

- Esmaspäeval on Peetril $9 \cdot 10 = 90$ varianti 2 soki võtmiseks, sh $2 \cdot 4 \cdot 6 = 48$ võimalust võtta kaks eri värvi sokki, seega $P(A) = \frac{48}{90}$.
- Teisipäevaks on jäänud sahtlisse 8 sokki, seega on seal $8 \cdot 7 = 56$ varianti kahe soki valimiseks. Kui esmaspäeval võeti kaks eri värvi sokki (st toimus sündmus $A$), siis jääb $2 \cdot 3 \cdot 5 = 30$ võimalust võtta 2 eri värvi sokki. Seega

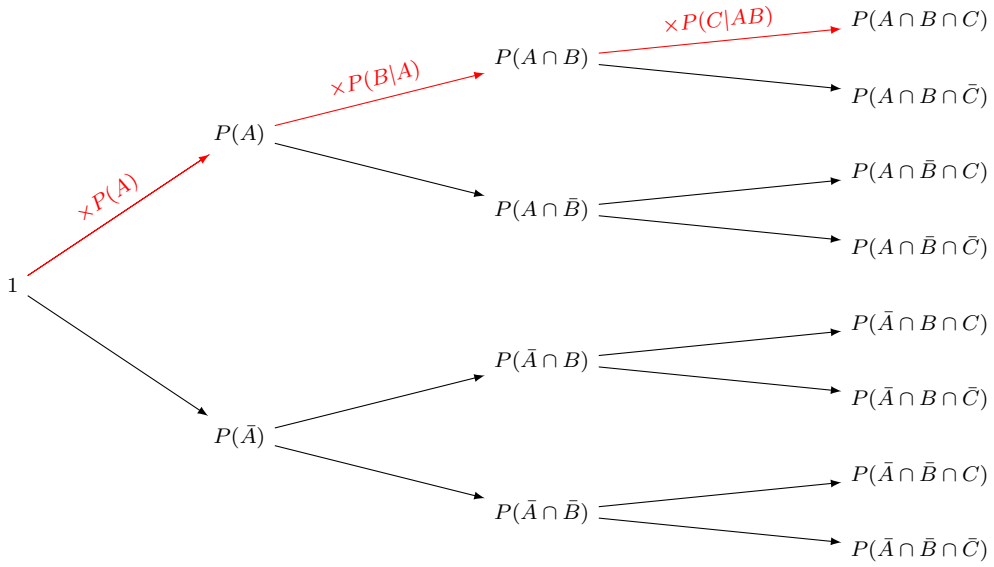
leiame, et $P(B|A) = \frac{30}{56}$. (NB! See ei ole sama, mis $P(B)$, sest kui me ei teaks kas $A$ on toimunud, siis me ei teaks ka, millised sokid on sahtlisse jäänud.)

- Kolmapäevaks on jäänud $6 \cdot 5 = 30$ varianti kahe soki valimiseks. Kui nii esmaspäeval kui teisipäeval on võetud kaks eri värvi sokki, siis on sahtlisse jäänud 2 valget ja 4 musta sokki ning seega on $2 \cdot 2 \cdot 4 = 16$ võimalust võtta 2 eri värvi sokki. Saame, et $P(C|AB) = \frac{16}{30}$.

Nüüd rakendame tõenäosuste korrutamise lauset:

$$P(ABC) = P(A) \cdot P(B|A) \cdot P(C|AB) = \frac{48}{90} \cdot \frac{30}{56} \cdot \frac{16}{30} = \frac{16}{105} \approx 0{,}152$$

Selle näite saab esitada ka nn otsustuspuu abil.




Nagu näha, tekib kolme sündmuse abil 8-haruline puu, sest iga sündmuse puhul on võimalik kas selle toimumine või mittetoimumine (sündmus või vastandsündmus) ja seega on võimalikke kombinatsioone kokku $2 \times 2 \times 2 = 8$. Meid huvitab ainult üks neist ja seega võime õige tõenäosuseni jõudmiseks liikuda ainult neid harusid pidi, mis selleni viivad, ning meid ei huvita muude harude tõenäosused.

**Näide 6.** Ühes arvutimängus on 10 taset. Kes esimese taseme ära lõpetab, see saab hakata mängima teist taset, teise taseme lõpetamisel kolmandat jne. Esimesed kolm taset on lihtsad: esmakordsel mängimisel suudab 1., 2. või 3. taseme lõpetada 95% mängijatest. Järgmised 3 taset on veidi keerukamad – nende eduka lõpetamise tõenäosus on esmakordsel mängimisel 80%. Viimased 4 taset on veelgi keerukamad ja nende lõpetamise tõenäosus on 50%. Kui suur on tõenäosus, et mängija jõuab esimese korraga 10. taseme lõppu – st lõpetab edukalt kõik 10 taset?

**Lahendus:**
Olgu $A_1, A_2, \ldots, A_{10}$ sündmused, et mängija lõpetab taseme 1, 2, …, 10.

$$P(A_1A_2 \ldots A_{10}) = P(A_1)P(A_2|A_1) \ldots P(A_{10}|A_1A_2 \ldots A_9) = 0{,}95^3 \cdot 0.8^3 \cdot 0.5^4 \approx 0{,}027.$$

Ehk ühe korraga suudab kõik 10 taset läbida vaid 2,7% mängijatest.

**Tõenäosuste korrutamise lause erijuht, kui sündmused järelduvad üksteisest.**
Eelmises näites panime tähele, et kui mängija on lõpetanud taseme $A_i$ $(i > 1)$, siis on kindel, et ta pidi eelnevalt

lõpetama ka taseme $A_{i-1}$ ja kõik sellele eelnevad tasemed. Seega saame öelda, et $A_i \subset A_{i-1}$ ning $A_i \cap A_{i-1} = A_i$. Seega võime kirjutada, et $P(A_i|A_1A_2 \dots A_{i-1}) = P(A_i|A_{i-1})$.

Üldiselt, saame järgmise tulemuse.
Olgu meil sündmuste jada nii, et $A_n \subset A_{n-1} \subset \dots \subset A_2 \subset A_1$. Sellisel juhul kehtib:

$$P(A_1A_2A_3 \dots A_{n-1}A_n) = P(A_n|A_{n-1})P(A_{n-1}|A_{n-2}) \dots P(A_2|A_1)P(A_1).$$

Seda valemit saame kasutada olukorras, kus iga sündmuse $A_i$ tõenäosus sõltub ainult sündmusest $A_{i-1}$ ja mitte varasemast "ajaloost" (juhuslike protsesside kontekstis nimetatakse sellist olukorda Markovi ahelaks).

### 2.1.3 Sõltumatud ja sõltuvad sündmused. Positiivselt ja negatiivselt korreleeritud sündmused.

**Definitsioon.** Sündmusi $A$ ja $B$ nimetatakse sõltumatuteks, kui kehtib:

$$P(A \cap B) = P(A) \cdot P(B)$$

Eelnevalt nägime, et: $P(A \cap B) = P(A|B)P(B) = P(B|A)P(A)$.
Seega kehtib sõltumatute sündmuste $A$ ja $B$ korral:

$P(A|B) = P(A)$ ja $P(B|A) = P(B)$, ehk siis sündmuse $A$ toimumise tõenäosus ei sõltu sellest, kas samaaegselt on toimunud sündmus $B$ või mitte (ja vastupidi).

**Näide 7.** Mängukaartide pakist tõmmatakse 1 juhuslik kaart. Siis sündmused $A =$ "saadi pilt" ja $B =$"saadi ärtu" on sõltumatud, sest

$$P(AB) = P(\text{"saadi ärtu pilt"}) = \frac{3}{52}, \quad \text{samuti} \quad P(A) \cdot P(B) = \frac{12}{52} \cdot \frac{1}{4} = \frac{3}{52}.$$

**Definitsioon.** Kui kehtib võrratus

$$P(A|B) > P(A),$$

siis sündmusi $A$ ja $B$ nimetatakse positiivselt korreleerituteks. Vastupidisel juhul, st kui kehtib

$$P(A|B) < P(A),$$

on tegemist negatiivselt korreleeritud sündmustega.

Positiivse korreleerituse tingimuse saab esitada ka alternatiivsel kujul:

$$P(A|B) > P(A) \quad \Leftrightarrow \quad \frac{P(A \cap B)}{P(B)} > P(A),$$

millest

$$P(A \cap B) > P(A) \cdot P(B)$$

Analoogselt kehtib negatiivselt korreleeritud sündmuste korral:

$$P(A \cap B) < P(A) \cdot P(B)$$

### 2.1.4 Sõltumatus rohkem kui kahe sündmuse puhul.

**Definitsioon.** Sündmusi $A_1, A_2, \ldots, A_n$ nimetatakse paarikaupa sõltumatuteks, kui kõik paarid $A_i, A_j (1 \leq i \leq j \leq n)$ on sõltumatud.

**Definitsioon.** Sündmusi $A_1, A_2, \ldots, A_n$ nimetatakse täielikult sõltumatuteks, kui iga $k = 1,2,\ldots$ ja suvaliste indeksite $1 \leq i_1 < i_2 < \ldots < i_k \leq n$ korral kehtib võrdus

$$P(A_{i_1} A_{i_2} \ldots A_{i_k}) = P(A_{i_1}) \cdot P(A_{i_2}) \cdot \ldots \cdot P(A_{i_k})$$

Näiteks kolme sündmuse täielikuks sõltumatuseks on vaja, et kehtiksid kõik võrdused:
$P(AB) = P(A)P(B)$, $P(AC) = P(A)P(C)$, $P(BC) = P(B)P(C)$ ja $P(ABC) = P(A)P(B)P(C)$.

NB! Täielikult sõltumatud sündmused on alati ka paarikaupa sõltumatud, kuid paarikaupa sõltumatud sündmused ei pruugi täielikult sõltumatud olla.

**Näide 8.** Defineerime kahe täringu viskamise tulemuste põhjal kolm sündmust: A="esimesel täringul tuleb 3 silma", B="teisel täringul tuleb 4 silma", C="kahe täringu silmade summa on 7". Näita, et need on paarikaupa sõltumatud, aga mitte täielikult sõltumatud. (Võid kasutada tabelit 1.1.)

**Näide 9.** Laktoositalumatust esineb Eestis 28%-l inimestest (hinnang genotüüpide sageduse põhjal). Kui suur on tõenäosus, et 5-inimeselises grupis vähemalt ühel on laktoositalumatus?

**Lahendus:**
Olgu $A_1, A_2, \ldots, A_5$ sündmused, et 1., 2.,...,5. inimesel on laktoositalumatus.
Oleme juba varem näinud, et sellise ülesande lahendamiseks on hea alustada vastandsündmusest – mitte ühelgi viiest pole laktoositalumatust ja selle tõenäosusest. Kui sündmused $A_i$ on sõltumatud, siis on seda ka vastandsündmused $\bar{A}_i$:

$$\begin{aligned} P(\bar{A}_1\bar{A}_2\bar{A}_3\bar{A}_4\bar{A}_5) &= P(\bar{A}_1) \cdot \ldots \cdot P(\bar{A}_5) = P(\bar{A}_i)^5 = [1 - P(A_i)]^5 = \\ &= (1 - 0{,}28)^5 = 0{,}72^5 \approx 0{,}19. \end{aligned}$$

Seega tõenäosus, et vähemalt ühel on laktoositalumatus, on ligikaudu $1 - 0{,}19 = 0{,}81$, ehk 81%.

## 2.2 Täistõenäosuse valem

Vaatleme nüüd olukorda, kus kogu tõenäosusruum on jagatav üksteist välistavateks sündmusteks.

Kõige lihtsamal juhul ongi tegemist ainult kahe sündmusega, nt $B$ ja $\bar{B}$ (on selge, et $B \cap \bar{B} = \emptyset$ ja $B \cup \bar{B} = \Omega$). Vaatleme nüüd ühte teist sündmust $A$. Sündmuse $A$ toimumiseks on kaks **teineteist väistavat** võimalust: kas toimub sündmus $A \cap B$, st $A$ toimub koos sündmusega $B$; või siis toimub sündmus $A \cap \bar{B}$, st toimub $A$, aga ei toimu sündmust $B$. Seega saame kirjutada:

$$A = (A \cap B) \cup (A \cap \bar{B}), \quad \text{millest liitmisreegli tõttu järeldub, et:}$$

$$P(A) = P[(A \cap B) \cup (A \cap \bar{B})] = P(A \cap B) + P(A \cap \bar{B}).$$

Kui me nüüd rakendame tõenäosustele $P(A \cap B)$ ja $P(A \cap \bar{B})$ tõenäosuste korrutamise reeglit, siis saame, et:

$$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B}). \tag{2.4}$$

Valem 2.4 on **täistõenäosuse valemi** lihtne erijuht.

**Näide 10.** Praktikumis tehti test loengu materjalide peale. Loengus kohal käinud tudengitest sooritas testi edukalt 90% ja loengust puudunud tudengitest sooritas testi edukalt 50%. Kui suur on testi edukalt sooritamise tõenäosus, kui loengus oli kohal 75% praktikumis viibinud tudengitest?

**Lahendus:**
Olgu sündmus $A$, et tudeng sooritas testi edukalt ja sündmus $B$, et tudeng käis loengus. Kasutades ülaltoodud valemit, leiame et:

$$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B}) = 0{,}9 \cdot 0{,}75 + 0{,}5 \cdot 0{,}25 = 0{,}8.$$

Üldisemal juhul saame aga rääkida suuremast arvust sündmustest, mis on üksteist välistavad ja katavad terve $\Omega$.

**Sündmuste täissüsteemiks** nimetatakse sündmuste komplekti $B_1, B_2, \ldots, B_n$ nii, et kehtivad omadused:

$$B_i \cap B_j = \emptyset,\ i \neq j; \quad \bigcup_{i=1}^{n} B_i = \Omega.$$

**Täistõenäosuse valem:**

$$P(A) = \sum_{i=1}^{n} P(A|B_i)P(B_i) \tag{2.5}$$

**Näide 11.** Üks õunamüüja müüb kolme sorti õunu, olgu need sordid A, B ja C. Pooled tema poolt müüdavad õunad on sordist A, 40% sordist B ja 10% sordist C. Selgub, et osad tema poolt müüdavatest õuntest on riknenud (mädanenud), kusjuures sordi A õuntest on riknenud 5%, sordi B õuntest 10%, aga sordi C õuntest ei ole ükski riknenud. Kui valida tema poolt müüdavatest õuntest juhuslikult üks, siis kui suure tõenäosusega on see riknenud?

**Lahendus:**
Olgu sündmus R, et juhuslikult valitud õun on riknenud, ning sündmused A, B ja C vastavad valitud õuna sordile. Kasutades täistõenäosuse valemit, leiame et:

$$P(R) = P(R|A)P(A) + P(R|B)P(B) + P(R|C)P(C) = 0{,}05 \cdot 0{,}5 + 0{,}1 \cdot 0{,}4 + 0 \cdot 0{,}1 = 0{,}065.$$

Seega on riknenud õuna saamise tõenäosus 0,065 ehk ligikaudu 6,5%.

### 2.2.1 Tinglik sõltumatus

Olgu meil sündmused $A \neq \emptyset$ ja $B \neq \emptyset$ ja $C \neq \emptyset$. Öeldakse, et sündmused $A$ ja $B$ on sõltumatud tingimusel $C$, kui:

$$P(A \cap B|C) = P(A|C) \cdot P(B|C).$$

Praktikas näeme tinglikku sõltumatust tihti olukordades, kus $C$ mõjutab nii $A$ kui $B$ toimumise tõenäosust, muutes nad nii ka omavahel sõltuvaks.

**Näide 12.** Oletame, et nii Aivar kui Bruno sõidavad hommikuti autoga tööle. Olgu $A$ sündmus, et Aivar jõuab õigeks ajaks tööle ning olgu $B$ sündmus, et Bruno jõuab õigeks ajaks tööle. Olgu $C$ sündmus, et töökohani viival teel on liiklusummik. Oletame, et liiklusummiku korral on nii Aivari kui Bruno õigeaegse töölejõudmise tõenäosus 50% ning ilma liiklusummikuta jõuavad mõlemad õigeaegselt tööle tõenäosusega 90%. Oletame ka, et liiklusummikuid

esineb 25% hommikutest ning liiklusummik on ainukene asi, mis samaaegselt võib mõjutada nii Aivari kui Bruno töölejõudmist. Seega kui meil on info liiklusummiku kohta, siis on $A$ ja $B$ sõltumatud ehk $P(A \cap B|C) = P(A|C) \cdot P(B|C)$. Näitame, et kui $C$ kohta info puudub, siis $A$ ja $B$ ei ole sõltumatud.

**Lahendus:**
Teame, et $P(C) = 0{,}25$, $P(A|C) = P(B|C) = 0{,}5$. Leiame $P(A)$, $P(B)$ ja $P(A \cap B)$:

$$P(A) = P(A|C)P(C) + P(A|\bar{C})P(\bar{C}) = 0{,}5 \cdot 0{,}25 + 0{,}9 \cdot 0{,}75 = 0{,}8$$

Seega ka $P(B) = 0{,}8$. Tingliku sõltumatuse tõttu teame:

$$P(A \cap B) = P(A \cap B|C)P(C) + P(A \cap B|\bar{C})P(\bar{C}) = 0{,}5 \cdot 0{,}5 \cdot 0{,}25 + 0{,}9 \cdot 0{,}9 \cdot 0{,}75 = 0{,}67$$

Et $P(A) \cdot P(B) = 0{,}64 \neq 0{,}67$, siis ei ole $A$ ja $B$ sõltumatud.

## 2.3 Bayesi valem

### 2.3.1 Bayesi valem lihtsal juhul ja üldjuhul.

Vaatleme näidet 10. Oletame, et tudeng sooritab testi edukalt ja praktikumijuhendaja soovib hinnata tõenäosust, et see tudeng käis loengus. Seega meil oleks vaja hinnata tõenäosust $P(B|A)$, kui meil on teada tõenäosused $P(A|B)$, $P(A|\bar{B})$ ja $P(B)$. Selgub, et selline tingliku tõenäosuse "ümberpööramine" on täiesti võimalik.

Tõenäosuste korrutamise lausest 2.2 leiame, et $P(B|A)P(A) = P(A|B)P(B)$. Sellest võrdusest saame avaldada $P(B|A)$:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)} \tag{2.6}$$

See ongi Bayesi valemi lihtsustatud kuju.

**Näide 13.** Tudeng Toomas on ülikoolis teinud juba 10 eksamit, millest kahel korral õnnestus tal hindeks A saada. Tagantjärele paneb ta tähele, et mõlemal korral oli tal seljas tema sinine lemmiksärk. Üldiselt kannab ta seda särki umbes igal kolmandal päeval. Ta läheb uuesti eksamit tegema ja paneb jälle oma lemmiksärgi selga. Kui suur on tõenäosus, et ta selle eksami A saab (kui eksamitulemus tõepoolest särgist sõltuks)?

**Lahendus:**
Olgu $A$ sündmus, et Toomas saab eksami hindeks $A$. Olgu $B$ sündmus, et Toomas kannab oma lemmiksärki. Toomas hindab oma varasema kogemuse põhjal, et $P(B|A) = 1$. Samuti saab Toomas hinnata, et $P(A) = \frac{2}{10}$ ja $P(B) = \frac{1}{3}$. Rakendades Bayesi valemit, saame:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{1 \cdot \frac{2}{10}}{\frac{1}{3}} = \frac{6}{10} = 0{,}6.$$

Seega on lemmiksärki kandes A saamise tõenäosus 0,6 ehk 60%.
*NB! Pane tähele, et valemis kasutatud tõenäosused on nn statistilised tõenäosused ehk statistilised hinnangud tõenäosusele. Need on adekvaatsed ainult siis, kui katseid on piisavalt palju. (Tõenäosus $P(B|A) = 1$ on hinnatud vaid kahe katse põhjal). Hiljem, kursuse statistika osas, õpime ka selliste hinnangute täpsust hindama. Praegu kandub esialgsete hinnangute ebatäpsus üle ka valemist saadud vastusele. Eksamil edukas olemine sõltub tegelikkuses ikka eelkõige õppimisest :)*

Arvestades, et sündmused $B$ ja $\bar{B}$ moodustavad sündmuste täissüsteemi, saame kasutades täistõenäosuse valemit avaldada $P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$ ja seega ka Bayesi valemi kujul:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})}. \tag{2.7}$$

**Näide 14.** Vt näite 10 olukorda. Praktikumis tehti test loengu materjalide peale. Loengus kohal käinud tudengitest sooritas testi edukalt 90% ja loengust puudunud tudengitest sooritas testi edukalt 50%. Loengus käis 75% praktikumis viibinud tudengitest.
Leiame nende andmete põhjal vastused küsimustele: (a) kui tudeng sooritas testi edukalt, siis kui suure tõenäosusega oli ta ka loengus käinud? (b) Kui tudengil test ebaõnnestus, siis kui suure tõenäosusega oli ta loengust puudunud?

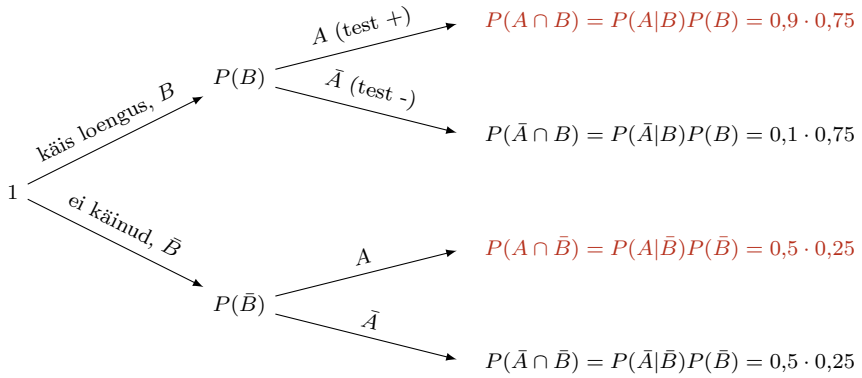
**Lahendus:**
(a) Rakendame otse eeltoodud valemit.

$$P(B|A) = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})} = \frac{0{,}9 \cdot 0{,}75}{0{,}9 \cdot 0{,}75 + 0{,}5 \cdot 0{,}25} = \frac{0{,}9 \cdot 0{,}75}{0{,}8} \approx 0{,}844$$

(nimetajas oleva avaldise väärtus leiti juba näites 10)
(b) Meil on vaja tõenäosust $P(\bar{B}|\bar{A})$. Et eelnevalt leidsime, et $P(A) = 0{,}8$, siis $P(\bar{A}) = 1 - 0{,}8 = 0{,}2$. Samuti teame, et $P(\bar{A}|\bar{B}) = 0{,}5$ ja $P(\bar{B}) = 1 - 0{,}75 = 0{,}25$. Seega:

$$P(\bar{B}|\bar{A}) = \frac{P(\bar{A}|\bar{B})P(\bar{B})}{P(\bar{A})} = \frac{0{,}5 \cdot 0{,}25}{0{,}2} = 0{,}625$$

Ka selles näites võib olla abi puudiagrammist, kus juhul (a) liigume mööda harusid, kus toimub sündmus $A$ ja leiame, kui suurel osal juhtudest toimub ka sündmus $B$ (joonisel punaselt) ning juhul (b) vaatleme harusid, kus toimus $\bar{A}$.




**Näide 15.** Vt näidet 11: õunamüüja müüb kolme sorti õunu, olgu need sordid A, B ja C. Pooled tema poolt müüdavad õunad on sordist A, 40% sordist B ja 10% sordist C. Selgub, et osad tema poolt müüdavatest õuntest on riknenud (mädanenud), kusjuures sordi A õuntest on riknenud 5%, sordi B õuntest 10%, aga sordi C õuntest ei ole ükski riknenud. Oletame, et ostad sellelt õunamüüjalt õunu ja avastad, et esimene kotist võetud õun on riknenud. Kui suure tõenäosusega on tegu õunaga sordist B?
Kasutades näite 11 tähistust, saame otsitava tõenäosuse leida kui:

$$P(B|R) = \frac{P(R|B)P(B))}{P(R)} = \frac{P(R|B)P(B))}{P(R|A)P(A) + P(R|B)P(B) + P(R|C)P(C)}.$$

Et tõenäosus $P(R)$ on näites 11 juba täistõenäosuses valemi abil leitud ($P(R) = 0{,}065$), saame kasutada valemi esimest, lihtsamat varianti:

$$P(B|R) = \frac{0{,}1 \cdot 0{,}4}{0{,}065} = \frac{40}{65} \approx 0{,}615.$$

Seega on tõenäosusega 61,5% tegu just õunaga sordist B.

Paneme tähele, et see näide erineb eelnevatest selle poolest, et täistõenäosuse valemi kasutamisel nimetajas oleva tõenäosuse leidmiseks peame arvestama kolmest sündmusest koosneva täissüsteemiga. Seega oleme siin kasutanud veidi üldisemat Bayesi valemit.

**Bayesi valem (üldine).** Moodustagu $B_i,\ i = 1,2,\ldots$ täissüsteemi. Suvalise sündmuse $A$ korral, kus $P(A) > 0$, kehtib valem:

$$P(B_j|A) = \frac{P(A|B_j)P(B_j)}{P(A)} = \frac{P(A|B_j)P(B_j)}{\sum_{i=1}^{n} P(A|B_i)P(B_i)},\quad j = 1,2,\ldots,n. \tag{2.8}$$

**Bayesi valem ja Bayesi statistika**

Bayesi valem on aluse pannud terve statistika koolkonna, Bayesi statistika arengule. Selgitamaks veidi Bayesi statistika üldist filosoofiat, kirjutame valemi 2.6 kujul:

$$P(B|A) = P(B) \cdot \frac{P(A|B)}{P(A)}. \tag{2.9}$$

Tõenäosust $P(B)$ saame nimetada sündmuse $B$ **aprioorseks tõenäosuseks** (*ingl. prior probability*) – see on see, mida me sündmuse $B$ kohta teame ilma lisainformatsioonita sündmuse $A$ kohta. Kui lisandub informatsioon, et $A$ on toimunud, siis muutub sündmuse $B$ tõenäosus $\frac{P(A|B)}{P(A)}$ korda. Suhet $\frac{P(A|B)}{P(A)}$ nimetatakse ka tõepärasuhteks (*ingl. likelihood ratio*) ja see iseloomustab, mitu korda muudab $B$ toimumine $A$ tõenäosust. Tulemusena saadakse tõenäosus $P(B|A)$, mida nimetatakse sündmuse $B$ **aposterioorseks tõenäosuseks**. Andmeanalüüsi kontekstis on $A$ rollis vaadeldud andmed, mille eesmärgiks on täpsustada varasemat teadmist $B$ (enamasti teatud parameetri väärtuse) kohta.

**Näide 16.** Üks firma toodab mälupulki. Selle firma toodangust on müügile jõudnud 5 ühesuguse suurusega partiid. Kvaliteedikontroll on näidanud, et umbes 1% selle firma toodetud mälupulkadest on rikkega. Mälupulki müüv pood märkab, et kõik tagasitoodud rikkega mälupulgad on pärit partiist nr 4. Leiame tõenäosuse, et kui inimene ostab mälupulga mis on partiist nr 4, siis see on rikkega.

**Lahendus:**

Olgu $A_4$ sündmus, et mälupulk on pärit partiist nr 4. Olgu $B$ sündmus, et mälupulk on rikkega. Siin aprioorne tõenäosus on $P(B) = 0{,}01$ (rikke tõenäosus enne poest saadud lisainfot). Samuti teame, et $P(A_4) = \frac{1}{5} = 0{,}2$. Poest saadud info põhjal teame nüüd, et $P(B|A_4) = 1$. Seega on tõepärasuhteks:

$$\frac{P(A_4|B)}{P(A_4)} = \frac{1}{0{,}2} = 5$$

ehk teadmine et mälupulk on partiist nr 4, suurendab tema rikke tõenäosust 5 korda. Seega $P(B|A_4) = 5 \cdot 0{,}01 = 0{,}05$. Seega on hinnanguliselt 5% 4. partii mälupulkadest rikkega.

*Oletame, et mõne aja pärast on poodi toodud ka teiste partiide rikkega mälupulki, kuid kõigist rikkega mälupulkadest moodustavad 4. partii omad 80%. Veendu, et nüüd tuleb tõepärasuhteks 4 ja ülesande vastuseks* 0,04.

### 2.3.2 Diagnostiliste testide omadused.

Üks väga tuntud Bayesi valemi rakendus on seotud diagnostiliste testidega. Diagnostiliseks testiks nimetatakse testi, mille eesmärgiks on teatud seisundi või omaduse olemasolu tuvastamine. Vaatleme juhtu, kus test saab anda kaks võimalikku tulemust: positiivne või negatiivne. Tuntud testide hulka kuuluvad näiteks rasedustest, testid mis tuvastavad teatud ainete tarvitamist (dopinguained, narkootikumid, alkohol) kui ka testid mis tuvastavad nakatumist mõne viirusega (koroonaviirus, HIV, gripp, ...).

Ideaalne test tuvastab vastava seisundi eksimatult – seega oleks sellise testi puhul üksühene vastavus seisundi olemasolu ja testitulemuse vahel. Ideaalseid teste esineb paraku väga harva ja seetõttu saab testi kasutatavust hinnata omaduste abil, mis on esitatavad tinglike tõenäosustena. Olgu sündmus $S$, et indiviidil on uuritav seisund ja sündmus $T^+$, et diagnostilise testi tulemus on positiivne ja $T^- = \bar{T}^+$, et testitulemus on negatiivne.

Sellise diagnostilise testi võimalikud tulemused saame esitada tabelina (tabel 2.1).

| | **Test** | |
|---|---|---|
| **Seisund:** | **positiivne,** $T^+$ | **negatiivne** $T^-$ |
| **esineb,** $S^+$ | õige positiivne | valenegatiivne |
| **ei esine,** $S^-$ | valepositiivne | õige negatiivne |

Tabel 2.1: Diagnostilise testi võimalikud tulemused.

Diagnostilise testi omadusi iseloomustavad kaks tinglikku tõenäosust, mida nimetatakse testi tundlikkuseks ja testi spetsiifilisuseks.

**Testi tundlikkus** (*ingl. sensitivity*) on tinglik tõenäosus, et uuritava seisundi olemasolul annab test positiivse tulemuse, ehk $P(T^+|S)$.

**Testi spetsiifilisus** (*ingl. specificity*) on tinglik tõenäosus, et uuritava seisundi puudumisel annab test negatiivse tulemuse, ehk $P(T^-|\bar{S})$.

Tundlikkuse ja spetsiifilisuse põhjal saame leida ka valepositiivse ja valenegatiivse tulemuse tõenäosused:

**Testi valenegatiivse tulemuse tõenäosus** on tinglik tõenäosus, et uuritava seisundi olemasolul annab test negatiivse tulemuse, ehk $P(T^-|S) = 1 - P(T^+|S) = 1 -$ tundlikkus.

**Testi valepositiivse tulemuse tõenäosus** on tinglik tõenäosus, et uuritava seisundi puudumisel annab test positiivse tulemuse, ehk $P(T^+|\bar{S}) = 1 - P(T^-|\bar{S}) = 1 -$ spetsiifilisus.

Testi tundlikkus ja spetsiifilisus on testi kõige olulisemad omadused, mis enamasti tehakse kindlaks katseliselt, statistiliste hinnangutena piisavalt suure hulga uuritavate andmetelt. Kõigi meditsiinis kasutatavate testide tundlikkus ja spetsiifilisus on dokumenteeritud ja testi kasutajal on alati võimalik nende näitajatega tutvuda (apteegis müüdavatel koduseks kasutamiseks mõeldud testidel on need näitajad alati trükitud pakendis olevale infolehele).

Testi kasutamisel praktikas ollakse aga olukorras, kus testitava seisundi olemasolu ei ole teada ja testi eesmärk ongi anda hinnang seisundi tõenäosusele. See tõenäosus ei ole aga tundlikkus ega spetsiifilisus, sest nüüd on meil tingimuseks hoopis testitulemus. Täpsemalt, positiivset testitulemust nähes huvitab meid tõenäosus $P(S|T^+)$ ja negatiivse tulemuse korral $P(\bar{S}|T^-)$ (või ka $P(S|T^-)$). Neid tõenäosuseid nimetatakse testi prognoosiväärtusteks.

**Testi positiivne prognoosiväärtus** (*ingl. positive predictive value*) on uuritava seisundi olemasolu tõenäosus tingimusel, et testitulemus on positiivne, ehk $P(S|T^+)$.

**Testi negatiivne prognoosiväärtus** (*ingl. negative predictive value*) on uuritava seisundi puudumise tõenäosus tingimusel, et testitulemus on negatiivne, ehk $P(\bar{S}|T^-)$.

Eespool nägime, et tingliku tõenäosuse "teistpidi pööramiseks" saame kasutada Bayesi valemit. Kui on teada testi tundlikkus ja spetsiifilisus, siis saame positiivse prognoosiväärtuse avaldada Bayesi valemi abil järgmiselt:

$$P(S|T^+) = \frac{P(T^+|S)P(S)}{P(T^+)} = \frac{P(T^+|S)P(S)}{P(T^+|S)P(S) + P(T^+|\bar{S})P(\bar{S})} \tag{2.10}$$

Võrdusest 2.10 näeme, et positiivse prognoosiväärtuse leidmiseks on meil vaja teada ka $P(S)$, mida võib nimetada ka uuritava seisundi **levimuseks** (*ingl. prevalence*), aga mõnes kontekstis ka eeltõenäosuseks. Seega võime selle võrduse kirjutada ka kujul:

$$P(S|T^+) = \frac{P(T^+|S)P(S)}{P(T^+|S)P(S) + [1 - P(T^-|\bar{S})][1 - P(S)]} = \frac{\text{tundlikkus} \cdot \text{levimus}}{\text{tundlikkus} \cdot \text{levimus} + (1 - \text{spetsiifilisus}) \cdot (1 - \text{levimus})}. \tag{2.11}$$

Näeme, et kui tundlikkus ja spetsiifilisus on puhtalt testi omadused, siis positiivne prognoosiväärtus sõltub sellest, kus seda testi kasutatakse – millisel määral esineb vastavat seisundit konkreetses testitavate kogumis.

**Näide 17.** PCR test koroonaviirusega nakatumise tuvastamiseks on väidetavalt tundlikkusega 85% ja spetsiifilisusega umbes 99% (Butler-Laporte, Lawandi jt.). Kui suur on tõenäosus, et positiivse testi saanud inimene on tegelikult nakatunud, kui: a) testi kasutatakse sümptomitega inimestel, kellest hinnanguliselt pooled on koroonaviirusega nakatunud?; b) testi kasutatakse nakatunute lähikontakstetel, kellest hinnanguliselt 10% on nakatunud?; c) testi kasutatakse rutiinsel testimisel inimeste seas, kellest hinnanguliselt 1% on nakatunud?

**Lahendus:**
Näeme, et kolme variandi puhul on muutuvaks parameetriks levimus: juhul a) $P(S) = 0{,}5$; b) $P(S) = 0{,}1$ ja c) $P(S) = 0{,}01$. Asendades antud parameetrid valemisse 2.11, saame:
a)

$$P(S|T^+) = \frac{0{,}85 \cdot 0{,}5}{0{,}85 \cdot 0{,}5 + (1 - 0{,}99) \cdot (1 - 0{,}5)} = 0{,}988;$$

b)

$$P(S|T^+) = \frac{0{,}85 \cdot 0{,}1}{0{,}85 \cdot 0{,}1 + (1 - 0{,}99) \cdot (1 - 0{,}1)} = 0{,}904;$$

c)

$$P(S|T^+) = \frac{0{,}85 \cdot 0{,}01}{0{,}85 \cdot 0{,}01 + (1 - 0{,}99) \cdot (1 - 0{,}01)} = 0{,}462.$$

Seega näeme, et esimesel juhul võib positiivse testitulemuse saanud isiku puhul olla peaaegu kindel, et ta on tõepoolest nakatunud, teisel juhul võib üks positiivne tulemus kümnest olla valepositiivne, kuid kolmandal juhul on kõigist positiivse testitulemuse saanutest vähem kui pooled tegelikult nakatunud.

Eelmise näite mõistmiseks võib kujutada ette andmeid, kus antud tõenäosused kehtivad. Paneme tähele, et positiivne prognoosiväärtus on andmetest hinnatav kui õigete positiivsete testitulemuste arvu ja kõigi positiivsete testitulemuste arvu suhe. Kui testitakse 100 päriselt nakatunud inimest, siis tundlikkuse 0,85 tõttu võime eeldada, et keskmiselt 85 neist saavad positiivse testitulemuse. Kui testitakse 100 mitte-nakatunud isikut, siis spetsiifilisuse 0,99 tõttu saavad neist 99 ka negatiivse testitulemuse, kuid tekib ka üks valepositiivne tulemus. Seega on õigete positiivsete ja kõigi positiivsete testitulemuste suhteks $\frac{85}{86} \approx 0{,}988$, mis ongi positiivse prognoosiväärtuse hinnanguks.

Kui nakatunuid testitakse küll 100, aga mitte-nakatunuid 100 korda rohkem, ehk 10000, siis tekkib ootuspäraselt ka 100 valepositiivset tulemust. Sellisel juhul on valepositiivseid tulemusi rohkem kui õigeid positiivseid tulemusi ja positiivse prognoosiväärtuse hinnang on alla 0,5.

*Vt ka selgitavaid jooniseid ja tabeleid loengukonspektist*

## 2.4 Kokkuvõte

Kokkuvõttes võib öelda, et nii tõenäosuste korrutamise lause, täistõenäosuse valem kui Bayesi valem on ühed oluliseimad valemid, mida läheb vaja pea igaühel, kes peab tegema arvutusi tõenäosustega.

# Peatükk 3

# Juhuslikud suurused ja tõenäosusjaotused

## 3.1 Diskreetne juhuslik suurus, selle jaotus ja jaotuse parameetrid.

### 3.1.1 Diskreetse juhusliku suuruse mõiste.

Juhuslike sündmuste ja nende tõenäosuste leidmisel on tihti otstarbekas kasutada sündmuse arvulist vastet, ehk juhusliku suuruse mõistet. Paljudel juhtudel on see juba otseselt määratud juhusliku katse poolt.

**Näide 1.** Täringut visatakse 10 korda. Kui suur on tõenäosus saada: a) mitte ühtegi „kuut"; b) täpselt üks „kuus"; c) vähemalt kolm „kuut"?

Ühe variandina saame siin defineerida sündmused $A_1, A_2, \ldots, A_{10}$, mis vastavad "kuue" saamisele 1 ,2, ..., 10. katsel. Samas ei huvita meid ükski konkreetne $A_i$, vaid nende toimumiste arv katseseeria jooksul. Selgub, et sellise ülesande juures on otstarbekas tuua sisse muutuja, nt $X$, mis tähistab viskeseeria jooksul saadud kuute arvu. Seega saame otsitavad tõenäosused kirja panna kui $P(X = 0)$, $P(X = 1)$ ja $P(X \geq 3)$. Üldistades seda ülesannet, soovime me teada tõenäosuseid $P(X = x_i)$, kus $x_i$ väärtus võib olla üks arvudest $0, 1, 2, \ldots, 10$.

Eelnevas näites tutvustatud suurus $X$ kannab üldisemalt juhusliku suuruse nimetust.

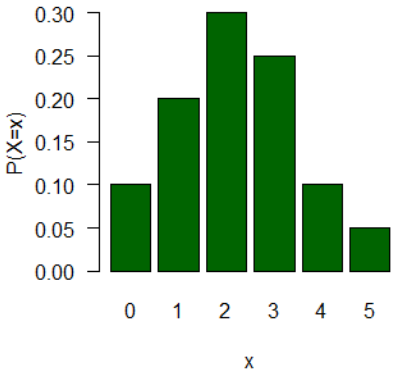
**Juhuslik suurus** *(ingl. random variable)* on muutuja, mille väärtused on määratud juhusliku katse tulemuste poolt (ehk igale võimalikule väärtusele vastab teatud sündmus)

Juhuslikku suurust võib vaadelda kui funktsiooni sündmuste ruumist reaalteljele:

$$X : \Omega \to \mathbb{R}$$

Seega kui sündmusele $A$ vastab juhusliku suuruse $X$ väärtus $x$, siis tõenäosuse $P(A)$ võime esitada kui $P(X = x)$.

**Näide 2.** Olgu $X$ juhuslik suurus, mis tähistab "vappide" arvu kahel mündiviskel. Näeme, et $X$ väärtused saavad olla kas 0, 1 või 2. Tõenäosuste $P(X = 0)$, $P(X = 1)$ ja $P(X = 2)$ leidmiseks võime eeldada, et meil on 4 võrdvõimalikku tulemust: vv, vk, kv, kk.
$P(X = 0) = P(\text{kk}) = 0{,}25$
$P(X = 1) = P(\text{vk või kv}) = 0{,}5$




Joonis 3.1: Näites 4 toodud jaotust kujutav tulpdiagramm.

$P(X = 2) = P(\text{vv}) = 0.25$
Need kolm tõenäosust määravadki juhusliku suuruse $X$ jaotuse ehk selle, kui suure tõenäosusega saavad esineda $X$ erinevad väärtused.

Vaatame nüüd (diskreetse) juhusliku suuruse ja selle jaotuse üldist definitsiooni.

**Diskreetseks juhuslikuks suuruseks** nimetatakse funktsiooni $X : \Omega \to \mathbb{R}$, mille võimalike väärtuste hulk on kas lõplik või loenduv. Tähistame $X$ väärtuseid $x_1$,$x_2$,...,($x_n$) ja tõenäosusi $p_i = P(X = x_i)$.

Diskreetse juhusliku suuruse jaotuseks nimetatakse paaride komplekti $(x_i, p_i), i = 1,2,\ldots$

Paneme tähele, et kõigi võimalike väärtuste tõenäosuste summa on alati 1: $\sum_i p_i = 1$

### 3.1.2 Diskreetse juhusliku suuruse jaotus ja selle esitamine tabelina. Tõenäosuste leidmine jaotustabeli põhjal.

Diskreetse juhusliku suuruse jaotust kujul $(x_i, p_i), i = 1,2,\ldots$ on tihti mugav esitada kas tabelina või arvutusreeglina (viimase variandiga tutvume järgmises peatükis). Vaatleme esmalt jaotuse esitamist tabeli kujul ja selliste jaotustabelite kasutamist.

**Näide 3.** Esitame näites 2 leitud tõenäosused tabelina:

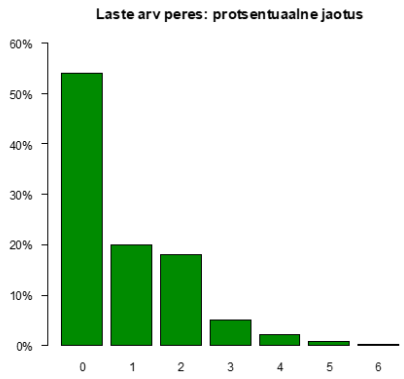
| $x_i$ | 0 | 1 | 2 |
|---|---|---|---|
| $p_i$ | 0,25 | 0,5 | 0,25 |

Tabeli kujul esitatud jaotust võib illustreerida ka tulpdiagrammi abil.

**Näide 4.** Olgu juhuslik suurus $X$, mille jaotus on esitatud järgmise tabelina.

| $x_i$ | 0 | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|---|
| $p_i$ | 0,1 | 0,2 | 0,3 | 0,25 | 0,1 | 0,05 |

Selle juhusliku suuruse jaotust saab illustreerida tulpdiagrammi abil, nagu näha joonisel 3.1.




Joonis 3.2: Näites 5 toodud jaotust (laste arv peres) kujutav tulpdiagramm, kusjuures y-telje skaalana on kasutatud protsenti (0-100%).

**Näide 5.** Oletame, et ühes asulas elavatest peredest on 54% sellised kus alaealisi lapsi pole, 20%-s leibkondadest on üks laps, 18% leibkondadest kaks last, 5% kolm last, 2% neli last, 0.7% peredest on viie lapsega ja 0.3% kuue lapsega (väga sarnane jaotus sellele, mis on Eestis - enam kui 6 lapsega pered praegu välja jäetud, neid on alla 0.1%). Tähistagu $X$ laste arvu selle asula juhuslikult valitud perekonnas. $X$ jaotus on toodud alloleva tabelina. Jaotuse esitamisel võib kasutada ka skaalat $0-100\%$, nagu näha tulpdiagrammil (joonis 3.2).

| $x_i$ | 0 | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|---|
| $p_i$ | 0,54 | 0,2 | 0,18 | 0,05 | 0,02 | 0,007 | 0,003 |

Võime veenduda, et tabelis toodud tõenäosuste summa on 1. Samuti saab siit leida erinevaid tõenäosusi – enam kui pooltes, ehk 54% peredest pole ühtegi last, seega 46%-l peredest on vähemalt üks laps. Samuti võime tõenäosuseid kombineerida – nt leiame, et 1 või 2 lapsega peresid on kõikidest peredest 38% $(0{,}2 + 0{,}18 = 0{,}38)$ ja 4 või enama lapsega peresid on 3% $(0{,}02 + 0{,}007 + 0{,}003)$.

### 3.1.3 Diskreetse juhusliku suuruse keskväärtus.

**Diskreetse juhusliku suuruse keskväärtuseks** (*ingl. expectation, mean*) nimetatakse arvu

$$EX = \sum_i x_i p_i = \sum_i x_i P(X = x_i)$$

**Näide 6.** Vt näidet 5 laste arvu kohta peres:

| $x_i$ | 0 | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|---|
| $P(X = x_i)$ | 0,54 | 0,2 | 0,18 | 0,05 | 0,02 | 0,007 | 0,003 |

Leiame keskväärtuse:
$EX = 0 \cdot 0{,}54 + 1 \cdot 0{,}2 + 2 \cdot 0{,}18 + 3 \cdot 0{,}05 + 4 \cdot 0{,}02 + 5 \cdot 0{,}007 + 6 \cdot 0{,}003 = 0{,}843$
Seega on ühes peres keskmiselt 0,843 last.

Sellest saame järeldada näiteks seda, et kui seal asulas elaks 1000 peret, siis oleks neis peredes kokku $1000 \cdot 0{,}843 = 843$ last. Kui igas peres on 2 täiskasvanut (mis ei vasta küll alati tõele), siis oleks seal asulas kokku $2 \cdot 1000 + 843 = 2843$ inimest.

Näeme, et $EX$ on üksikväärtuste kaalutud keskmine.

**Näide 7.** Oletame, et näites 5 kirjeldatud asula puhul võrreldakse kahte stsenaariumit demograafilise olukorra muutumiseks:

1. Suureneb suurte perede arv, st 4-6 lapsega perede arv kahekordistub, aga selle arvelt väheneb 3-lapseliste perede arv 1% võrra ja 2-lapseliste perede arv 2% võrra
2. Ühe lapsega perede osakaal suureneb 2% võrra (20% asemel 22%), nii kahe kui kolme lapsega perede osakaalud suurenevad 1% võrra (senise 18% ja 5% asemel 19% ja 6%), ning ilma lasteta perede osakaal väheneb 4% võrra.

Kumba stsenaariumi korral suureneks selle asula laste arv rohkem?

**Lahendus:**
Leiame, kui palju muutuks keskmine laste arv ühel või teisel juhul. Algselt leidsime keskväärtuse kui:
$EX = 0 \cdot 0{,}54 + 1 \cdot 0{,}2 + 2 \cdot 0{,}18 + 3 \cdot 0{,}05 + 4 \cdot 0{,}02 + 5 \cdot 0{,}007 + 6 \cdot 0{,}003 = 0{,}843$
Olgu $X_1$ ja $X_2$ juhuslikud suurused, mis vastavad laste arvule vastavalt 1. ja 2. stsenaariumi korral. Leiame, et:
$EX_1 = EX + 4 \cdot 0{,}02 + 5 \cdot 0{,}007 + 6 \cdot 0{,}003 - 3 \cdot 0{,}01 - 2 \cdot 0{,}02 = EX + 0{,}063$ (keskmine kasvaks 0,063 võrra).

$EX_2 = EX + 1 \cdot 0{,}02 + 2 \cdot 0{,}01 + 3 \cdot 0{,}01 = 0{,}843 + 0{,}07 = 0{,}913$ (keskmine kasvaks 0,07 võrra).
Näeme, et 2. variant tooks veidi suurema muutuse, kuid vahe kahe stsenaariumi vahel on väga väike.

### 3.1.4 Keskväärtuse omadused.

**Näide 8.** Mõnikord võib juhuslikku suurust defineerida mitmel moel. Näiteks kui meil on juhuslik suurus $X$, millel on kolm võimalikku väärtust, 1 ,2 ja 3, siis võime defineerida uue juhusliku suuruse $Y$ nii, et $Y = X^2 - 1$. Seega on $Y$ võimalikud väärtused 0, 3 ja 8. Selge on aga, et tõenäosused $P(X = 2)$ ja $P(Y = 3)$ on sama sündmuse tõenäosused ja seega võrdsed: $P(Y = 3) = P(X^2 - 1 = 3) = P(X = 2)$. Seega selles näites $P(Y = y_i) = P(X = x_i) = p_i$, $i$ = 1,2,3 ja ka keskväärtuse leidmisel saame valemis muuta vaid juhusliku suuruse väärtuseid, kuid tõenäosused jäävad samaks.

$$EY = \sum_i y_i p_i = \sum_i (x_i^2 - 1) p_i.$$

Üldisemalt saame selle tulemuse sõnastada teoreemina:

**Teoreem.** Olgu $X$ diskreetne juhuslik suurus ja $g : \mathbb{R} \to \mathbb{R}$ mingi funktsioon. Siis juhusliku suuruse $g(X)$ keskväärtus avaldub kujul:

$$Eg(X) = \sum_i g(x_i) P(X = x_i) = \sum_i g(x_i) p_i \tag{3.1}$$

Seega juhusliku suuruse $Y = g(X)$ keskväärtuse (nt $EX^2$) arvutamiseks pole vaja leida $Y$ jaotust – piisab argumendi $X$ jaotuse teadmisest. Teoreemi tõestus on toodud Kalev Pärna õpukus (lk 62). Lisaks näites 8 toodud olukorrale, kus erinevatele $X$ väärtustele vastavad erinevad $g(X)$ väärtused, kehtib teoreem ka siis, kui üks ja seesama $g(X)$ väärtus võib tekkida erinevate $X$ väärtuste korral.

**Näide 9.** Olgu meil diskreetne juhuslik suurus, mille jaotuse saame esitada järgmise tabelina:

| $x_i$ | -2 | -1 | 0 | 1 | 2 |
|---|---|---|---|---|---|
| $P(X = x_i)$ | 0,1 | 0,2 | 0,2 | 0,4 | 0,1 |

Leiame juhusliku suuruse $X$ ja samuti $X^2$ keskväärtused:

$$EX = (-2)\cdot 0{,}1 + (-1)\cdot 0{,}2 + 0\cdot 0{,}2 + 1\cdot 0{,}4 + 2\cdot 0{,}1 = 0{,}2$$

$$EX^2 = 4\cdot 0{,}1 + 1\cdot 0{,}2 + 0\cdot 0{,}2 + 1\cdot 0{,}4 + 4\cdot 0{,}1 = 1{,}4.$$

Üks sageli kasutatav järeldus sellest teoreemist on **keskväärtuse lineaarsuse omadus**:

$$E(aX+b) = aEX + b, \quad \text{kus} \quad a,b \in \mathbb{R}.$$

Tõestame selle erijuhu kehtivuse:

$$E(aX+b) = \sum_i (ax_i + b)p_i = \sum_i ax_ip_i + \sum_i bp_i = a\sum_i x_ip_i + b\sum_i p_i = aEX + b,$$

sest $\sum_i p_i = 1$ (kõigi võimalike väärtuste tõenäosuste summa) ning $\sum_i x_ip_i = EX$.

Selle omaduse erijuhtudeks on:

$E(X+b) = EX + b$,

$E(aX) = aEX$,

$E(b) = b$.

### 3.1.5 Diskreetse juhusliku suuruse dispersioon ja standardhälve.

Keskväärtus on mõnes mõttes parim *ühe arvuga esitatav* kokkuvõte juhusliku suuruse jaotusest, n-ö jaotuse raskuskese. Siiski ei piisa jaotuse kirjeldamiseks keskväärtusest. Näiteks on sama keskväärtus nii triviaalsel juhuslikul suurusel mis saabki võtta ainult ühte väärtust, näiteks $P(X=0)=1$ (siin $EX=0$) kui juhuslikul suurusel, mis saab võrdse tõenäosusega võtta väärtusi $-10$ ja $10$ ($P(X=-10)=P(X=10)=0{,}5$, kus samuti $EX=0$). Seega võivad juhuslikud suurused üksteisest erineda veel *varieeruvuse* poolest. Varieeruvuse iseloomustamiseks kasutatakse dispersiooni ja standardhälvet.

Juhusliku suuruse $X$ dispersiooniks (*ingl. variance*) nimetatakse arvu

$$DX = E(X-EX)^2. \tag{3.2}$$

Et suurus $(X-EX)^2$ on alati mittenegatiivne, siis on ka $DX$ alati mittenegatiivne. Juhul kui $DX=0$, siis see tähendab, et juhuslikul suurusel puudub varieeruvus, st tegemist on konstandiga.

Dispersiooni saame esitada ka alternatiivsel kujul:

$$\begin{aligned} DX = E(X-EX)^2 &= E[X^2 - 2X\cdot EX + (EX)^2] \\ &= E(X^2) - E(2X\cdot EX) + E[(EX)^2] \\ &= E(X^2) - 2EX\cdot EX + (EX)^2 = E(X^2) - (EX)^2. \end{aligned}$$

Enamasti jäetakse $E(X^2)$ kirjapanekul sulud ära ja seega võib kirja panna dispersiooni alternatiivse valemi kui:

$$DX = EX^2 - (EX)^2. \tag{3.3}$$

(*Pane tähele, et DX asemel kohtame ingliskeelses kirjanduses dispersiooni tähistusena enamasti* $Var(X)$.)

Dispersioon on jaotuse **hajuvuse** mõõt, mis iseloomustab, kui kaugele keskväärtusekst $EX$ võivad jääda üksikud $X$ väärtused.

Dispersiooni arvutamisel saame kasutada eeltoodud teoreemi juhusliku suuruse funktsiooni keskväärtuse kohta:

$$DX = E(X - EX)^2 = \sum_i (x_i - EX)^2 p_i, \tag{3.4}$$

kus $EX = \sum_i x_i p_i$. Võime lähtuda ka valemist 3.3:

$$DX = EX^2 - (EX)^2 = \sum_i x_i^2 p_i - (\sum_i x_i p_i)^2. \tag{3.5}$$

Enamasti (kuid mitte alati!) on lihtsam kasutada arvutamisel valemit 3.3 ja 3.5.

**Näide 10.** Leiame näites 9 toodud juhusliku suuruse $X$ dispersiooni. Paneme tähele, et seal on juba leitud $EX = 0{,}2$ ja $EX^2 = 1{,}4$. Seega saame leida:

$$DX = EX^2 - (EX)^2 = 1{,}4 - 0{,}2^2 = 1{,}36.$$

**Näide 11.** Olgu meil kaks firmat, A ja B. Töötajate protsentuaalne jaotus neis firmades vastavalt nende palkadele on toodud järgmistes tabelites:

Firma A:

| Palk (EUR) | Osakaal töötajatest |
|---|---|
| 1000 | 40% |
| 2500 | 20% |
| 3000 | 20% |
| 5000 | 20% |

Firma B:

| Palk (EUR) | Osakaal töötajatest |
|---|---|
| 500 | 20% |
| 1500 | 20% |
| 2000 | 40% |
| 6000 | 10% |
| 7000 | 10% |

**Lahendus:**
Olgu $X$ ja $Y$ juhuslikud suurused, mis vastavad palgale firmas A ja B, vastavalt, tuhandetes (et oleks lihtsam kirjapilt ja arvutamine). Seega: $EX = 0{,}4{\cdot}1{+}0{,}2{\cdot}2{,}5{+}0{,}2{\cdot}3{+}0{,}2{\cdot}5 = 2{,}5$ ning $EY = 0{,}2{\cdot}0{,}5{+}0{,}2{\cdot}1{,}5{+}0{,}4{\cdot}2{+}0{,}1{\cdot}6{+}0{,}1{\cdot}7 = 2{,}5$. Leiame, et keskmine palk on kahes firmas ühesugun, 2500 eurot. Ometigi näeme, et palkade jaotus neis firmades on erinev. Firmas B on võimalik saada kõrgemat palka kui firmas A, kuid samas on seal võimalik saada ka madalamat palka kui firma A kõige madalam palk.
Leiame palkade dispersiooni kumbagis firmas, kasutades selleks tabeli abi:

Firma A:

| $x_i$ | $p_i$ | $x_i p_i$ | $x_i - EX$ | $(x_i - EX)^2$ | $(x_i - EX)^2 p_i$ |
|---|---|---|---|---|---|
| 1 | 0,4 | 0,4 | -1,5 | 2,25 | 0,9 |
| 2,5 | 0,2 | 0,5 | 0 | 0 | 0 |
| 3 | 0,2 | 0,6 | 0,5 | 0,25 | 0,05 |
| 5 | 0,2 | 1 | 2,5 | 6,25 | 1,25 |
| summa: | 1 | $EX$ =2,5 | | | $DX$ =2,2 |

Firma B:

| $y_i$ | $p_i$ | $y_i p_i$ | $y_i - EY$ | $(y_i - EY)^2$ | $(y_i - EY)^2 p_i$ |
|---|---|---|---|---|---|
| 0,5 | 0,2 | 0,1 | -2 | 4 | 0,8 |
| 1,5 | 0,2 | 0,3 | -1 | 1 | 0,2 |
| 2 | 0,4 | 0,8 | -0,5 | 0,25 | 0,1 |
| 6 | 0,1 | 0,6 | 3,5 | 12,25 | 1,225 |
| 7 | 0,1 | 0,7 | 4,5 | 20,25 | 2,025 |
| summa: | 1 | $EY$ =2,5 | | | $DY$ =4,35 |

Paneme tähele, et alternatiivselt saaks leida dispersiooni $EX^2$ kaudu (tihti lihtsam), näiteks firmas A:

| $x_i$ | $p_i$ | $x_ip_i$ | $x_i^2$ | $p_ix_i^2$ |
|---|---|---|---|---|
| 1 | 0,4 | 0,4 | 1 | 0,4 |
| 2,5 | 0,2 | 0,5 | 6,25 | 1,25 |
| 3 | 0,2 | 0,6 | 9 | 1,8 |
| 5 | 0,2 | 1 | 25 | 5 |
| summa: | 1 | $EX$ =2,5 | | 8,45 |

Nüüd $DX = 8{,}45–2{,}5^2 = 8{,}45–6{,}25 = 2{,}2$ (tuh EUR$^2$).

Firma B palkade dispersioon on suurem kui firmas A – see annab ühe arvu abil edasi sõnumi, et palkade varieeruvus on firmades suurem. Seega võib keskmist koos dispersiooniga nähes öelda, et kuigi keskmiselt on palgad võrdsed, on firmas B suurem tõenäosus saada keskmisest märksa suuremat, aga ka märksa väiksemat palka.

Paneme aga tähele, et dispersiooni ühikuks ei ole näites 11 EUR, vaid EUR$^2$. See teeb dispersiooni raskesti tõlgendatavaks. Tihti on otstarbekas kasutada varieeruvuse iseloomustamiseks ruutjuurt dispersioonist ehk **standardhälvet**.

**Definitsioon** Arvu $\sigma_X = \sqrt{DX}$ nimetatakse juhusliku suuruse $X$ standardhälbeks.

Kui dispersioon mõõdab n-ö *ruutkeskmist kaugust* keskväärtusest $EX$ (ehk keskmist kauguse ruutu), siis standardhälve on lähemal "keskmisele kaugusele keskmisest".

Eelmises näites (11) on firma A palkade standardhälbeks $\sigma_X = \sqrt{2{,}2} \approx 1{,}48$(tuh.EUR) ja firmas B $\sigma_Y = \sqrt{4{,}35} \approx 2{,}09$(tuh.EUR).
Need arvud annavad ettekujutuse, kui palju võib töötajate palk *keskmiselt* erineda keskmisest palgast.

### 3.1.6 Diskreetse juhusliku suuruse dispersiooni omadused.

Nii nagu keskväärtuse korral, pakub ka dispersiooni puhul huvi, kuidas ta muutub kui me rakendame juhuslikule suurusele mõnda funktsiooni. Et dispersiooni leidmine hõlmab ruutu võtmist, siis ei ole juhusliku suuruse funktsiooni dispersiooni leidmine alati lihtne. Erandiks on lihtsad lineaarsed teisendused ehk nn skaalateisendused, kus uus juhuslik suurus leitakse algse juhusliku suuruse korrutamisel mõne konstandiga ja/või talle mõne konstandi liitmisel. Olgu $c$ konstant. Siis kehtivad järgmised omadused:

1. $Dc = 0$
2. $D(X + c) = DX$
3. $D(cX) = c^2DX$

Neid omadusi on lihtne tõestada keskväärtuse omadusi kasutades. Näitame siin vaid viimase omaduse kehtivust. Eelnevalt teame, et juhusliku suuruse $cX$ keskväärtus avaldub kui $cEX = cEX$. Seega:

$$D(cX) = E(cX - cEX)^2 = E[c(X - EX)]^2 = E[c^2(X - EX)^2] = c^2E(X - EX)^2 = c^2DX.$$

Näiteks kui juhuslikku suurust $X$ suurendada 2 korda, nt defineerides uue juhusliku suuruse kui $Y = 2X$, siis $EY = 2EX$, aga $DY = 4DX$. Seega dispersioon suureneb 4 korda. Paneme aga tähele, et standardhälve suureneb ka kaks korda: $\sigma_Y = \sqrt{DY} = \sqrt{4DX} = 2\sqrt{DX} = 2\sigma_X$.

**Näide 12.** Leiame näites 9 toodud juhusliku suuruse $X$ puhul ka juhusliku suuruse $Y = 20 - 10X$ keskväärtuse ja dispersiooni.

**Lahendus:**
Eelnevalt leidsime, et: $EX = 0{,}2$ ning (näites 10) ka, et $DX = 1{,}36$. Seega:

$$EY = E(20 - 10X) = 20 - 10 \cdot 0{,}2 = 18.$$

Dispersiooni leidmiseks rakendame omadusi 2 ja 3:

$$DY = D(20 - 10X) = D(-10X) = 100DX = 100 \cdot 1{,}36 = 136.$$

Seega polnud meil siin vaja uue juhusliku suuruse jaotustabelit moodustada ega kogu $EX$ ja $DX$ arvutuskäiku läbi teha.

Paneme tähele, et kui $E(cX) = cEX$ ja $E(-cX) = -cEX$, siis $D(cX) = D(-cX) = c^2DX$.

## 3.2 Kaks juhuslikku suurust ja nende summa.

Väga tihti saame defineerida juhuslikke suuruseid mitme teise juhusliku suuruse abil. Kõige tavalisem on juhuslike suuruste liitmine. Seetõttu on kasulik teada, kuidas saab leida nii tekkinud juhuslike suuruste keskväärtust ja dispersiooni.

### 3.2.1 Summa keskväärtus.

**Lemma** Olgu $X$ ja $Y$ diskreetsed juhuslikud suurused. Kui eksisteerivad (on lõplikud) keskväärtused $EX$ ja $EY$, siis kehtib seos:

$$E(X + Y) = EX + EY$$

**Keskväärtuse lineaarsuse omadus.** Konstantide $a,b \in \mathbb{R}$ korral kehtib:

$$E(aX + bY) = aEX + bEY$$

Üldisem variant:

$$E\sum_{i=1}^{n}(c_iX_i) = \sum_{i=1}^{n} c_iE(X_i),\ c_i \in \mathbb{R}$$

(Tõestus K.Pärna õpikus lk 66)

**Näide 13.** Ühes urnis on 1 valge ja 3 musta kuuli, teises urnis on 3 valget ja 2 musta kuuli. Kummastki urnist võetakse välja kaks kuuli. Milline on kokku saadud valgete kuulide arvu keskväärtus?

**Lahendus:**
Olgu $X_1$ esimest urnist saadud valgete kuulide arv ja $X_2$ teisest urnist saadud valgete kuulide arv ning olgu $Y = X_1 + X_2$. Koostame esmalt $X_1$ ja $X_2$ jaotustabelid ja leiame nende keskväärtused.

$X_1$:

| $x_{1i}$ | 0 | 1 |
|---|---|---|
| $p_i$ | $\frac{1}{2}$ | $\frac{1}{2}$ |

, $X_2$:

| $x_{2i}$ | 0 | 1 | 2 |
|---|---|---|---|
| $p_i$ | $\frac{1}{10}$ | $\frac{6}{10}$ | $\frac{3}{10}$ |

Leiame, et $EX_1 = \frac{1}{2} = 0{,}5$ ning $EX_2 = \frac{6}{10} + 2 \cdot \frac{3}{10} = \frac{12}{10} = 1{,}2$.

Seega $EY = EX_1 + EX_2 = 0{,}5 + 1{,}2 = 1{,}7$.

Nägime, et $Y$ keskväärtuse leidmiseks ei olnud vaja koostada $Y$ jaotustabelit.

### 3.2.2 Sõltumatud diskreetsed juhuslikud suurused.

**Definitsioon** Diskreetseid juhuslikke suurusi $X$ ja $Y$ nimetatakse sõltumatuteks, kui iga $i$ ja $j$ korral sündmused $(X = x_i)$ ja $(Y = y_j)$ on sõltumatud, s.t

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$$

Juhuslike suuruste sõltumatus tuleneb sageli sõltumatutest katsetest – nt kahe täringu viskamine, kus $X$ ja $Y$ on silmade arvud kummagil täringul

**Lemma. Korrutise keskväärtus.** Kui $X$ ja $Y$ on sõltumatud juhuslikud suurused, siis:

$$E(XY) = EX \cdot EY \tag{3.6}$$

Tõestame selle lemma. Sõltumatuse tõttu saame juhusliku suuruse $XY$ keskväärtuse kirjutada kui:

$$\begin{aligned} E(XY) = \sum_i \sum_j x_i y_j P(X = x_i, Y = y_j) &= \sum_i \sum_j x_i y_j P(X = x_i) P(Y = y_j) \\ &= \sum_i x_i P(X = x_i) \sum_j y_j P(Y = y_j) = EX \cdot EY. \end{aligned}$$

(Kahe juhusliku suuruse ühisjaotusest $P(X = x_i, Y = y_j)$ ning juhuslike suuruste omavahelise seose kirjeldamisest tuleb rohkem juttu hiljem)

### 3.2.3 Summa dispersioon.

Olgu sõltumatud juhuslikud suurused $X$ ja $Y$. Leiame, millega võrdub nende summa dispersioon.

$$\begin{aligned} D(X+Y) = E(X+Y)^2 - [E(X+Y)]^2 &= E(X^2 + 2XY + Y^2) - (EX + EY)^2 \\ &= EX^2 + 2E(XY) + EY^2 - (EX)^2 - 2EX \cdot EY - (EY)^2 \\ &= DX + DY + 2EXY - 2EX \cdot EY. \end{aligned}$$

Et aga eelnevalt nägime, et sõltumatute juhuslike suuruste korral $E(XY) = EX \cdot EY$, siis saame, et kui juhuslikud suurused on sõltumatud, siis nende summa dispersioon avaldub kui dispersioonide summa:

$$D(X + Y) = DX + DY.$$

Samuti saame leida:

$$D(aX + bY) = a^2 DX + b^2 DY, \text{ kus } a,b \in \mathbb{R}$$

Siit järeldub, et sõltumatute juhuslike suuruste vahe dispersioon avaldub kui:

$$D(X - Y) = D[X + (-1) \cdot Y] = DX + DY \quad \text{ja} \quad D(aX - bY) = a^2 DX + b^2 DY.$$

Sõltumatute juhuslike suuruste summa standardhälve avaldub kui:

$$\sigma_{aX+bY} = \sqrt{a^2 DX + b^2 DY} = \sqrt{a^2 \sigma_X^2 + b^2 \sigma_Y^2} \neq a\sigma_X + b\sigma_Y$$

Pane tähele, et seda ei saa avaldada standardhälvete summana.

**Näide 14.** Ausat täringut visatakse kaks korda. Olgu $Y$ saadud silmade summa kahel täringul ja olgu $Z$ saadud silmade vahe. Leiame $Y$ ja $Z$ keskväärtuse ja dispersiooni.

**Lahendus:**
Olgu $X$ silmade arv ühel täringul. Leiame esmalt $X$ keskväärtuse ja dispersiooni. $X$ jaotuse saame esitada järgmisel kujul:

| $x_i$ | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| $p_i$ | $\frac{1}{6}$ | $\frac{1}{6}$ | $\frac{1}{6}$ | $\frac{1}{6}$ | $\frac{1}{6}$ | $\frac{1}{6}$ |

Nüüd $EX = \frac{1}{6}(1+2+3+4+5+6) = \frac{7}{2}$. Leiame samuti: $EX^2 = \frac{1}{6}(1^2+2^2+3^2+4^2+5^2+6^2) = \frac{91}{6}$.

Seega $DX = EX^2 - (EX)^2 = \frac{91}{6} - \left(\frac{7}{2}\right)^2 = \frac{35}{12} \approx 2{,}92$.

Olgu $X_1$ ja $X_2$ silmade arvud esimesel ja teisel täringul. Et $Y = X_1 + X_2$, siis

$$EY = EX_1 + EX_2 = 3{,}5 + 3{,}5 = 7 \quad \text{ja} \quad DY = DX_1 + DX_2 = 2 \cdot \frac{35}{12} \approx 5{,}83.$$

Juhusliku suuruse $Z = X_1 - X_2$ korral aga:

$$EZ = EX_1 - EX_2 = 3{,}5 - 3{,}5 = 0 \quad \text{ja} \quad DZ = DX_1 + DX_2 = 2 \cdot \frac{35}{12} \approx 5{,}83.$$

Seega on $Y$ ja $Z$ keskväärtused erinevad, aga dispersioonid samad. Saamaks sellest paremini aru, võib koostada $Y$ ja $Z$ jaotustabelid:

| $y_i$ | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| $P(Y=y_i)$ | $\frac{1}{36}$ | $\frac{2}{36}$ | $\frac{3}{36}$ | $\frac{4}{36}$ | $\frac{5}{36}$ | $\frac{6}{36}$ | $\frac{5}{36}$ | $\frac{4}{36}$ | $\frac{3}{36}$ | $\frac{2}{36}$ | $\frac{1}{36}$ |

ja

| $z_i$ | -5 | -4 | -3 | -2 | -1 | 0 | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| $P(Z=z_i)$ | $\frac{1}{36}$ | $\frac{2}{36}$ | $\frac{3}{36}$ | $\frac{4}{36}$ | $\frac{5}{36}$ | $\frac{6}{36}$ | $\frac{5}{36}$ | $\frac{4}{36}$ | $\frac{3}{36}$ | $\frac{2}{36}$ | $\frac{1}{36}$ |

Näeme, et kuigi juhuslike suuruste $Y$ ja $Z$ väärtuste skaalad on erinevad, on nende jaotused muidu ühesugused. Keskväärtuste erinevus viitabki erinevale skaalale, dispersioonide erinevus aga erinevale varieeruvusele.

## 3.3 Levinumad diskreetsed jaotused

### 3.3.1 Jaotuse esitamine tõenäosusfunktsiooni abil.

Diskreetse juhusliku suuruse jaotuse, ehk paaride komplekti $(x_i,p_i)$ esitamiseks on erinevaid võimalusi:

- Kui $X$ väärtuste arv on lõplik ja mitte väga suur, saab jaotuse esitada tabelina, kus on esimeses reas (või ka veerus) $X$ väärtused $x_i$ ja teises reas (või veerus) vastavad tõenäosused $p_i$.
- Teine võimalus jaotuse esitamiseks on tõenäosusfunktsiooni kaudu, kus tõenäosus $P(X = x)$ avaldub $x$ funktsioonina (vahel tähistatakse ka kui $f(x)$).

**Näide 15.** Olgu juhusliku suuruse $X$ jaotus esitatav tabelina:

| $x_i$ | 0 | 1 | 2 | 3 |
|---|---|---|---|---|
| $p_i$ | 0,4 | 0,3 | 0,2 | 0,1 |

Alternatiivselt saame sama jaotuse esitada kui:

$$P(X = x) = f(x) = 0{,}1(4 - x), \quad \text{kus } x \in \{0; 1; 2; 3\}$$

Paneme tähele, et: $\sum_{x=1}^{4} f(x) = 1$.

### 3.3.2 Bernoulli jaotus

Bernoulli jaotus on kõige lihtsama diskreetse juhusliku suuruse jaotus, mille abil saab kirjeldada olukorda, kus huvi pakub ainult ühe sündmuse $A$ toimumine ning juhusliku suuruse väärtuseks on 1, kui $A$ toimub ja 0 muidu:

$$X = \begin{cases} 1, & \text{kui } A \text{ toimub} \\ 0, & \text{kui } A \text{ ei toimu, ehk toimub } \bar{A}. \end{cases}$$

**Definitsioon.** Öeldakse, et juhuslik suurus $X$ on Bernoulli jaotusega ja tähistame $X \sim Be(p)$, kui tema võimalikud väärtused on 0 või 1, ning $p = P(X = 1)$.

Tõenäosust $p$ nimetatakse Bernoulli jaotuse parameetriks.

Seega Bernoulli jaotuse parameeter avaldub kui $p = P(X = 1) = P(A)$. See üks parameeter määrab terve jaotuse, sest $P(X = 0) = P(\bar{A}) = 1 - p$.

Bernoulli jaotuse keskväärtus avaldub kui: $EX = 0 \cdot (1 - p) + 1 \cdot p = p$.

Paneme tähele, et kuna $X$ väärtuseks on kas 0 või 1, siis $X^2 = X$, ja seega ka $EX^2 = EX = p$.

Seetõttu avaldub Bernoulli jaotuse dispersioon kui: $DX = EX^2 - (EX)^2 = 0^2 \cdot (1-p) + 1^2 \cdot p - p^2 = p - p^2 = p(1-p)$

**Näide 16.** Olgu juhusliku suuruse $X$ väärtuseks väärtuseks 1, kui täringul tuleb 6 silma ja 0 muidu:

$$X = \begin{cases} 1, & \text{kui tulemuseks on 6 silma} \\ 0, & \text{muidu.} \end{cases}$$

Siin $X$ on Bernoulli jaotusega, parameetriga $p = \frac{1}{6}$, ehk võime kirjutada, et $X \sim Be(\frac{1}{6})$.
Seega $EX = p = \frac{1}{6}$ ning $\quad DX = p(1 - p) = \frac{1}{6} \cdot \frac{5}{6} = \frac{5}{36}$.

Paneme tähele, et konkreetset Bernoulli jaotust iseloomustab parameetri $p$ väärtus. Muutes $p$ väärtust, saame erinevad Bernoulli jaotused.

Bernoulli jaotuse tõenäosusfunktsiooni võime alternatiivsel kujul kirja panna ka kui:

$$P(X = k) = f(k; p) = p^k (1 - p)^{1-k}, \quad \text{kus } k \in \{0; 1\}.$$

### 3.3.3 Binoomjaotus

Järgnevalt vaatleme olukordi, kus toimub $n$ sõltumatut katset, mille tulemusena toimub kas mingi sündmus $A$ või selle vastandsündmus $\bar{A}$. Hvipakkuv juhuslik suurus $X$ on sündmuse $A$ toimumiste arv $n$ katses.

Nii näiteks võib meid huvitada tõenäosus, et 10 korda täringut visates saadakse täpselt kolm "kuut´´, aga ka tõenäosus, et 20 juhuslikult valitud tudengi küsitlemisel leitakse vähemalt 5 ühiselamus elavat tudengit. Sellistes näidetes saab huvipakkuva tõenäosuse leida binoomjaotust kasutades.

**Näide 17.** Leiame tõenäosuse, et 10 korda täringut visates tuleb kolm "kuut".

**Lahendus:**
Defineerime juhusliku suuruse $X$ kui "kuute" arv 10 täringuviske korral.
Olgu sündmus $A$, et *ühel* täringuviskel tuleb 6 silma. Sündmus $\bar{A}$ on siis järelikult sündmus, et tuleb $1 \dots 5$ silma.
Teame, et $P(A) = p = \frac{1}{6}$ ning $P(\bar{A}) = 1 - p = \frac{5}{6}$.
Tegemist on 10 sõltumatu juhusliku katsega, kus iga kord saab toimuda kas $A$ või $\bar{A}$.
Tõenäosus, et esimesel kolmel viskel tuleb 6 ja järgmisel 7 viskel $1 \dots 5$ on seega (sõltumatuse tõttu!):

$$p \cdot p \cdot p \cdot \underbrace{(1-p) \cdot (1-p) \dots \cdot (1-p)}_{\text{7 korda}} = p^3(1-p)^7$$

Kolm "kuut" võivad tulemustejadas esineda ükskõik millisel kohal – kokku on selleks erinevaid võimalusi $C_{10}^3$. Seega on otsitav tõenäosus:

$$P(X = 3) = C_{10}^3 \left(\frac{1}{6}\right)^3 \left(\frac{5}{6}\right)^7.$$

Sarnaselt toodud näitele leiame nüüd üldise valemi, mis annab tõenäosuse, et $n$ sõltumatu juhusliku katse korral esineb sündmus $A$ täpselt $k$ korda.

Olgu $X$ juhuslik suurus, mis tähistab sündmuse $A$ toimumiste arvu $n$ katse korral. Otsitav tõenäosus on $P(X = k)$, kus $k \in 0, 1, \dots, n$.
Olgu $p = P(A)$ tõenäosus, et sündmus $A$ toimub ühe katse korral.
Et katsed on sõltumatud, siis tõenäosus et sündmus $A$ toimub $k$ korda, on $p^k$. Kõigil ülejäänud kordadel, ehk $n - k$ korral peab toimuma sündmus $\bar{A}$: selle tõenäosus on $(1-p)^{n-k}$.
Võimalike sündmuste $A$ ja $\bar{A}$ järjestusi kus $A$ toimub $k$ korda ja $\bar{A}$ toimub $n - k$ korda, on $C_n^k$. (Sellest võib mõelda ka nii, et kui meil on 10 järjekorranumbrit $1, \dots, 10$, siis küsime, kui palju on erinevaid võimalusi neist $k$ numbri väljavalimiseks – need on siis katsete järjekorranumbrid, kus toimub sündmus $A$.) Erinevad järjestused on üksteist välistavad, kusjuures iga konkreetse järjestuse tõenäosus on $p^k(1-p)^{n-k}$ . Seega on otsitav tõenäosus:

$$P(X = k) = C_n^k p^k (1-p)^{n-k}.$$

Seda valemit nimetatakse Bernoulli valemiks (ehk bionoomjaotuse tõenäosusfunktsiooniks).

**Definitsioon.** juhuslik suurus $X$ on binoomjaotusega, $X \sim B(n,p)$, kui ta on mingi sündmuste $A$ toimumiste arv $n$ sõltumatus katses, kus igal üksikkatsel $P(A) = p$

Binoomjaotuse parameetriteks on $n$ ja $p$.

Tähistame juhusliku suuruse $X$ võimalikud väärtused $k$-ga, kus $k = 0, 1, 2, \dots, n$.

Binoomjaotuse tõenäosusfunktsioon:

$$P(X = k) = C_n^k p^k (1-p)^{n-k}$$

(Bernoulli valem!)

Järgnevalt leiame binoomjaotuse keskväärtuse ja dispersiooni. Selleks paneme tähele, et binoomjaotusega juhuslikku suurust $X \sim B(n,p)$ saab vaadelda kui juhuslike suuruste $X_i$ summat:

$$X = X_1 + X_2 + \dots + X_n,$$

kus $X_i = 1$, kui $i$-ndal katsel toimus huvipakkuv sündmus $A$ ($i$-ndal täringuviskel tuli 6, $i$-s patsient sai ravimist abi, ...) ja $X_i = 0$ kui seda sündmust ei toimunud (st toimus vastandsündmus $\bar{A}$).

Näeme, et $X_i$ on sõltumatud Bernoulli jaotusega juhuslikud suurused, $X_i \sim Be(p)$. Teame, et $E(X_i) = p$

Seetõttu saame avaldada $X$ keskväärtuse kui:

$$E(X) = E(X_1 + X_2 + \ldots + X_n) = E(X_1) + E(X_2) + \ldots + E(X_n) = np$$

Et $X$ on sõltumatute komponentide summa, ning iga komponendi $X_i$ dispersioon on $D(X_i) = p(1-p)$, siis avaldub ka dispersioon liidetavate dispersioonide summana kui:

$$D(X) = D(X_1) + D(X_2) + \ldots + D(X_n) = np(1-p)$$

Kokkuvõttes nägime, et binoomjaotusega juhusliku suuruse keskväärtus ja dispersioon avalduvad kui:

$$\begin{aligned} EX &= np \\ DX &= np(1-p) \end{aligned}$$

Lisaks saab näidata, et binoomjaotusega juhusliku suuruse kõige tõenäolisem väärtus (ehk mood) on võrdne suuruse $(n+1)p$ täisosaga. Kui $(n+1)p$ on täisarv, siis esinevad väärtused $(n+1)p$ ja $(n+1)p-1$ võrdse (kõige suurema) tõenäosusega.

**Näide 18.** Näites 17 on $n = 10$ ja $p = \frac{1}{6}$. Seega $(n+1)p = \frac{11}{6}$, mille täisosaks on 1. Seetõttu on täringu viskamisel 10 korda kõige tõenäolisem "kuute" arv 1 (võid soovi korral veenduda, et tõenäosus saada 10 viske korral täpselt üks "kuus" on ligikaudu 0,323). Kui täringut visataks aga 11 korda, siis võib võrdse tõenäosusega tulla nii $(n+1)p = \frac{12}{6} = 2$ kui $(n+1)p - 1 = 1$ "kuut" (mõlema tulemuse tõenäosus on ligikaudu 0,296).

**Näide 19.** Oletame, et üks pood on otsustanud kampaania korras teha kingituse 20%-le ostjatest, kusjuures kingisaajad valitakse juhuslikult loosimise teel. Poe omanik avastab, et müüja on teinud kingituse 20-st esimest kliendist seitsmele, ja talle tundub et seda on liiga palju. Ta kahtlustab müüjat pettuses (jagas tuttavatele kingitusi?). Kuidas hinnata, kas müüja pettis või mitte?

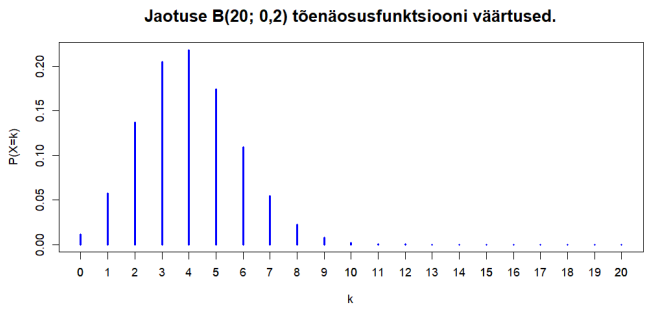
**Lahendus:**
Ausa loosimise korral on kingisaajate hulk 20 kliendi seas on binoomjaotusega, parameetritega 20 ja 0,2. Olgu $X$ kingisaajate arv 20 kliendi seas. Binoomjaotuse tõenäosusfunktsiooni abil on võimalik leida $X$ jaotus ehk tõenäosused $P(X = k)$:

$$P(X = k) = C_{20}^{k} 0{,}2^k 0{,}8^{n-k}, \quad k \in 0{,}1, \ldots, 20.$$

Neid tõenäosuseid saab leida ka tarkvara või veebikalkulaatorite abil. Näiteks tarkvara R võimaldab neid leida funktsiooni `dbinom()` abil. Tulemused on toodud joonisel 3.3.
Hindame tõenäosust, et kingituse saab 7 või rohkem klienti, ehk $P(X \geq 7)$. Veidi lihtsam on leida tõenäosust $P(X \leq 6) = P(X = 0) + P(X = 1) + \ldots + P(X = 6) \approx 0{,}913$ (leitud R funktsiooni `pbinom` abil, mis võimaldab leida tõenäosuseid $P(X \leq k)$.) Seega leiame, et:

$$P(X \geq 7) = 1 - P(X \leq 6) \approx 1 - 0{,}913 = 0{,}087.$$

See tõenäosus (8,7%) ei ole nii väga väike, et müüjat pettuses süüdistada saaks – andmed ei ole vastuolus väitega, et loosimine toimus ausalt.
*Hiljem näeme, et sarnast arutluskäiku kasutatakse ka statistilise testimise juures.*




Joonis 3.3: Binoomjaotuse $B(20; 0{,}2)$ tõenäosusfunktsiooni väärtused (näide 19).

### 3.3.4 Geomeetriline jaotus

**Näide 20.** Täringut visatakse niikaua, kuni saadakse esimest korda 6 silma. Mis on tõenäosus, et selleks kulub täpselt 3 viset?

Seega küsime, mis on tõenäosus, et kolmest viskest kahel esimesel korral tuleb vähem kui 6 silma ja kolmandal korral täpselt 6 silma. Kui $A_i$ on sündmus, et $i$-ndal katsel tuleb 6 silma, ja $X$ on 6 silma saamiseks kuluvate katsete arv, siis saame, et:

$$P(X = 3) = P(\bar{A}_1 \cap \bar{A}_2 \cap A_3) = \frac{5}{6} \cdot \frac{5}{6} \cdot \frac{1}{6} \approx 0{,}12$$

(sõltumatud sündmused!)

**Definitsioon (geomeetriline jaotus).** Diskreetne juhuslik suurus $X$ on geomeetrilise jaotusega parameetriga $p$, $X \sim \text{Geom}(p)$, kui $X$ võimalikud väärtused on 1, 2, 3, ... ning

$$P(X = k) = (1 - p)^{k-1} p$$

Geomeetrilist jaotusega saab kirjeldada juhuslikku suurust, mis on defineeritud kui sõltumatute katsete arv kuni mingi sündmuste $A$ toimumiseni, kus igal üksikkatsel $P(A) = p$. Seega sellel jaotusel on ainult üks parameeter, $p$. Näeme, et geomeetrilise jaotusega juhusliku suuruse väärtuseks ei saa kunagi olla 0, vaid tema minimaalne väärtus on 1. Paneme ka tähele, et teoreetiliselt võib geomeetrilise jaotusega juhuslikul suurtusel olla lõpmatult palju väärtuseid – arvul $k$ puudub selge maksimum. Kuidas me saame kindlad olla, et juhusliku suuruse kõigi väärtuste tõenäosuste summa on 1? Selleks saame kasutada geomeetrilise jaga summa valemit:

$$\sum_{s=0}^{\infty} ar^s = a + ar + ar^2 + ar^3 + \ldots = \frac{a}{1 - r}, \quad \text{kui} \quad |r| < 1$$

Nüüd, võttes $s = k - 1$, saame leida, et:

$$\sum_{k=1}^{\infty} (1 - p)^{k-1} p = \sum_{s=0}^{\infty} (1 - p)^s p = \frac{p}{1 - (1 - p)} = 1.$$

(Võrreldes geomeetrilise jada valemiga on $a$ $p$ ja $r$ rollis $1 - p$.) Seega on tõepoolest ka see lõpmatu arvu liidetavatega summa võrdne 1-ga.
Järgnevalt leiame geomeetrilise jada keskväärtuse. Lähtume keskväärtuse definitsioonist ja seega:

$$EX = \sum_{k=1}^{\infty} k(1 - p)^{k-1} p = \sum_{k=0}^{\infty} k(1 - p)^{k-1} p.$$

(Summa esimene komponent $k = 0$ korral võrdub 0-ga, seega pole vahet kas alustada summat $k$ väärtusest 0 või 1.) Siin ei saa geomeetrilist progressiooni otse kasutada, kuid me jõuame keskväärtuseni väikese "trikiga". Olgu $q = 1 - p$ ja seega $EX = \sum_{k=0}^{\infty} kq^{k-1}p$. Leiame, millega võrdub $EX - qEX$:

$$\begin{aligned} EX - qEX &= \sum_{k=0}^{\infty} kq^{k-1}p - q\sum_{k=0}^{\infty} kq^{k-1}p \\ &= (p + 2qp + 3q^2p + 4q^3p + \ldots) - (qp + 2q^2p + 3q^3p + 4q^4p + \ldots) \\ &= p + qp + q^2p + \ldots = 1 \end{aligned}$$

Seega: $EX(1 - q) = EXp = 1$ ehk ja geomeetrilise jaotusega juhusliku suuruse keskväärtus avaldub kui:

$$EX = \frac{1}{p}.$$

Saab ka näidata, et geomeetrilise jaotuse korral avaldub juhusliku suuruse dispersioon kui:

$$DX = \frac{1 - p}{p^2}.$$

Tõestus on veidi pikem ja seetõttu me seda siin ei näita. Paneme tähele, et geomeetrilise jaotuse korral kehtib iga $k \geq 1$ korral: $P(X = k + 1) = (1 - p)P(X = k) < P(X = k)$ ehk $k$ suurenedes jäävad vastavad tõenäosused järjest väiksemaks. Seega on selle jaotuse mood alati 1.

### 3.3.5 Negatiivne binoomjaotus

**Näide 21.** Täringut visatakse kuni saadakse kolm "kuut". Kui suur on tõenäosus, et soovitud tulemus saavutatakse täpselt 10 viskega?

**Lahendus:**
Kui täringut visatakse kolme "kuue" saamiseni, siis saadud "kuute" arv on fikseeritud, aga juhuslik on 6-st erinevate tulemuste arv. Seega on loogiline defineerida juhuslik suurus $X$, kui tulemusega $1 \ldots 5$ tehtud täringuvisete arv kuni kolme 6 saamiseni. Niisiis on meil vaja leida tõenäosus $P(X = 7)$.
Paneme tähele, et kui antud olukorras $X = 7$, siis see tähendab, et on sooritatud visete jada, kus viimaseks tulemuseks on 6, ja sellele eelneb 9 tulemust, mille seas on täpselt kaks "kuut" ja 7 kuuest erinevat tulemust. Sellise tulemuste jada tõenäosuse saame leida Bernoulli valemi järgi, kus ühe fikseeritud järjestusega jada tõenäosuseks on $p^2(1 - p)^7$, kus $p$ on ühel viskel "kuue" tõenäosus (teame, et $p = \frac{1}{6}$). Kõigi võimalikke sobivate järjestuste arv on $C_9^2$. Et viimane tulemus peab kindlasti olema 6, leiame otsitava tõenäosuse kui:

$$P(X = 7) = C_9^2 \cdot p^2(1 - p)^7 \cdot p = C_9^2 p^3(1 - p)^7 = C_9^2 \left(\frac{1}{6}\right)^3 \left(\frac{5}{6}\right)^7 = 36 \cdot \frac{5^7}{6^{10}} \approx 0{,}047.$$

Seega leidsime, et tõenäosus saada 10 viskega täpselt 3 "kuut" on veidi alla 5%.

Üldisemal juhul saame seega näidata, et kui üksikkatse puhul on soovitud tulemuse, ehk sündmuse $A$ tõenäosuseks $p$, siis tõenäosus, et $A$ toimumiseks $m$ korda toimub vastandsündmus $\bar{A}$ $k$ korda, on:

$$P(X = k) = C_{k+m-1}^{m-1} p^m (1 - p)^k$$

Sellisel moel defineeritud juhuslik suurus $X$ on negatiivse binoomjaotusega: $X \sim NB(m,p)$. Siin katseseeria kogupikkus on $n = m + X$, kus $m$ on fikseeritud ning $X$ juhuslik.

**Näide 22.** Vaatleme veelkord näite 21 olukorda, kus täringut visatakse kuni saadakse kolm "kuut". Küsime aga nüüd, kui palju peab keskmiselt täringut viskama kolme "kuue" saamiseni?

**Lahendus:**
Paneme tähele, et viskeseeria pikkus on kolme geomeetrilise jaotusega juhusliku suuruse summa, ehk $X+3 = X_1+X_2+X_3$, millest $X = X_1+X_2+X_3-3$, kus $X_i \sim Geom(p)$. Siit näeme, et $EX = 3EX_i-3 = \frac{3}{p}-3 = 3\cdot 6-3 = 15$. Seega on kolme "kuue" saamiseks vaja visata täringut keskmiselt $15+3 = 18$ korda.

Üldise negatiivse binoomjaotusega juhusliku suuruse $X$ puhul kehtib seega, et $X = \sum_{i=1}^{m} X_i - m$, kus $X_i \sim Geom(p)$.

Seega avaldub negatiivse binoomjaotusega juhusliku suuruse $X$ keskväärtus kui:

$$EX = \frac{m}{p} - m = \frac{(1-p)m}{p}.$$

Et $X_i$ on sõltumatud, siis avaldub negatiivse binoomjaotusega juhusliku suuruse $X$ dispersioon kui:

$$DX = D(\sum_{i=1}^{m} X_i - m) = D(\sum_{i=1}^{m} X_i) = \frac{(1-p)m}{p^2}.$$

Paneme tähele, et kui $m = 1$, siis juhuslik suurus $Y = X+1$ on geomeetrilise jaotusega ehk $Y \sim Geom(p)$. Seega on geomeetriline jaotus negatiivse binoomjaotuse erijuht.

### 3.3.6 Hüpergeomeetriline jaotus

**Näide 23.** : Korvis on 5 kollast ja 15 punast õuna. Korvist võetakse juhuslikult välja 5 õuna. Kui suur on tõenäosus, et täpselt kaks neist on kollased?

**Lahendus:**
Kokku on $C_{20}^5$ võimalust 5 õuna väljavõtmiseks. Võimalusi 5 kollasest õunast 2 väljavõtmiseks on $C_5^2$ ja võimalusi 15 punasest õunast 3 väljavõtmiseks $C_{15}^3$. Seega on otsitav tõenäosus:

$$P(X=2) = \frac{C_5^2 \cdot C_{15}^3}{C_{20}^5} \approx 0{,}29.$$

Sarnaselt eeltoodud näitele saame defineerida üldise jaotuse juhuslikule suurusele mis vastab teatud tüüpi objektide arvule tagasipanekuta valiku korral.

**Definitsioon (hüpergeomeetriline jaotus).** Olgu meil hulk suurusega $N$, kus on kahte tüüpi elemente, kusjuures $K$ elementi on esimest ja $N-K$ teist tüüpi. Kui sellest hulgast võetakse tagasipanekuta $n$-elemendiline juhuslik alamhulk, siis juhuslik suurus $X$, mille väärtuseks on esimest tüüpi elementide selles alamhulgas on hüpergeomeetrilise jaotusega, parameetritega $N$, $K$ ja $n$, ning $X$ jaotus on esitatud kui:

$$P(X=k) = \frac{C_K^k \cdot C_{N-K}^{n-k}}{C_N^n}, \quad \text{kus } k = 0,1,2,\ldots,n.$$

Hüpergeomeetrilist haotust tähistatakse kui: $X \sim H(N,K,n)$.
Kui $X$ on hüpergeomeetrilise jaotusega, siis tema keskväärtus ja dispersioon avalduvad kui:

$$\begin{aligned} EX &= n\frac{K}{N} \\ DX &= n\frac{K(N-K)(N-n)}{N^2(N-1)} \end{aligned}$$

Lisaks on võimalik näidata, et kõige tõenäolisem väärtus ehk mood on hüpergoemeetrilise jaotuse korral:

$$\lceil \frac{(n+1)(K+1)}{N+2} \rceil - 1 \quad \text{ja} \quad \lfloor \frac{(n+1)(K+1)}{N+2} \rfloor.$$

NB! Kui tähistame $p = \frac{K}{N}$, siis: $EX = np$ ja $DX = np(1-p)\frac{N-n}{N-1}$.
Seega on hüpergeomeetrilise jaotuse omadused väga sarnased binoomjaotusele. Saab näidata, et kui $N$ on suur, siis lähenebki hüpergeomeetriline jaotus binoomjaotusele parameetritega $n$ ja $p$.

**Näide 24.** Kastist, kus on 50 kollast ja 150 punast õuna, võetakse juhuslikult välja 5 õuna. Kui suur on tõenäosus, et täpselt kaks neist on kollased?

**Lahendus:**

$$P(X=2) = \frac{C_{50}^2 \cdot C_{150}^3}{C_{200}^5} = \frac{50!}{2! \cdot 48!} \cdot \frac{150!}{3! \cdot 147!} \cdot \frac{5! \cdot 195!}{200!} \approx 0{,}266.$$

Muudame tegurite järjekorda ülaltoodud avaldises ja lihtsustame, saades:

$$P(X=2) = \frac{5!}{2! \cdot 3!} \cdot \frac{50! \cdot 150! \cdot 195!}{48! \cdot 147! \cdot 200!} = C_5^2 \cdot \frac{49 \cdot 50 \cdot 148 \cdot 149 \cdot 150}{196 \cdot 197 \cdot 198 \cdot 199 \cdot 200} = C_5^2 \cdot \frac{49}{196} \cdot \frac{50}{197} \cdot \frac{148}{198} \cdot \frac{149}{199} \cdot \frac{150}{200}.$$

Nüüd näeme, et: $\frac{50}{197} \approx \frac{49}{196} = 0{,}25$ ning $\frac{148}{198} \approx \frac{149}{199} \approx \frac{150}{200} = 0{,}75$.

Seega: $P(X=2) \approx C_5^2 \cdot 0{,}25^2 \cdot 0{,}75^3 \approx 0{,}264$.
Osutub, et siin näites annab binoomjaotuse tõenäosusfunktsioon üsna korrektse vastuse (ja palju väiksema arvutusmahuga!).

See seaduspära kehtib ka üldiselt: kui $N >> n$, siis on hüpergeomeetriline jaotus $H(N,K,n)$ lähendatav binoomjaotusega $B(n, p = \frac{K}{N})$. Reeglina töötab lähendus hästi, kui $N > 20n$.

### 3.3.7 Poissoni jaotus

Vaatleme nüüd selliseid juhuslikke suuruseid, mille väärtuseks on millegi/kellegi loendamisel saadav arv. Näiteks võib selleks olla "Delta" õppehoone juures olevat silda ületavate autode arv järgneva 10 minuti jooksul, päeva jooksul Eestis sündinud laste arv, või hoopis munade arv varesepesas. Sellise juhusliku suuruse väärtuseks saavad olla arvud $0, 1, 2, \ldots$, kusjuures maksimaalne väärtus ei ole fikseeritud. Osutub, et seda tüüpi juhuslike suuruste jaotuseks sobib tihti Poissoni jaotus.

**Definitsioon (Poissoni jaotus).** Juhuslik suurus $X$ on Poissoni jaotusega, $X \sim Po(\lambda)$, kui $X$ võimalikud väärtused on 0,1,2,3,... ning

$$P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda},$$

kus $\lambda > 0$ on Poissoni jaotuse parameeter.

Poissoni jaotuse puhul kehtivad järgmised omadused:

- Kui $\lambda < 1$, siis X väärtuste 0,1,2,... tõenäosused kahanevad järjest.

- Kui $\lambda$ on täisarv, siis on kõige suurema tõenäosusega esinevateks väärtusteks $\lambda$ ja $\lambda-1$, kusjuures
$$P(X=\lambda)=P(X=\lambda-1).$$
- Kui $\lambda$ ei ole täisarv, siis on kõige suurema tõenäosusega esinevaks väärtuseks $\lambda$ täisosa $\lfloor\lambda\rfloor$.
- Kokkuvõtvalt võib öelda, et moodideks on $\lfloor\lambda\rfloor$ ja $\lceil\lambda\rceil-1$ (mitte-täisarvulise $\lambda$ korral langevad need kaks kokku.)

Esmalt veendume, et Poissoni jaotuse kõgi tõenäosuste summa on 1. Selleks meenutame, et suvalise funktsiooni $f(x)$ saab esitada *Taylori rea* kujul: Funktsiooni $f(x)$ Taylori rida 0 ümbruses on:
$$f(x)=f(0)+f'(0)x+\frac{f''(0)}{2!}x^2+\frac{f^{(3)}(0)}{3!}x^3+\dots$$
Funktsiooni $e^\lambda$ Taylori ritta arendus on seega järgmine:
$$e^\lambda=1+\lambda+\frac{\lambda^2}{2!}+\frac{\lambda^3}{3!}+\dots=\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}.$$
Seetõttu:
$$\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}e^{-\lambda}=e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}=e^{-\lambda}\cdot e^\lambda=1.$$
Samu teadmisi saab kasutada ka Poissoni jaotuse keskväärtuse leidmisel:
$$EX=\sum_{k=0}^{\infty}k\cdot P(X=k)=\sum_{k=0}^{\infty}k\frac{\lambda^k}{k!}e^{-\lambda}=\sum_{k=1}^{\infty}k\frac{\lambda^k}{k!}e^{-\lambda}=e^{-\lambda}\sum_{k=1}^{\infty}k\frac{\lambda\cdot\lambda^{k-1}}{(k-1)!\cdot k}=\lambda e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}=\lambda e^{-\lambda}e^\lambda=\lambda.$$
Leidsime, et Poissoni jaotuse parameeter $\lambda$ on ühtlasi Poissoni jaotuse keskväärtuseks. Leiame ka dispersiooni. Selleks on otstarbekas leida esmalt $E[X(X-1)]$, kasutades selleks juhusliku suuruse funktsiooni keskväärtuse valemit:
$$E[X(X-1)]=\sum_{k=0}^{\infty}k(k-1)\frac{\lambda^k}{k!}e^{-\lambda}=\sum_{k=2}^{\infty}k(k-1)\frac{\lambda^k}{k!}e^{-\lambda}=\lambda^2\sum_{k=2}^{\infty}\frac{\lambda^{k-2}}{(k-2)!}e^{-\lambda}=\lambda^2\sum_{m=0}^{\infty}\frac{\lambda^m}{m!}e^{-\lambda}=\lambda^2$$
(Sest $\displaystyle\sum_{m=0}^{\infty}\frac{\lambda^m}{m!}e^{-\lambda}$ on Poissoni jaotuse tõenäosuste summa ja seetõttu võrdub 1-ga.)
Saime, et $E[X(X-1)]=\lambda^2$. Samal ajal $E[X(X-1)]=EX^2-EX=EX^2-\lambda$. Seega $EX^2=\lambda^2+\lambda$.
Dispersiooni saame siis avaldada kui:
$$DX=EX^2-(EX)^2=\lambda^2+\lambda-\lambda^2=\lambda$$
Seega:
Poissoni jaotuse keskväärtus ja dispersioon on võrdsed: $EX=DX=\lambda$

**Näide 25.** Ajaleht "Tartu Postimees" kirjutas 30. detsembril 2016: "Aastal 2016 sündis Tartu Ülikooli Kliinikumis 2495 last, 1308 poissi ja 1187 tüdrukut (29. detsembri kella 10 seisuga). Kolmel päeval aastas oli sünnitusi 14, ühel päeval ei sündinud ühtegi last, keskmine sünnituste arv päevas oli 7."
Uurime, kas sündide arv päevas sarnaneb Poissoni jaotusega juhuslikule suurusele. Hinnangu parameetrile $\lambda$ saame, kui leiame keskmise sündide arvu päevas: $\lambda=\dfrac{2495}{364}\approx 6{,}85$. Hindame nüüd tõenäosuseid, et päevas sünnib 0, 1, 2 või 14 last:
$$\begin{aligned}
P(X=0) &= \frac{6{,}85^0}{0!}e^{-6{,}85}=e^{-6{,}85}\approx 0{,}001\\
P(X=1) &= \frac{6{,}85^1}{1!}e^{-6{,}85}\approx 0{,}007\\
P(X=2) &= \frac{6{,}85^2}{2!}e^{-6{,}85}\approx 0{,}025\\
P(X=14) &= \frac{6{,}85^{14}}{14!}e^{-6{,}85}\approx 0{,}006
\end{aligned}$$

Seega võiks sellise sündumuse korral leiduda hinnanguliselt üks päev 1000-st, kus ei sünni ühtegi last. Päevi kus sünnib 14 last, võiks aga olla aastas keskmiselt $365 \cdot 0{,}006 = 2{,}2$. Näeme, et need hinnangud ei ole kaugel sellest, mida vaadeldi reaalsuses.
*Tegime siin eelduse, et sünnid jagunevad aasta peale ühtlaselt – tegelikkuses ei pruugi see alati nii olla ja seetõttu võib nii erakordselt paljude sündidega päevi kui ka päris ilma sündideta päevi olla veidi rohkem kui Poissoni jaotuse korral eeldada võiks.*

### 3.3.8 Poissoni piirteoreem

Nägime, et mitmete eelpool tutvustatud jaotuste (nt binoomjaotus, geomeetriline jaotus, ...) tõenäosusfunktsiooni oli lihtne tuletada, kasutades tuttavaid operatsioone tõenäosustega. Poissoni jaotuse korral ei paista see aga nii lihtne olevat. Osutub aga, et Poissoni jaotuse tõenäosusfunktsioon on tegelikult Bernoulli valemi ehk binoomjaotuse jaotusfunktsiooni piirväärtuseks, kui $n$ läheneb lõpmatusele. Kehtib järgmine teoreem:

Poissoni piirteoreem Olgu $X_1, X_2, \ldots$ binoomjaotusega juhuslikud suurused, $X_n \sim B(n,p_n)$ ja leidku aset koondumine $EX_n = np_n \to \lambda > 0$. Siis binoomjaotuse tõenäosused koonduvad Poissoni jaotuse tõenäosusteks:

$$P(X_n = k) = C_n^k p_n^k (1-p_n)^{n-k} \to \frac{\lambda^k}{k!} e^{-\lambda}, \ n \to \infty.$$

Sellest järeldub, et kui $n$ on suur ja $p$ on suhteliselt väike, siis on binoomjaotus väga lähedane Poissoni jaotusele. Praktika näitab, et lähenduse kasutamiseks võiks olla kas $n \geq 20$ ja $p \leq 0{,}05$ või $n \geq 100$ ja $p \leq 0.10$.

**Näide 26.** Umbes 1,5% Tartu Ülikooli Loodusteaduste valdkonna tudengitest on pärit Saaremaalt (2020-2022 vastuvõtustatistika andmetel). Kui suur on tõenäosus, et praktikumirühmas kus on 25 Loodusteaduste valdkonna tudengit, on vähemalt kaks Saaremaalt pärit tudengit?

**Lahendus:**
Olgu $X$ Saaremaalt pärit tudengite arv selles praktikumirühmas. Saame eeldada, et $X \sim B(25; 0{,}015)$.
Variant 1: Kasutades binoomjaotuse eeldust, leiame esmalt $P(X < 2)$:

$$P(X < 2) = P(X = 0) + P(X = 1) = (1 - 0{,}015)^{25} + 25 \cdot 0{,}015 \cdot (1 - 0{,}015)^{24} \approx 0{,}946.$$

Seega $P(X > 2) = 1 - P(X \leq 2) \approx 1 - 0{,}946 = 0{,}054$.
Variant 2: Kasutame Poissoni jaotuse lähendust: $EX = np = 25 \cdot 0{,}015 = 0{,}375$, seega $\lambda = 0{,}375$. Nüüd:

$$P(X < 2) = P(X = 0) + P(X = 1) = e^{-0{,}375} + 0{,}375 \cdot e^{-0{,}375} = e^{-0{,}375} \cdot (1 + 0{,}375) = 1{,}375 \cdot e^{-0{,}375} \approx 0{,}945.$$

Seega saame hinnata, et $P(X \geq 2) \approx 1 - 0{,}945 = 0{,}055$.
Vahe kahe tulemuse vahel on väga väike (tõenäosuse hinnanguks vastavalt 5,4% või 5,5%) ja seega ei kaota me oluliselt täpsuses, kui kasutame binoomjaotuse asemel Poissoni jaotuse eeldust.

### 3.3.9 Kokkuvõte: seosed jaotuste vahel.

Kokkuvõttes nägime, et diskreetsete jaotuste vahel kehtivad järgmised seosed:

- Bernoulli jaotus on binoomjaotuse erijuht, kui $n = 1$.
- Geomeetriline jaotus on negatiivse binoomjaotuse erijuht, kui $m = 1$
  Siin toodud parametrisatsiooni kohaselt: kui $X \sim NB(1,p)$, siis $(X - 1) \sim \text{Geom}(p)$)
- Hüpergeomeetriline jaotus läheneb binoomjaotusele, kui $N >> n$.
  ($N$ on palju suurem kui $n$).
- Binoomjaotus läheneb Poissoni jaotusele, kui $n$ on suur ja $p$ väike
  (Poissoni piirteoreem).

| $(x;y)$ | 2. kuul | | | | |
|---|---|---|---|---|---|
| 1. kuul: | S | S | P | P | M |
| S | | $(2;0)$ | $(1;1)$ | $(1;1)$ | $(1;0)$ |
| S | $(2;0)$ | | $(1;1)$ | $(1;1)$ | $(1;0)$ |
| P | $(1;1)$ | $(1;1)$ | | $(0;2)$ | $(0;1)$ |
| P | $(1;1)$ | $(1;1)$ | $(0;2)$ | | $(0;1)$ |
| M | $(1;0)$ | $(1;0)$ | $(0;1)$ | $(0;1)$ | |

| $Y$ / $X$ | 0 | 1 | 2 | $\Sigma$ |
|---|---|---|---|---|
| 0 | 0 | 0,2 | 0,1 | 0,3 |
| 1 | 0,2 | 0,4 | 0 | 0,6 |
| 2 | 0,1 | 0 | 0 | 0,1 |
| $\Sigma$ | 0.3 | 0.6 | 0,1 | 1 |

Tabel 3.1: Võimalikud $X$ (siniste kuulide arv) ja $Y$ (siniste kuulide arv) väärtused $(x;y)$ kahe kuuli võtmisel urnist, kus on kaks sinist, kaks punast ja üks must kuul. Parempoolne tabel kujutab tulemusena tekkinud $X$ ja $Y$ ühisjaotust.

## 3.4 Kahe juhusliku suuruse ühisjaotus ja nendevaheline seos.

### 3.4.1 Kahe diskreetse juhusliku suuruse (ehk diskreetse juhusliku vektori) ühisjaotus.

**Näide 27.** Urnist, kus on kaks sinist, kaks punast ja üks must kuul, võetakse juhuslikult kaks kuuli. Soovime leida tõenäosuse, et: (a) saadakse üks sinine ja mitte ühtegi punast kuuli; (b) saadakse üks sinine ja üks punane kuul; (c) saadakse kaks punast kuuli.

**Lahendus:**
Seda ülesannet oskame me lahendada klassikalise tõenäose põhimõttel, arvestades tagasipanekuta valikuga. Alternatiivselt võime ka siin defineerida juhuslikud suurused ja uurida nende jaotust. Olgu $X$ saadud siniste kuulide arv ja olgu $Y$ saadud punaste kuulide arv. Tabeli 3.1 vasakpoolses osas on toodud kõik võimalikud $X$ ja $Y$ väärtused antud juhusliku katse korral. Näeme, et iga elementaarsündmus määrab korraga nii $X$ kui $Y$ väärtuse – näiteks kui saadakse üks sinine ja üks must kuul, siis $(X;Y) = (1;0)$. Tabelist näeme, et kuulide järjekorda arvestades esineb väärtuste komplekti $(1;0)$ 4 elementaarsündmuse puhul 20-st võimalikust, ehk võime kirjutada küsimuse (a) vastuseks $P(X = 1, Y = 0) = 0{,}2$. Kokkuvõttes saame $X$ ja $Y$ võimalike väärtuste paaride tõenäosused esitada nii nagu näidatud tabeli 3.1 parempoolses osas – juhuslike suuruste ühisjaotuse tabelis. Sealt leiame ka vastused ülesande küsimustele (b) ja (c) kui $P(X = 1; Y = 1) = 0{,}4$ ja $P(X = 0; Y = 2) = 0{,}1$.

Defineerime nüüd juhusliku vektori $(X,Y)$ ja ühisjaotuse mõiste üldiselt.

Olgu diskreetsete juhuslike suuruste $X$ ja $Y$ väärtused vastavalt $x_1,x_2,\ldots$ ja $y_1, y_2, \ldots$ . Siis juhusliku vektori $(X,Y)$ väärtusteks on kõikvõimalikud paarid $(x_i,y_j)$, kus $i, j = 1,2,\ldots$. Tähistame nende paaride tõenäosused $p_{ij} = P(X = x_i, Y = y_j)$.

**Definitsioon.** **Diskreetse juhusliku vektori $(X,Y)$ ühisjaotuseks** nimetatakse kolmikute komplekti
$\{(x_i,y_j,p_{ij}),\ i,j = 1,2,\ldots\}$, kus $p_{ij} = P(X = x_i, Y = y_j)$.

Ühisjaotuse saab esitada tabeli kujul, nagu näidatud tabelis 3.2. Paneme tähele, et nii sündmused $\{Y = y_j\}$ $(j \in 1,2,\ldots)$ kui $\{X = x_i\}$ $(j \in 1,2,\ldots)$ moodustavad sündmuste täissüsteemi. Seega kehtib:

$$\sum_j p_{ij} = \sum_j P(X = x_i, Y = y_j) = \sum_j P(\{X = x_i\} \cap \{Y = y_j\}) = P(X = x_i)$$

ning samamoodi

$$\sum_i p_{ij} = \sum_i P(X = x_i, Y = y_j) = P(Y = y_j),$$

ehk tabeli 3.2 ridu või veerge summeerides saame vastavalt $X$ või $Y$ jaotused, ehk marginaaljaotused.
Tähistame: $P(X = x_i) = \sum_j p_{ij} = p_{i\cdot}$ ja $P(Y = y_j) = \sum_i p_{ij} = p_{\cdot j}$.

| $X$ \ $Y$ | $y_1$ | $y_2$ | $y_3$ | $\dots$ | $y_j$ | $\dots$ | $\sum$ |
|---|---|---|---|---|---|---|---|
| $x_1$ | $p_{11}$ | $p_{12}$ | $p_{13}$ | $\dots$ | $p_{1j}$ | $\dots$ | $p_{1.}$ |
| $x_2$ | $p_{21}$ | $p_{22}$ | $p_{23}$ | $\dots$ | $p_{2j}$ | $\dots$ | $p_{2.}$ |
| $x_3$ | $p_{31}$ | $p_{32}$ | $p_{33}$ | $\dots$ | $p_{3j}$ | $\dots$ | $p_{3.}$ |
| $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ |
| $x_i$ | $p_{i1}$ | $p_{i2}$ | $p_{i3}$ | $\dots$ | $p_{ij}$ | $\dots$ | $p_{i.}$ |
| $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ |
| $\sum$ | $p_{.1}$ | $p_{.2}$ | $p_{.3}$ | $\dots$ | $p_{.j}$ | $\dots$ | 1 |

$p_{ij} = P(X = x_i, Y = y_j)$

Tabel 3.2: Diskreetsete juhuslike suuruste $X$ ja $Y$ ühisjaotus koos marginaaljaotustega.

Kokkuvõttes veendusime, et juhusliku vektori $(X,Y)$ ühisjaotuse tabelis:

- reasummad moodustavad juhusliku suuruse $X$ jaotuse ning
- veerusummad moodustavad juhusliku suuruse $Y$ jaotuse, st:

$$p_{i.} = P(X = x_i), \quad p_{.j} = P(Y = y_j) \text{ ja } \sum_i \sum_j p_{ij} = 1.$$

### 3.4.2 Kahe juhusliku suuruse funktsiooni keskväärtus.

Ühisjaotuse abil saame defineerida ka kahemuutuja funktsiooni keskväärtuse (vt ka teoreem 2.2 K.Pärna õpikus).

Teoreem:

**Kahemuutuja funktsiooni keskväärtus** avaldub kujul:

$$Eg(X,Y) = \sum_i \sum_j g(x_i,y_j)P(X = x_i, Y = y_j) = \sum_i \sum_j g(x_i,y_j)p_{ij}. \tag{3.7}$$

Selle teoreemi tõestus on sarnane ühemuutuja funktsiooni keskväärtuse valemi tõestusele (valem 3.1).

Tõestus:
Olgu juhuslik suurus $Z = g(X,Y)$. Definitsiooni kohaselt:

$$\begin{aligned} EZ = \sum_k z_i P(Z = z_k) &= \sum_k z_k \sum_{x_i,y_j : g(x_i,y_j)=z_k} P(X = x_i, Y = y_j) \\ &= \sum_k \sum_{x_i,y_j : g(x_i,y_j)=z_k} g(x_i,y_j)P(X = x_i, Y = y_j) \\ &= \sum_i \sum_j g(x_i,y_j)P(X = x_i, Y = y_j). \end{aligned}$$

Pange tähele, et sellest teoreemist järeldub ka peatükis 3.2 toodud lemma kahe juhusliku suuruse summa keskväärtuse kohta, kus saime teada et $E(X + Y) = EX + EY$. Selle kehtivuses on nüüd lihtne veenduda, sest:

$$\begin{aligned} E(X + Y) &= \sum_i \sum_j (x_i + y_j)p_{ij} = \sum_i \sum_j x_i p_{ij} + \sum_i \sum_j y_j p_{ij} \\ &= \sum_i x_i \sum_j p_{ij} + \sum_j y_j \sum_i p_{ij} = \sum_i x_i p_{i.} + \sum_J y_j p_{.j} = EX + EY. \end{aligned}$$

| | 2. kaart | | | | | |
|---|---|---|---|---|---|---|
| 1. kaart: | 1 | 2 | 3 | 4 | 5 | 6 |
| 1 | | 2 | 3 | 4 | 5 | 6 |
| 2 | 2 | | 4 | 6 | 8 | 10 |
| 3 | 3 | 6 | | 12 | 15 | 18 |
| 4 | 4 | 8 | 12 | | 20 | 24 |
| 5 | 5 | 10 | 15 | 20 | | 30 |
| 6 | 6 | 12 | 18 | 24 | 30 | |

Tabel 3.3: Kahel kaardil olevad numbrid ja nende korrutis.

Teine järeldus siit on ka seos 3.6: sõltumatute juhuslike suuruste korrutise keskväärtus avaldub kui $EXY = EX \cdot EY$.

**Näide 28.** Visatakse kahte täringut. Olgu $X$ esimesel täringul saadud silmade arv ja olgu $Y$ teisel täringul saadud silmade arv Leia $E(XY)$..

**Lahendus:**
Tegemist on sõltumatute juhuslike suurustega (vt peatükki 3.2.2) ja seetõttu saame kasutada teadmist, et sellisel juhul $EXY = EX \cdot EY = 3{,}5^2 = 12{,}25$.

**Näide 29.** Laual on tagurpidi kaardid numbritega $1 \dots 6$ ja sealt tõmmatakse juhuslikult kaks kaarti. Olgu $X$ esimesel kaardil olev number ja olgu $Y$ teisel kaardil olev number. Leia $E(XY)$..

**Lahendus:**
Nüüd enam ei ole tegemist sõltumatute juhuslike suurustega, sest näiteks $P(X = 1) = P(Y = 1) = \frac{1}{6}$, aga $P(X = 1, Y = 1) = 0$. (sest sama kaarti ei saa kaks korda võtta). Seega näite 28 lahendus siin ei kehti. Saame aga kasutada valemit 3.7, millest:

$$EXY = \sum_{i=1}^{6} \sum_{j=1}^{6} x_i y_j P(X = x_i, Y = y_j).$$

Tabelit 3.3 vaadates võime tähele panna, et tekkinud kahemõõtmeline jaotus erineb kahe täringu viskamisel saadud summa jaotusest ainult selle võrra, et lahtrisse $i = j$ sattuda ei saa ja seega on vastav tõenäosus 0. Kõik teised variandid esinevad võrdse tõenäosusega $\frac{1}{30}$. Seega võime siin leida:

$$EXY = \frac{1}{30}(\sum_{i=1}^{6} \sum_{j=1}^{6} x_i y_j - \sum_{i=1}^{6} x_i^2) \approx 11{,}67.$$

### 3.4.3 Sõltumatud ja sõltuvad juhuslikud suurused. Kovariatsioon ja korrelatsioon.

Väga tihti pakub huvi küsimus, kas kaks juhuslikku suurust on sõltumatud või mitte. Sõltumatute juhuslike suuruste korral ei anna ühe juhusliku suuruse väärtuse teadmine mingit infot teise kohta, kuid sõltuvuse korral see nii ei ole. Nii nägime näites 29 (numbritega kaartide võtmine laualt), et kui on teada $X$ väärtus, näiteks $X = 3$ siis see annab $Y$ kohta on info, et $Y$ väärtus ei saa olla 3. Kahe juhusliku suuruse $X$ ja $Y$ marginaaljaotusi teades on nende ühisjaotus kindlalt määratud ainult siis, kui nad on sõltumatud, st $p_{ij} = p_{i.} p_{.j}$.

**Näide 30.** Olgu meil kaks Bernoulli jaotusega juhuslikku suurust $X \sim Ber(0{,}7)$ ja $Y \sim Ber(0{,}8)$. Tabelis 3.4 on toodud kaks võimalikku ühisjaotuse tabelit nende juhuslike suuruste jaoks.

**A:**

| $Y$ / $X$ | 0 | 1 | $\Sigma$ |
|---|---|---|---|
| 0 | 0,06 | 0,24 | 0.3 |
| 1 | 0,14 | 0,56 | 0.7 |
| $\Sigma$ | 0.2 | 0.8 | 1 |

**B:**

| $Y$ / $X$ | 0 | 1 | $\Sigma$ |
|---|---|---|---|
| 0 | 0,15 | 0,15 | 0.3 |
| 1 | 0,05 | 0,65 | 0.7 |
| $\Sigma$ | 0.2 | 0.8 | 1 |

Tabel 3.4: Kaks võimalikku ühisjaotust samade marginaaljaotuste $X \sim Ber(0{,}7)$ ja $Y \sim Ber(0{,}8)$ korral.

Näeme, et marginaaljaotused on nii tabelis A kui B samad, kuid ühisjaotused on erinevad. On lihtne veenduda, et tabelis A kujutatud ühisjaotuse korral on $X$ ja $Y$ sõltumatud: kehtib $p_{ij} = p_{i.}p_{.j}$. Tabeli B korral see aga ei kehti, seega on tegemist sõltuvate juhuslike suurustega. Seega ei anna info $X$ ja $Y$ (marginaal)jaotuste kohta meile veel piisavat infot ühisjaotuse kohta.
Selle näite puhul paneme tähele ka seda, et *kahe Bernoulli jaotusega juhusliku suuruse ühisjaotus on määratud siis, kui on teada marginaaljaotused ja vähemalt üks tõenäosus* $p_{ij}$. Kõik ülejäänud tõenäosused tabelis on leitavad lihtsate lahutamistehete abil, sest rea- ja veerusummad on määratud marginaaljaotuste poolt.

Näites 27 panime tähele, et kuigi nii $X$ kui $Y$ (urnist võetud siniste ja punaste kuulide arv) saavad võtta väärtudeid $0, 1, 2$, siis $X = 2$ korral saab $Y$ väärtus olla ainult 0. Seega võime öelda, et $X$ ja $Y$ on negatiivselt seotud – mida suurem on $X$ väärtus, seda väiksem saab olla $Y$ ja vastupidi. Väga tihti pakuvadki huvi olukorrad, kus seos kahe juhusliku suuruse vahel on monotoonne – st ühe juhusliku suuruse väärtuse suurenedes esinevad teise juhusliku suuruse väärtused süstemaatiliselt kas suurema või väiksema tõenäosusega. Sellist sorti sõltuvuse mõõtmiseks ja iseloomustamiseks kasutatakse kovariatsiooni ja korrelatsiooni mõistet.

**Definitsioon.** **Juhuslike suuruste $X$ ja $Y$ kovariatsiooniks** nimetatakse suurust:

$$\text{cov}(X,Y) = E(X - EX)(Y - EY). \tag{3.8}$$

**Näide 31.** Leiame näites 27 toodud juhuslike suuruste kovariatsiooni. Tabelis 3.1 toodud marginaaljaotusi kasutades leiame, et $EX = EY = 0{,}8$. Seega:

$$\begin{aligned} cov(X,Y) &= \sum_i \sum_j (x_i - 0{,}8)(y_j - 0{,}8)p_{ij} \\ &= (-0{,}8) \cdot 0{,}2 \cdot 0{,}2 + (-0{,}8) \cdot 1{,}2 \cdot 0{,}1 + 0{,}2 \cdot (-0{,}8) \cdot 0{,}2 + 0{,}2 \cdot 0{,}2 \cdot 0{,}4 + 1.2 \cdot (-0{,}8) \cdot 0{,}1 \\ &= -0{,}032 - 0{,}096 - 0{,}032 + 0{,}016 - 0{,}096 = -0{,}24 \end{aligned}$$

Selle arvutuskäigu juures paneme tähele, et enamus liidetavaid on negatiivsed: seal kus korrutis $(x_i - 0{,}8)(y_j - 0{,}8)$ oleks olnud positiivne, on vastav tõenäosus $p_{ij} = 0$ – ehk, olukorda kus $X$ ja $Y$ oleks samaaegselt kas alla või üle keskmise, esineb väga väikese tõenäosusega. Seega osutus ka kovariatsioon negatiivseks.

Öeldakse, et:

1. Kui $\text{cov}(X,Y) > 0$, siis öeldakse, et $X$ ja $Y$ on positiivselt korreleeritud
2. Kui $\text{cov}(X,Y) < 0$, siis öeldakse, et $X$ ja $Y$ on negatiivselt korreleeritud
3. Kui $\text{cov}(X,Y) = 0$, siis öeldakse, et $X$ ja $Y$ on mittekorreleeritud

Kovariatsiooni leidmisel on tihti kasulik kasutada alternatiivset valemit:

$$\text{cov}(X,Y) = E(XY) - EX \cdot EY. \tag{3.9}$$

Näitame, et see kehtib:

$$\begin{aligned} \text{cov}(X,Y) &= E(X - EX)(Y - EY) = E(XY - X \cdot EY - EX \cdot X + EX \cdot EY) = \\ &= E(XY) - EX \cdot EY - EX \cdot EY + EX \cdot EY = \\ &= E(XY) - EX \cdot EY \end{aligned}$$

Paneme ka tähele, et sõltumatute juhuslike suuruste korral $cov(X,Y) = 0$, sest siis $EXY = EX \cdot EY$.

**Näide 32.** Leiame näites 27 toodud juhuslike suuruste kovariatsiooni ka alternatiivse valemi abil. Paneme tähele, et:

$$EXY = \sum_i \sum_j x_i y_j p_{ij} = 1 \cdot 1 \cdot 0{,}4 = 0{,}4,$$

sest kõik teised liikmed summas on võrdsed 0-ga. Juba leidsime, et $EX = EY = 0{,}8$, seega:

$$cov(X,Y) = 0{,}4 - 0{,}8 \cdot 0{,}8 = 0{,}4 - 0{,}064 = -0{,}24.$$

Saime sama tulemuse mis enne, aga palju väiksema vaevaga!

**Näide 33.** Leiame ka näites 29 kirjeldatud juhuslike suuruste (numbrid kahel laualt tõmmatud kaardil) kovariatsiooni. Nägime, et $EXY \approx 11{,}67$ ning $EX \cdot EY = 3{,}5 \cdot 3{,}5 = 12{,}25$. Seega:

$$cov(X,Y) = 11{,}67 - 12{,}25 = -0{,}58.$$

Seega on ka siin tegu negatiivse korreleeritusega.

**Näide 34.** Visatakse kahte täringut. Olgu $Y$ kahe täringu silmade vahe ja olgu $Z$ kahe täringu silmade korrutis. Leiame $cov(Y,Z)$.

**Lahendus:**
Olgu $X_1$ ja $X_2$ juhuslikud suurused, mis vastavad esimesel ja teisel täringul saadud silmade arvule. Paneme tähele, et $X_1$ ja $X_2$ on sõltumatud juhuslikud suurused. Nüüd $Y = X_1 - X_2$ ja $Z = X_1X_2$.

Seega $EY = E(X_1 - X_2) = EX_1 - EX_2 = 0$
ning $EZ = E(X_1X_2) = (EX_1)(EX_2) = 3{,}5^2$.

Näeme, et $EZY = E[X_1X_2(X_1 - X_2)] = E(X_1^2X_2 - X_1X_2^2) = 0$, sest $X_1$ ja $X_2$ on sama jaotusega.

Seega $\text{cov}(Y,Z) = EYZ - EYEZ = 0 - 0 = 0$.

Samas ei ole $Y$ ja $Z$ sõltumatud. Selle näitamiseks piisab, kui leiame $Y$ ja $Z$ väärtused nii, et $P(Y = y) \neq 0$ ning $P(Z = z) \neq 0$, kuid $P(Y = y, Z = z) = 0$ (näiteks $Y = 2$ ja $Z = 1$).

Nägime, et kui $X$ ja $Y$ on sõltumatud, siis $cov(X,Y) = 0$, aga vastupidine järeldus ei pruugi alati kehtida: kui $cov(X,Y) = 0$, siis $X$ ja $Y$ ei pruugi tingimata veel sõltumatud olla. Seega ei ole mittekorreleeritus sama mis sõltumatus.

Saab näidata, et:
$\text{cov}(X,X) = DX$ (proovi ise tõestada!)

Samuti saab näidata, et: $0 \leq |\text{cov}(X,Y)| \leq \sqrt{DX \cdot DY}$

Seetõttu on korrelatsioonikordaja defineeritud kui:

$$\rho(X,Y) = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y},$$

kusjuures $-1 \leq \rho(X,Y) \leq 1$.
(tuleme selle juurde tagasi hiljem)

**Summa dispersioon**

**Summa dispersioon.** Olgu $X$ ja $Y$ kaks juhuslikku suurust. Siis kehtib:

$$D(X+Y) = DX + DY + 2\text{cov}(X,Y)$$

Tõestus:

$$\begin{aligned} D(X+Y) &= E(X+Y)^2 - [E(X+Y)]^2 \\ &= E(X^2+2XY+Y^2) - [(EX)^2 + 2EX\cdot EY + (EY)^2] \\ &= E(X^2) - (EX)^2 + E(Y^2) - (EY)^2 + 2[EXY - EX\cdot EY] \\ &= DX + DY + 2\text{cov}(X,Y). \end{aligned}$$

Kui $X$ ja $Y$ on sõltumatud, siis nende summa dispersioon avaldub kui dispersioonide summa:

$$D(X+Y) = DX + DY$$

Samuti:

$$D(aX+bY) = a^2DX + b^2DY, \text{ kus } a,b \in \mathbb{R}$$

Sõltumatute juhuslike suuruste summa standardhälve avaldub kui:

$$\sigma_{aX+bY} = \sqrt{a^2DX + b^2DY} = \sqrt{a^2\sigma_X^2 + b^2\sigma_Y^2} \neq a\sigma_X + b\sigma_Y$$

**Kovariatsioon, korrelatsioon ja lineaarne teisendus.**

Olgu juhuslikud suurused $X$ ja $Y$ ning konstandid $a$, $b$, $c$ ja $d$, kusjuures $a \neq 0$ ja $c \neq 0$. Kehtib, et:

$$\text{cov}(aX+b,\ cY+d) = ac\ \text{cov}(X,Y).$$

Seega:

$$\text{cov}(X+b,\ Y+d) = \text{cov}(X,Y).$$

Samuti on lihtne veenduda, et:

$$\rho(aX+b,\ cY+d) = \rho(X,Y).$$

Saame järeldada ka seda, et kui $X$ ja $Y$ on korreleeritud, siis lineaarne teisendus ei saa muuta neid mittekorreleerituteks ja vastupidi – mittekorreleeritud juhuslikke suurusi ei saa lineaarse teisendusega korreleerituks muuta.

### 3.4.4 Tinglikud jaotused.

Definitsioon. Juhusliku suuruse $Y$ tinglik jaotus tingimusel et $X = x_i$, on tinglike tõenäosuste komplekt

$$p_{j|i} = \frac{p_{ij}}{p_i},$$

$$\text{kus } p_{j|i} = P(Y = y_j | X = x_i),\ p_{ij} = P(X = x_i, Y = y_j) \text{ ja } p_i = P(X = x_i).$$

Tingliku jaotuse suhtes saab defineerida ka tingliku keskväärtuse.

Definitsioon. Juhusliku suuruse $X$ tinglikuks keskväärtuseks sündmuse $B$ suhtes (tingimusel $B$) nimetatakse arvu

$$E(X|B) = \sum_i x_i P(X = x_i|B).$$

Kõige tavalisem on sündmusena $B$ käsitleda teise juhusliku suuruse $Y$ konkreetset väärtust $y$.

$$E(X|Y = y) = \sum_i x_i P(X = x_i|Y = y).$$

Teoreem 2.6. Moodustagu $B_1$,$B_2$,... sündmuste täissüsteemi ruumis $\Omega$, kusjuures $P(B_j) > 0$ iga $j$ korral. Siis:

$$EX = \sum_j E(X|B_j)P(B_j)$$

Enamasti saab täissüsteemina vaadelda sündmuseid, mis vastavad mõne teise juhusliku suuruse, nt $Y$ võimalikele väärtustele:

$$EX = \sum_j E(X|Y = y_j)P(Y = y_j)$$

## 3.5 Jaotusfunktsioon ja juhusliku suuruse üldine definitsioon.

Meeldetuletus:

- Juhuslik suurus (ingl. *random variable*) on muutuja, mille väärtused on määratud juhusliku katse tulemuste poolt (ehk igale võimalikule väärtusele vastab teatud sündmus)
- Juhuslikku suurust võib vaadelda kui funktsiooni sündmuste ruumist (kõigi võimalike sündmuste hulk antud juhusliku katse korral) reaalteljele:
$$X : \Omega \to \mathbb{R}$$
- Seega kui sündmusele A vastab juhusliku suuruse X väärtus x, siis tõenäosust P(A) võime esitada kui P(X=x)
- Diskreetse juhusliku suuruse võimalike väärtuste hulk on lõplik või loenduv.

Järgnevalt vaatleme aga juhuslikke suurusi, mis võivad võtta väärtusi pideval skaalal – kas terve reaaltelje ulatuses või mõnel selle lõigul. Selliseid juhuslikke suuruseid nimetatakse pidevateks juhuslikeks suurusteks.

Pidevad juhuslik suurused on tihti sobivad mingite mõõtmistulemuste kirjeldamiseks (pikkus, kaal, ...) ja neid iseloomustab fakt, et ühel lõigul on teoreetiliselt lõpmatu arv selle juhusliku suuruse võimalikke väärtuseid.

Mõnikord on $X$ küll rangelt võttes diskreetne, kuid väärtuseid on nii palju ja neid on nii tihedalt, et lihtsuse mõttes loetakse väärtuste hulgaks kõik reaalarvud mingis intervallis (nt. töötasu).

Eespool nägime, et diskreetse juhusliku suuruse jaotuseks nimetatakse paaride komplekti $(x_i, p_i), i = 1,2,\ldots,$ kusjuures $\sum_i p_i = 1$. Kui aga juhusliku suuruse võimalikud väärtused on reaalarvud (kas mingil lõigul või kogu reaaltelje ulatuses), siis ei saa jaotust esitada tõenäosuste $P(X = x)$ tabelina, sest võimalike väärtuste hulk ei ole loenduv.

### 3.5.1 Üldine juhusliku suuruse definitsioon.

Olgu antud tõenäosusruum $(\Omega, \mathcal{F}, P)$ (siin $\Omega$ on kõigi elementaarsündmuste hulk ja $\mathcal{F}$ on sündmuste ruum, ehk kõigi võimalike sündmuste hulk) ja olgu $X$ mingi funktsioon: $X : \Omega \to \mathbb{R}$.
Tähistame lühidalt hulga $(X \le x) \equiv \{\omega : X(w) \le x\} \subset \Omega$ ($x$ on mingi reaalarv)

**Definitsioon.** Juhuslikuks suuruseks nimetatakse funktsiooni $X : \Omega \to \mathbb{R}$, mille korral on täidetud tingimus, et

$$\forall x \in \mathbb{R} \text{ korral hulk } \{X \le x\} \in \mathcal{F}$$

Lihtsustatult: suvalise reaalarvu $x$ puhul vastab $\{X \le x\}$ mõnele konkreetsele sündmusele (olenevalt $x$ väärtuseks võib selleks sündmuseks olla ka $\emptyset$ või $\Omega$).

### 3.5.2 Jaotusfunktsiooni mõiste. Diskreetse juhusliku suuruse jaotusfunktsioon.

**Definitsioon.** Juhusliku suuruse $X$ jaotusfunktsiooniks *((cumulative) distribution function, cdf)* nimetatakse funktsiooni

$$F_X(x) \equiv F(x) = P(X \le x), \quad x \in \mathbb{R}$$

- Alaindeksite $F_X$, $F_Y$ jne. kasutamine on otstarbekas eelkõige siis, kui tegeldakse üheaegselt mitme juhusliku suuruse jaotusfunktsioonidega.

- Osutub, et jaotusfunktsioon $F(x)$ sisaldab kogu infot, mida on vaja juhusliku suurusega $X$ seotud tõenäosuste arvutamiseks.

**Diskreetse juhusliku suuruse jaotusfunktsioon.**

**Näide 35.** Ausat münti visatakse 3 korda. Olgu juhuslik suurus $X$ defineeritud kui saadud vappide arv. Seega: $X \sim B(3; \frac{1}{2})$

Tõenäosusfunktsioon:

$$P(X = x) = C_3^x \cdot \left(\frac{1}{2}\right)^x \cdot \left(\frac{1}{2}\right)^{3-x} = C_3^x \cdot \frac{1}{2^3} = \frac{C_3^x}{8},$$

kus $x \in \{0; 1; 2; 3\}$. Arvutades need tõenäosused välja, saame jaotustabeli, kus tõenäosused võime kirja panna kas harilike või kümnendmurdudena:

| $x_i$ | 0 | 1 | 2 | 3 |
|---|---|---|---|---|
| $p_i$ | $\frac{1}{8}$ | $\frac{3}{8}$ | $\frac{3}{8}$ | $\frac{1}{8}$ |

ehk

| $x_i$ | 0 | 1 | 2 | 3 |
|---|---|---|---|---|
| $p_i$ | 0,125 | 0,375 | 0,375 | 0,125 |

Jaotusfunktsiooni $F(x) = P(X \leq x)$ väärtuste leidmiseks saame esiteks kirja panna, et kui $x < 0$, siis $F(x) = 0$, sest selle juhusliku suuruse väärtus ei saa olla negatiivne.
Edasi näeme, et $F(0) = P(X \leq 0) = P(X = 0) = 0{,}125$, sest ainus võimalik tingimust $x \leq 0$ rahuldav väärtus on $x = 0$. Samuti paneme tähele ka, et kui $0 < x < 1$, siis endiselt $F(x) = P(X = 0) = 0{,}125$.
Kui aga $x = 1$ või $1 < x < 2$, siis näeme, et tingimusele $X \leq x$ vastab juba kaks võimalikku $X$ väärtust, 0 ja 1.
Seega näiteks: $F(1{,}5) = P(X \leq 1{,}5) = P(X = 0 \text{ või } X = 1) = P(X = 0) + P(X = 1) = 0{,}125 + 0{,}375 = 0{,}5$ (saame liita, sest sündmused $X = 0$ ja $X = 1$ on teineteist välistavad).
Arutelu jätkates saame:

$$F(x) = \begin{cases} 0, & \text{kui } x < 0; \\ \frac{1}{8} = 0{,}125, & \text{kui } 0 \leq x < 1; \\ \frac{1}{2} = 0{,}5, & \text{kui } 1 \leq x < 2; \\ \frac{7}{8} = 0{,}875, & \text{kui } 2 \leq x < 3; \\ 1, & \text{kui } x \geq 3. \end{cases}$$

Üldiselt saame diskreetse juhusliku suuruse jaotusfunktsiooni panna kirja järgmiselt. Olgu $X$ diskreetne juhuslik suurus, mille võimalikud väärtused on $x_1, x_2, x_3, \ldots, (x_n)$. (Väärtus $x_n$ eksisteerib vaid siis, kui võimalike väärtuste hulk on lõplik.)

$$F(x) = \begin{cases} 0, & \text{kui } x < x_1 \\ \sum\limits_{i: x_i \leq x} p_i, & \text{kui } x_1 \leq x (\leq x_n); \\ 1, & \text{kui } x > x_n \text{ (kui } x_n \text{ eksisteerib).} \end{cases}$$

Kui diskreetse juhusliku suuruse võimalike väärtuste hulk ei ole lõplik, siis rangelt võttes ei eksisteeri sellist $x$ väärtust, kus $F(x) = 1$, kuid kehtib: $\lim\limits_{x \to \infty} F(x) = 1$.

### 3.5.3 Pideva juhusliku suuruse jaotusfunktsioon.

**Näide 36.** Laskur tulistab ringikujulist märklauda raadiusega $r$, kusjuures tabamiskoha jaotus märklaual on ühtlane. Olgu $X$ tabamiskoha kaugus märklaua keskpunktist. Leiame juhusliku suuruse $X$ jaotusfunktsiooni.

**Lahendus:**
Olgu $0 \leq x \leq r$. Sündmuse $\{X \leq x\}$ toimumine tähendab seda, et lask tabab väiksemat ringi raadiusega x. Kasutame geomeetrilist tõenäosust ehk pindalade suhet:

$$F(x) = P(X \leq x) = \frac{\pi x^2}{\pi r^2} = \frac{x^2}{r^2}$$

Ilmselt $F(x) = 0$, kui $x = 0$, ja $F(x) = 1$, kui $x > r$.
Kokkuvõttes:

$$F(x) = \begin{cases} 0, & \text{kui } x \leq 0, \\ \dfrac{x^2}{r^2}, & \text{kui } 0 < x \leq r, \\ 1, & \text{kui } x > r. \end{cases}$$

Näeme, et funktsioon $F(x)$ on antud juhul pidev, monotoonselt kasvav funktsioon.

### 3.5.4 Jaotusfunktsiooni omadused.

Jaotusfunktsiooni peamised omadused on üsna lihtsalt tuletatavad jaotusfunktsiooni definitsioonist. Nii näeme, et $F(x)$ ei saa olla kunagi kahanev funktsioon, sest iga $d > 0$ korral:
$F(x + d) = P(X \leq x + d) = P(X \leq x \text{ või } x < X \leq x + d) = P(X \leq x) + P(x < X \leq x + d) > P(X \leq x) = F(x)$.

Kokku on jaotusfunktsioonil $F(x)$ 6 omadust – selleks, et funktsioon $F(x)$ saaks olla mõne juhusliku suuruse jaotusfunktsioon, peavad need kõik kehtima.

**Jaotusfunktsiooni omadused.**

1. $0 \leq F(x) \leq 1, \ \forall x \in \mathbb{R}$

2. $F(x)$ on monotoonselt kasvav: $a \leq b \Rightarrow F(a) \leq F(b)$

3. $P(a < X \leq b) = F(b) - F(a), \ \forall a \in \mathbb{R}$

4. Piirväärtused:
$$\lim_{x \to -\infty} F(x) = 0, \quad \lim_{x \to \infty} F(x) = 1$$

5. $F(x)$ on paremalt pidev:
$$\lim_{x \to a+} F(x) = F(a), \ \forall a \in \mathbb{R}$$

6.
$$P(X = b) = F(b) - \lim_{x \to b-} F(x), \ \forall b \in \mathbb{R}$$
(funktsiooni hüppe pikkus punktis $b$)

## 3.6 Pidevad juhuslikud suurused. Tihedusfunktsiooni mõiste.

**Definitsioon.** juhuslikku suurust $X$ nimetatakse pidevaks, kui tema jaotusfunktsioon avaldub integraalina:

$$F_X(x) = \int_{-\infty}^{x} f_X(u)du \quad \forall x \in \mathbb{R}$$

Funktsiooni $f_X(x)$ nimetatakse juhusliku suuruse $X$ tihedusfunktsiooniks ehk lihtsalt tiheduseks (vahel ka tõenäosustiheduseks).
*ingl. density*

Kasutades teadmist, et integraali tuletis ülemise raja järgi annab integraalialuse funktsiooni, saame seose:

$$f_X(x) = F'_X(x)$$

(punktides kus $F_X(x)$ on diferentseeruv)

Seega tihedus $f_X(x)$ näitab, kui kiiresti kasvab jaotusfunktsioon punktis $x$.

Pideva tunnuse jaotusfunktsioon on pidev

Jaotus võib olla ka segu pidevast ja diskreetsest komponendist (joonis)

### Tihedusfunktsiooni omadused

Põhiomadused:

1. $$f_X(x) \geq 0 \ \forall x \in \mathbb{R}$$
2. $$\int_{-\infty}^{\infty} f_X(x)dx = 1$$

Iga omadusi 1 ja 2 rahuldav funktsioon $f_X$ on mingi juhusliku suuruse tihedus.

Täiendav omadus:
$F_X(x)$ pidevuse tõttu $P(X = a) = P(X = b) = 0$, seega

$$P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b) = \int_a^b f_X(x)dx$$

### 3.6.1 Pideva juhusliku suuruse keskväärtus ja dispersioon.

**Definitsioon.** Pideva juhusliku suuruse keskväärtuseks nimetatakse arvu:

$$EX = \int_{-\infty}^{\infty} x f_X(x)dx,$$

kus eeldame, et $\int_{-\infty}^{\infty} |x| f_X(x)dx < \infty$.

Pange tähele sarnasust diskreetse juhusliku suuruse keskväärtusega, arvestades et integraal on summa üldistus, kui summeerimine toimub üle pideva skaala.

- Keskväärtus on jaotuse raskuskese.

- Saab näidata, et pideva juhusliku suuruse $X$ korral kehtib võrdus:

$$E[g(X)] = \int_{-\infty}^{\infty} g(X) f_X(x) dx$$

- Ülaltoodud võrdusest järeldub, et pideva juhusliku suuruse keskväärtuse korral kehtivad samad omadused, mis diskreetse juhusliku suuruse korral: $E(aX + b) = aEX + b$.

**Näide 37.** (näite 36 järg). Laskur tulistab ringikujulist märklauda raadiusega $r$, kusjuures tabamiskoha jaotus märklaual on ühtlane. Milline on tabamiskoha keskmine kaugus tsentrist?

**Lahendus:**
Olgu $X$ tabamiskoha kaugus märklaua tsentrist -– leiame $X$ keskväärtuse. Enne leidsime jaotusfunktsiooni:

$$F(x) = \begin{cases} 0, & \text{kui } x \leq 0, \\ \dfrac{x^2}{r^2}, & \text{kui } 0 < x \leq r, \\ 1, & \text{kui } x > r. \end{cases}$$

Leiame esmalt $X$ tihedusfunktsiooni:

$$\frac{d}{dx}\frac{x^2}{r^2} = \frac{2x}{r^2}.$$

Seega:

$$f(x) = F'(x) = \frac{2x}{r^2}, \text{ kui } 0 < x \leq r, \quad (0 \text{ mujal})$$

Nüüd:

$$EX = \int_0^r x\frac{2x}{r^2}dx = \frac{2}{r^2}\int_0^r x^2 dx = \frac{2x^3}{3r^2}\Big|_0^r = \frac{2}{3}r.$$

Seega keskmiselt jääb tabamus $\frac{2}{3}$ raadiuse kaugusele keskpunktist.

**Pideva juhusliku suuruse dispersioon.**

Dispersiooni üldine definitsioon on sama igat tüüpi juhuslike suuruste korral.

Definitsioon. Juhusliku suuruse $X$ dispersiooniks nimetatakse arvu:

$$DX = E(X - EX)^2.$$

Pideva juhusliku suuruse dispersiooni saab arvutada kui:

$$DX = \int_{-\infty}^{\infty} (x - EX)^2 f_X(x) dx.$$

Nagu eelnevalt oleme õppinud, saame dispersiooni leidmisel kasutada ka alternatiivset valemit:

$$DX = EX^2 - (EX)^2,$$

kusjuures pideva juhusliku suuruse korral:

$$EX^2 = \int_{-\infty}^{\infty} x^2 f_X(x) dx.$$

### 3.6.2 Lihtsad pidevad jaotused: ühtlane jaotus ja eksponentjaotus.

Nägime, diskreetsete juhuslike suuruste korral saame eristada parameetrilisi diskreetseid jaotuseid, kus konkreetne jaotus on määratud tõenäosusfunktsiooni üldkujuga (mis omakorda sisaldab parameetreid, mille väärtused määravad jaotuse täpsed omadused). Samamoodi leidub ka palju pidevaid jaotuseid, mis on määratud kas jaotus- või tihedusfunktsiooni üldkujuga (pideva juhusliku suuruse korral saame alati jaotusfunktsioonist tihedusfunktsiooni tuletada ja vastupidi) ja mis sobivad kasutamiseks erinevates praktilistes olukordades. Esmalt tutvume kahe lihtsama jaotusega, ühtlase ja eksponentjaotusega.

#### Ühtlane jaotus.

**Definitsioon.** Öeldakse, et juhuslik suurus $X$ on ühtlase jaotusega lõigus $[a,b]$, $X \sim U(a,b)$, kui tema tihedusfunktsioon on

$$f_X(x) = \begin{cases} \dfrac{1}{b-a}, & \text{kui } x \in [a,b] \\ 0, & \text{muidu.} \end{cases}$$

Ühtlane jaotus on kõige lihtsam pidev jaotus – tema parameetriteks on lõigu $[a,b]$ otspunktid ja juhuslik suurus $X$ võib võtta väärtusi ühesuguse tõenäosusega kogu lõigu ulatuses.

Ühtlase jaotuse omadused on veel:

- Tähistus: $X \sim U(a,b)$. Jaotuse parameetrid: $a, b \in \mathbb{R}$.
- Ühtlase jaotuse jaotusfunktsioon:

$$F_X(x) = \begin{cases} 0, & \text{kui } x < a, \\ \dfrac{x-a}{b-a}, & \text{kui } a \le x < b, \\ 1, & \text{kui } x \ge b. \end{cases}$$

- Keskväärtus: $EX = \dfrac{a+b}{2}$. (Lõigu $[a;b]$ keskpunkt.)
- Dispersioon: $DX = \dfrac{(b-a)^2}{12}$.

#### Eksponentjaotus.

- Tähistus: $X \sim Exp(\lambda)$. Jaotuse parameeter $\lambda > 0$.
- Iseloomustus: sageli kasutusel kui kahe sündmuse vahelise ajavahemiku jaotus, kui sündmused toimuvad ühtlase intensiivsusega.
- Eksponentjaotuse tihedusfunktsioon:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{kui } x \ge 0; \\ 0, & \text{kui } x < 0. \end{cases}$$

- Jaotusfunktsioon:

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & \text{kui } x \ge 0; \\ 0, & \text{kui } x < 0. \end{cases}$$

- Keskväärtus: $EX = \dfrac{1}{\lambda}$.

- Dispersioon: $DX = \frac{1}{\lambda^2}$.
- Eksponentjaotuse oluline omadus: "mälu puudumine":

  $P(X > x + d|X > x) = P(X > d), \quad \forall d > 0$

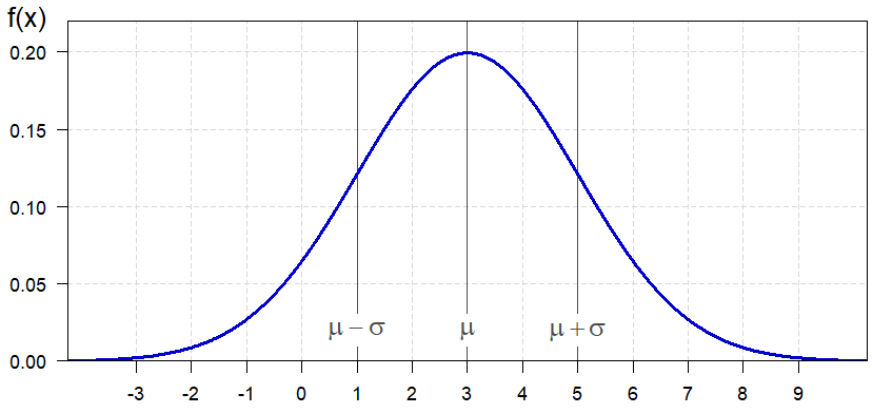
**Näide 38.** Mari töötab telefoninõustajana ühes firmas, kus ta võtab vastu klientide telefonikõnesid. Keskmiselt saab ta 100 kõnet 8-tunnise tööpäeva jooksul. Ta peab 5 minutit ära käima ja loodab et vahepeal kõnesid ei tule. Mis on tõenäosus, et nii lähebki, st. 5 minuti jooksul ei tule ühtegi kõnet?

**Lahendus:**
Sellele küsimusele saame vastata, kui eeldame, et kõned saabuvad sama intensiivsusega kogu päeva jooksul. Sellisel juhul on ajavahemik kahe kõne vahel (aga ka aeg päeva algusest esimese kõneni ning aeg suvalisest hetkest järgmise kõneni) eksponentjaotusega.

- Olgu $X$ kahe kõne vaheline aeg minutites. Et tööpäevas on $8 \times 60 = 480$ minutit, siis leiame, et keskmiselt tuleb üks kõne iga $480/100 = 4{,}8$ minuti tagant.
- Teistpidi võib öelda, et keskmine kõnede arv 1 minuti kohta on $100/480 \approx 0{,}21$.
- Seega on $X$ eksponentjaotusega ning jaotuse parameetriks ehk intensiivsuseks on $\lambda = 0{,}21$, ehk kirjutame, et $X \sim Exp(0{,}21)$.
- Kasutades eksponentjaotuse jaotusfunktsiooni, leiame, et:

  $$P(X > 5) = 1 - F(5) = e^{-0{,}21*5} \approx 0{,}35$$

  ehk tõenäosus, et 5 minuti jooksul ei tule ühtegi kõnet, on 0,35.
- Nn mälu puudumise omaduse tõttu teame, et see tõenäosus ei sõltu sellest, kas tegu on päeva esimese 5 minutiga või hoopis tööpäeva viimase 5 minutiga või sellega, kas eelnenud 5 minuti jooksul on mõni kõne tulnud või mitte.
- Kahe kõne vahelise ajavahemiku keskväärtuseks on: $EX = \frac{1}{\lambda} \approx 4{,}8$ ja dispersiooniks $DX = \frac{1}{\lambda^2} \approx 22{,}7$. Standardhälve on seega $\sigma = \sqrt{DX} = EX \approx 4{,}8$.




Joonis 3.4: Normaaljaotuse $N(3,2)$ tihedusfunktsioon.

### 3.6.3 Normaaljaotus.

Normaaljaotus on jaotus, mida saab vaieldamatult lugeda kõige olulisemaks pidevaks jaotuseks. Selle olulisus saab selgemaks ülejäänud kursuse jooksul, kui tutvume nii tsentraalse piirteoreemiga kui selle olulisusega levinud statistikameetodite juures.

**Definitsioon.** Öeldakse, et $X$ on normaaljaotusega juhuslik suurus, $X \sim \mathcal{N}(\mu, \sigma)$, kui tema tihedusfunktsioon on:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

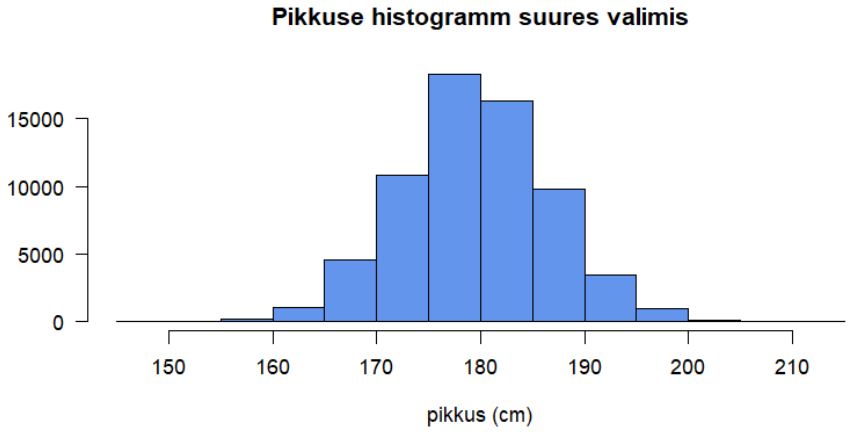
kus $-\infty < \mu < \infty$ ja $\sigma > 0$ on jaotuse parameetrid.

Normaaljaotuse tihedusfunktsiooni graafik on toodud joonisel 3.4. Näeme, et tegemist on sümmeetrilise jaotusega, millel on 2 parameetrit: $\mu$ ja $\sigma$. Tihedusfunktsiooni uurides näeme, et funktsioon saavutab maksimumi siis, kui $e^{-\frac{(x-\mu)^2}{2\sigma^2}} = e^0 = 1$, ehk kui $x = \mu$ (sest muude $x$ väärtuste korral on $e$ astendatud alati negatiivse arvuga ja seega on astendamise tulemus väiksem kui 1). Selgub, et parameeter $\mu$ ongi normaaljaotusega juhusliku suuruse korral nii keskväärtuseks kui mediaaniks.

Andmeanalüüsis puutume tihti kokku andmetega, mille jaotus sarnandeb normaaljaotusega – sellised on nt mõõtmistulemused bioloogias (või ka füüsikas, kui varieeruvus on telkkinud mõõtmisvea poolt) aga ka muudes valdkondades. Joonisel 3.5 on toodud meeste pikkuse histogramm suures valimis (TÜ Eesti geenivaramu kohort) – näeme, et histogrammi kuju sarnaneb normaaljaotuse tihedusfunktsiooni kujule ja seega võib arvata, et nende andmete kirjeldamiseks sobib normaaljaotus.

Normaaljaotuse tihedusfunktsiooni iseloomustavad järgmised omadused:

1. Tihedus $f(x)$ on sümmeetriline $\mu$ suhtes.
2. Tihedusfunktsiooni piirväärtused: $\lim_{x \to \pm\infty} f(x) = 0$.
3. Funktsiooni käänupunktid on $x = \mu \pm \sigma$.
4. Funktsiooni maksimum on:
$$\max f(x) = f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}.$$




Joonis 3.5: Meeste pikkuse histogramm TÜ Eesti geenivaramu kohordi põhjal.

### Normaaljaotuse keskväärtus ja dispersioon

Normaaljaotuse keskväärtuse ja dispersiooni leidmine integreerimise teel väga keeruline. (Vt. K. Pärna õpikust lk 99). (Et keskväärtus on $\mu$, tuleneb juba ka funktsiooni sümmeetrilisusest.)

$$EX = \int_{-\infty}^{\infty} x \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \ldots = \mu$$

Osutub, et teine parameeter, $\sigma$, on normaaljaotuse standardhälve ja seega dispersioon on $\sigma^2$. Ka seda saab näidata integreerides, kasutades sobivalt valitud muutujavahetust.

$$DX = E(X - EX)^2 = \int_{-\infty}^{\infty} (x-\mu)^2 \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \ldots = \sigma^2$$

Leidmaks tõenäosuseid $P(X \leq x)$ või $P(a|X \leq b)$ normaaljaotusega juhusliku suuruse korral, oleks meil vaja leida jaotusfunktsioon, ehk:

$$F(x) = \int_{\infty}^{x} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y-\mu)^2}{2\sigma^2}} dy.$$

Selgub, et seda integraali polegi kuigi lihtne leida ja peaks kasutama numbrilise integreerimise abi. Reaalsuses pole seda siiski vaja tänapäeval teha, sest esiteks on vastavad arvutused implementeeritud enamikesse andmeanalüüsi tarkvaradesse, kuid saame hakkama ka ilma arvutita, kui kasutame standardse normaaljaotuse tabeleid.

### Standardne normaaljaotus

**Definitsioon.** Normaaljaotust parameetritega $\mu = 0$ ja $\sigma = 1$ nimetatakse standardseks normaaljaotuseks (tähist. $\mathcal{N}(0,1)$).
Standardse normaaljaotuse tihedusfunktsioon on:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty \leq x \leq \infty$$

Selgub, et suvalist normaaljaotusega juhuslikku suurust saab teisendada standardse normaaljaotuse kujule.

Olgu $X$ normaaljaotusega juhuslik suurus: $X \sim \mathcal{N}(\mu,\sigma)$. Kui juhuslik suurus $Z$ on defineeritud nii, et:

$$Z = \frac{X - \mu}{\sigma}, \quad \text{siis } Z \sim \mathcal{N}(0,1).$$

(vt tõestust loengu 7 slaidilt nr 15)

Seega piisab, kui meil on arvutatud (tabuleeritud, lähenduste abil arvutitarkvarasse programmeeritud,. . . ) standardse normaaljaotuse jaotusfunktsiooni väärtused ja nende abil saame leida igasugusele normaaljaotusega juhuslikule suurusele vastavaid tõenäosuseid (kujul $P(X < a)$, $P(X \geq b)$, $P(a \leq X < b)$, jne.)

Standardse normaaljaotuse jaotusfunktsiooni tähistatakse $\Phi(x)$ ja ta on defineeritud kui:

$$\Phi(x) = P(Z \leq x) = \int_0^x frac1\sqrt{2\pi}e^{-\frac{y^2}{2}}\,dy.$$

Et standardse nornaaljaotuse tihedus on sümmeetriline 0 ümber, siis kehtib standardse normaaljaotuse korral, et $\Phi(-x) = P(Z \leq -x) = P(Z > x) = 1 - P(Z \leq x)$. Seega piisab, kui me teame $\Phi(x)$ väärtusi vaid $x \geq 0$ korral. Tabelis 3.5 on toodud $\Phi(x)$ väärtused $0 \leq x \leq 3$ korral, sammuga 0,01. Tabeli lugemisel kasutame järgmist algoritmi.

**$\Phi(x)$ väärtuste leidmine tabeli põhjal.**

Paneme tähele, et tabelit saab kasutada $x$ väärtuste korral, mis on esitatud kuni 2 kümnendkoha täpsusega. Kui on vaja suuremat täpsust, siis võib kasutada kas arvutitarkvara (sh veebikalkulaatoreid) või ka lineaarset interpoleerimist sellesama tabeli abil. Praktikas pole enamasti nii suurt täpsust vaja.

Seega $\Phi(x)$ leidmiseks:

1. Leia tabeli rida, mis vastab arvu $x$ absoluutväärtuse $|x|$ täisarvulisele osale ja esimesele kümnendkohale. (Nt arvu 1,28 korral rida tähisega 1,2).

2. Leia veerg, mis vastab $x$ teisele kümnendkohale (1,28 korral veerg tähisega 0.08).

3. Kui $x > 0$, siis vastavas reas ja veerus asuv arv ongi $\Phi(x)$ väärtus.

4. Kui $x < 0$, siis oled leidnud $\Phi(-x)$ väärtuse ja saad leida: $\Phi(x) = 1 - \Phi(-x)$.

**Näide 39.** Oletame, et leiti, et 18-24-aastaste naiste pikkus on ligikaudu normaaljaotusega keskväärtusega 168 ja standardhälbega 6. Seega on juhuslikult valitud noore naise pikkus vaadeldav juhusliku suurusena: $X \sim \mathcal{N}(168; 6)$. Leiame, kui suur on nende naiste osakaal, kes on pikemad kui 180cm.

**Lahendus:**
Kui $X \sim \mathcal{N}$(168,6), siis väärtuse 180 skaleeritud väärtus on: $Z = \dfrac{180 - \mu}{\sigma} = \dfrac{180 - 168}{6} = 2$. Seega peame leidma tõenäosuse $P(Z > 2)$, kus $Z$ on standardse normaaljaotusega. Ehk siis:

$$P(X > 180) = P(Z > 2) = 1 - P(Z \leq 2) = 1 - \Phi(2).$$

Väärtuse $\Phi(2)$ saame leida tabelist 3.5, kus leiame et see on 0,9772. Seega:

$$P(X > 180) = 1 - 0{,}9772 = 0{,}0228.$$

Saame, et otsitavaks tõenäosuseks on 0,0228 ehk ligikaudu 2,3%.

**Standardse normaaljaotuse jaotusfunktsioon** $\Phi(x)$

| | 0 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |

Tabel 3.5: Standardse normaaljaotuse jaotusfunktsiooni väärtuste tabel.

### 3.6.4 Jaotuse arvkarakteristikud

#### Jaotuse momendid

Juhusliku suuruse jaotuse arvkarakteristikuteks nimetatakse erinevaid jaotust iseloomustavaid arvulisi näitajaid. Siiani oleme tutvunud jaotuse keskväärtuse ja dispersiooniga ($EX$ ja $DX$). Dispersiooni arvutamise käigus oli vahel otstarbekas leida ja juhusliku suuruse ruudu keskväärtus $EX^2$. Selgub, et need on erijuhud jaotuse momentidest.

**Definitsioon.** Juhusliku suuruse $m$-ndat järku momendiks nimetatakse arvu $E(X^m)$, $m-$ndat järku keskmomendiks (tsentraalseks momendiks) nimetatakse arvu $E(X - EX)^m$. (Dispersioon on teist järku keskmoment.)

Tähistame keskmomendi kui $\mu_m = E(X - EX)^m$.

Suhet $\frac{\mu_3}{\sigma^3}$ nimetatakse jaotuse asümmeetria kordajaks (*ingl. skewness*).

Sümmeetrilise jaotuse korral $\frac{\mu_3}{\sigma^3} = 0$.

#### Jaotuse paiknemist (keskmist) iseloomustavad arvkarakteristikud

Keskväärtus EX on ainult üks nn jaotuse paiknemise ehk nn keskmise tendentsi näitajatest. Sümmeetrilise jaotuse korral on keskväärtusele lähedased juhusliku suuruse väärtused tõenäolisemad kui need mis on keskväärtusest kaugemal. Kui jaotus pole sümmeetriline, siis võib vahel olla kasu ka teistest näitajatest, nagu näiteks mood ja mediaan.

**Mood.** Pideva juhusliku suuruse $X$ moodiks nimetatakse sellist väärtust $x$, mille korral on $X$ tihedusfunktsiooni $f(x)$ väärtus saavutab kas globaalse või lokaalse maksimumi. Diskreetse juhusliku suuruse moodiks on kõige tõenäoseim väärtus (kui mitu järjestikust väärtust on kõige tõenäolisemad, siis võetakse nende keskmine).

Mood on väärtus, mille läheduses on juhusliku suuruse väärtuste tõenäosus suurem kui sealt kaugemal.

**Mediaan.** Juhusliku suuruse mediaaniks nimetatakse arvu $\mathrm{med}(X)$ (kasutatakse ka tähistusi $\mathrm{med}X$ või $MeX$ või $M(X)$, vms.), mille korral:

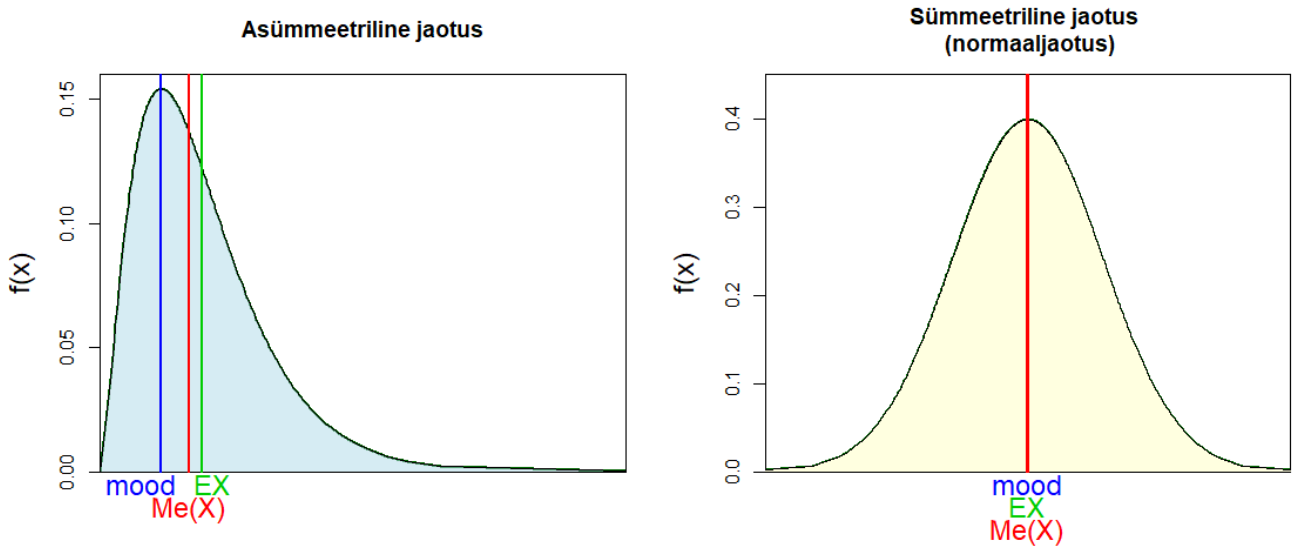
$$P(X \leq \mathrm{med}X) \geq \frac{1}{2} \quad \text{ja} \quad P(X \geq \mathrm{med}X) \geq \frac{1}{2}$$

Pideva juhusliku suuruse korral $P(X \leq \mathrm{med}X) = P(X \geq \mathrm{med}X) = \frac{1}{2}$. Seega on mediaan nn keskmine väärtus, millest nii suuremaid kui väiksemaid väärtuseid esineb tõenäosusega 50%.

Sümmeetrilise jaotuse korral on mood, mediaan ja keskväärtus võrdsed, kuid ebasümmeetrilise jaotuse korral võivad nad kõik erinevad olla (vt. joonist 3.6).

#### Kvantiilid.

Mediaani võib nimetada ka jaotuse 0,5−kvantiiliks. Üldisemalt:




Joonis 3.6: Mediaan, mood ja keskväärtus asümmeetrilise ja sümmeetrilise jaotuse korral.

- Pideva juhusliku suuruse $X$ $\alpha$-kvantiiliks nimetatakse arvu $q_\alpha$, mille korral $P(X \leq q_\alpha) = \alpha$.
- Täiendkvantiil $\bar{q}_\alpha$ on arv, mille korral $P(X > \bar{q}_\alpha) = \alpha$

Mõningatel kvantiilidel on eraldi nimetused:

mediaan ehk $med(X) = q_{0,5}$

kvartiilid ehk $Q_1 = q_{0,25}$, $Q_2 = q_{0,5}$ (mediaan) ja $Q_3 = q_{0,75}$. (Kvartiilid jagavad jaotuse neljaks.) Kvartiile $Q_1$ ja $Q_3$ nimetatakse vahel ka alumiseks ja ülemiseks kvartiiliks.

kvintiilid, sekstiilid, detsiilid, jne on kvantiilid, mis jagavad jaotuse vastavalt viieks, kuueks või 10-ks.

NB! Sümmeetrilise jaotuse korral paiknevad kvantiilid $q_\alpha$ ja vastavad täiendkvantiilid $\bar{q}_\alpha$ mediaani suhtes sümmeetriliselt.

Juhusliku suuruse $X$ $\alpha$-kvantiili $q_\alpha$ leidmiseks on vaja avaldada $x$ seosest:

$$F_X(x) = \alpha.$$

($x$ väärtus mis seda võrdust rahuldab, ongi $q_\alpha$)
Analoogselt leiame täiendkvantiili $\bar{q}_\alpha$ kui $x$ väärtuse, mis rahuldab seost: $1 - F_X(x) = \alpha$.
Kui $X$ jaotuse kohta on teada vaid tihedusfunktsioon $f_X(x)$, siis on kvantiili leidmiseks vaja avaldada $x$ võrdusest:

$$\int_{-\infty}^{x} f_X(u)du = \alpha.$$

**Näide 40.** Eksponentjaotuse mediaan ja kvantiilid.
Eksponentjaotuse $\alpha$-kvantiil on leitav, kui avaldada $x$ võrdusest: $F(x) = 1 - e^{-\lambda x} = \alpha$. Leiame, et:

$$x = q_\alpha = -\frac{\ln(1-\alpha)}{\lambda}.$$

Seega saame näiteks mediaani:

$$\text{med}(X) = -\frac{\ln(0{,}5)}{\lambda} = \frac{\ln(2)}{\lambda} \approx \frac{0{,}69}{\lambda}.$$

Eksponentjaotuse täiendkvantiili leidmiseks peame avaldama $x$ võrdusest $1 - F(x) = e^{-\lambda x} = \alpha$ ja seega leiame, et

$$\bar{q}_\alpha = -\frac{\ln(\alpha)}{\lambda}.$$

**Näide 41.** Tuleme tagasi näite 38 juurde, kus klienditelefonile tulevate kõnede vaheline aeg oli eksponentjaotusega: $X \sim Exp(0{,}21)$.

- Leidsime, et $X$ keskväärtus on $\frac{1}{0{,}21} \approx 4{,}8$, ehk keskmiselt jääb kahe kõne vahele 4,8 minutit.
- Nüüd leiame ka mediaani:
$$\text{med}(X) \approx \frac{0{,}69}{\lambda} \approx 3{,}3 \text{ minutit.}$$
Seega võib öelda, et kuigi keskmiselt on kahe kõne vaheline aeg peaaegu 5 minutit, järgneb umbes pooltel kordadel uus kõne kuni 3,3 minuti jooksul pärast eelmist.
- Leiame ka kvartiilid:
$$q_{0{,}25} = -\frac{\ln(0{,}75)}{0{,}21} \approx 1{,}4 \quad \text{ja} \quad q_{0{,}25} = -\frac{\ln(0{,}25)}{0{,}21} \approx 6{,}6.$$
Seega saabub 25% kõnedest kuni 1,4 minutit pärast eelmist, kuid samas jääb 25% juhtudest kahe kõne vaheline aeg pikemaks kui 6,6 minutit.
- Kui keskväärtuse põhjal võis ehk antud näidet isegi realistlikuks pidada (?), siis mediaan ja kvartiilid iseloomustavad, et selliste parameetrite korral on telefoninõustaja tööpäev ehk ebarealistlikult intensiivne. (Võimalik, et realistlikum on mõni väiksem $\lambda$ väärtus.)

**Normaaljaotuse kvantiilid ja kahe sigma reegel.**

Standardse normaaljaotuse korral saame kvantiili $q_\alpha$ leidmiseks kasutada tabelit 3.5 (võrreldes jaotusfunktsiooni väärtuse leidmisega kasutame tabelit nüüd tagurpidi):

- Kui $\alpha \geq 0{,}5$, siis tuleb otsida tabelist jaotusfunktsiooni väärtus, mis on võimalikult lähedane $\alpha$-le, ning lugeda rea ja veeru tähistustest arv $q_\alpha$.
- Kui $\alpha < 0{,}5$, siis leiame tabeli abil väärtusele $1-\alpha$ vastava arvu $q_{1-\alpha}$ ja jaotuse sümmeetrilisuse tõttu leiame: $q_\alpha = -q_{1-\alpha}$.

Selge, et standardse normaaljaotuse mediaan $q_{0{,}5} = 0$. Leiame tabeli abil kvartiilid: $q_{0{,}75} = 0{,}67$ ja seega $q_{0{,}25} = -0{,}67$.
Samuti saame leida näiteks: $q_{0{,}95} = 1{,}64$ ja $q_{0{,}975} = 1{,}96$.

**Normaaljaotusega $X \sim \mathcal{N}(\mu, \sigma)$ juhusliku suuruse kvantiilide leidmine:**

- Arvestades et suvalise normaaljaotusega juhusliku suuruse $X \sim \mathcal{N}(\mu, \sigma)$ korral nn skaleeritud suurus $Z = (X - \mu)/\sigma$ standardse normaaljaotusega, siis suvalise $X$ kvantiili $q_{X,\alpha}$ korral saame, et:
$$\frac{q_{X,\alpha} - \mu}{\sigma} = q_{Z,\alpha} \text{ ja seega } q_{X,\alpha} = \sigma q_{Z_\alpha} + \mu.$$

- Saame, et $X$ kvartiilid on leitavad kui $\mu - 0{,}67\sigma$ ja $\mu + 0{,}67\sigma$.
- Seega jääb 50% normaaljaotusega juhusliku suuruse $X$ väärtustest vahemikku $\mu \pm 0{,}67\sigma$
- Samamoodi leiame, et 90% $X$ väärtustest jääb vahemikku $(q_{0{,}05}; (q_{0{,}95})$ ehk vahemikku $\mu \pm 1{,}64\sigma$.
- 95% vahemikku $X$ väärtustest jääb vahemikku $(q_{0{,}025}; (q_{0{,}0975})$ ehk $\mu \pm 1{,}96\sigma$ ehk ligikaudu $\mu \pm 2\sigma$.

Reegel, et 95% normaaljaotusega juhusliku suuruse väärtustest jääb maksimaalselt $2\sigma$ kaugusele keskväärtusest $\mu$, kannab kahe sigma reegli nimetust.

**Näide 42.** Konveierilt tulevad piimapakid, mille pakendile on kirjutatud 1 L. Piimapakkide tegelikud mahud aga varieeruvad st jaotuvad normaalselt standardhälbega 1 ml. Kui suur peab olema paki keskmine maht, et alakaalulise paki (ehk "petta") saaks ainult 1% ostjaid?

**Lahendus:**
Olgu piimapaki kaal $X \sim \mathcal{N}(\mu, 1)$. Meil on vaja leida selline $\mu$ väärtus, et $P(X < 1000) = 0{,}01$. Et $\sigma = 1$, siis $Z = \dfrac{X - \mu}{\sigma} = X - \mu$ on standardse normaaljaotusega.
Saame arvetada, et $P(X < 1000) = P(X - \mu < 1000 - \mu) = P(Z < 1000 - \mu)$.
Leiame standardse normaaljaotuse 0,01-kvantiili $q_{0{,}01}$, arvestades, et $q_{0{,}01} = -q_{0{,}99}$. Tabelis 3.5 asub arvule 0,99 kõige lähem väärtus reas ja veerus, mis vastab arvule 2,33.
Saame, et $q_{0{,}01} \approx -2{,}326$.

Seega $P(Z < -2{,}33) = 0{,}01$. Siit $1000 - \mu \approx -2{,}33$ ja $\mu = 1000 + 2{,}326 = 1002{,}33$ ehk **keskmine piimapaki peaks olema** 1002,33**ml ehk** 1,00233 **liitrit**.

## 3.7 Seosed juhuslike suuruste vahel. Mitmemõõtmelised juhuslikud suurused ja jaotused

### 3.7.1 Juhusliku vektori mõiste, juhuslike suuruste sõltumatus.

Statistilise andmeanalüüsi üheks peamiseks ülesandeks on seoste leidmine andmetes. Tõenäosuslikult vastab sellele seos juhuslike suuruste vahel. Seoste otsimine andmetes on võimalik siis, kui oskame esmalt defineerida, mida me seose all mõtleme, vastavate juhuslike suuruste kaudu.

**Juhusliku vektori mõiste.** Kui m juhuslikku suurust $X_1, X_2, \ldots, X_m$ on määratud ühes ja samas katses, siis vektorit $(X_1, X_2, \ldots, X_m)$ nimetatakse $m$-mõõtmeliseks juhuslikuks vektoriks.

Diskreetsete juhuslike suuruste juures tutvusime põgusalt ka kahe mitmemõõtmelise diskreetse jaotusega (ehk diskreetse juhusliku vektori jaotusega): üldine hüpergeomeetriline jaotus ja multinoomjaotus.

Pidevate juhuslike suuruste korral vaatleme selles kursuses vaid kahemõõtmelisi juhuslikke vektoreid, nt. $(X, Y)$.

Juhusliku vektori $(X,Y)$ jaotusfunktsiooniks nimetatakse funktsiooni $F_{X,Y}(x,y) = P(X \leq x, Y \leq y)$.

### 3.7.2 Pidev kahemõõtmeline juhuslik vektor ja ühistiheduse mõiste.

**Definitsioon.** Juhuslikku vektorit $(X,Y)$ nimetatakse pidevaks, kui tema jaotusfunktsioon avaldub kujul:

$$F_{X,Y}(x,y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(u,v)dudv.$$

Funktsioon $f_{X,Y}(u,v)$ on juhusliku vektori $(X,Y)$ tihedusfunktsioon (ka lihtsalt ühistihedus).

Ühistiheduse põhiomadused:

1. $f_{X,Y}(u,v) \geq 0$.
2. $\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f_{X,Y}(u,v)dudv = 1$.

Nn ristkülikuse sattumise tõenäosus avaldab kujul:

$$P(a < X \leq b, c < Y \leq d) = \int_{a}^{b}\int_{c}^{d} f_{X,Y}(u,v)dudv$$

NB! Kui ühe juhusliku suuruse korral avaldus tõenäosus vahemikku kuuluda kõveraaluse pindalana, siis nüüd on tegu ruumalaga.

Üldiselt: tasandilisse piirkonda $B \subset \mathbb{R}^2$ sattumise tõenäosus:

$$P[(X,Y) \in B] = \int\int_{B} f(u,v)dudv$$

**Kahemõõtmeline ühtlane jaotus.**

Kahemõõtmelise ühtlase jaotuse korral on meil tegemist ristkülikuga.

Kahemõõtmeline ühtlane jaotus tasandi piirkonnas $D$ (pindalaga $S_D$) on defineeritud tihedusfunktsiooniga:

$$f_{X,Y}(x,y) = \begin{cases} \frac{1}{S_D}, & \text{kui } (x,y) \notin D \\ 0, & \text{kui } (x,y) \in D \end{cases}$$

Tõenäosuste arvutamine kahemõõtmelise (aga ka ühe- või kolmemõõtmelise) ühtlase jaotuse korral taandub geomeetrilise tõenäosuse põhimõttele.

**Näide 43.** Väljakule suurusega $40 \times 50m$ kaotatakse võti. Kui suur on tõenäosus, et võti ei asu kaugemal kui 2m väljaku servast, kui ta võis sama tõenäosusega kaduda ükskõik millises väljaku punktis?

**Lahendus 1.** Väljaku pindala on $40 \cdot 50 = 2000m^2$. Geomeetrilise tõenäosuse põhimõttel leiame, et väljaku seesmise osa (rohkem kui 2m servast) pindala on $(40-4)\cdot(50-4) = 36 \cdot 46 = 1656m^2$, seega kuni $2m$ kaugusele servast jääva osa pindala on $2000 - 1656 = 344m^2$ ning otsitav tõenäosus on seega $\frac{344}{2000} = 0{,}172$.

**Lahendus 2.** Võtme asukohakoordinaadid (määrates nullpunkti ühte väljaku nurka) on määratud kahemõõtmelise juhusliku vektoriga $(X,Y)$, mis on kahemõõtmelise ühtlase jaotusega ristkülikus $[0;40] \times [0;50]$. Seega tõenäosus, et võti asub rohkem kui 2m kaugusel servast, on:

$$P(2 < X \leq 38, 2 < Y \leq 48) = \int_{2}^{38}\int_{2}^{48} \frac{1}{2000}dudv = \frac{1}{2000}(38-2)\cdot(48-2) = \frac{36\cdot 46}{2000},$$

aga et otsime vastandsündmuse tõenäosust, siis:

$$P(X \leq 2 \text{ või } X > 38, Y \leq 2 \text{ või } Y > 48) = 1 - \frac{36 \cdot 46}{2000} = \frac{344}{2000}.$$

ehk jõuame täpselt sama arvutustehteni ja sama tulemuseni nagu geomeetrilist tõenäosust kasutades.

Selles näites võib tunduda integreerimisega vaevanägemine mõttetu -– siiski on see nii vaid kõige lihtsama, st ühtlase jaotuse korral ja üldjuhul on siiski vaja tõenäosuste leidmiseks tihedus- või jaotusfunktsiooni kasutada.

**Juhuslike suuruste sõltumatus üldisel ja pideval juhul.**

Uurimaks seoseid juhuslike suuruste vahel on esmalt vaja defineerida seose puudumine, ehk sõltumatus.

**Definitsioon.** Juhuslikke suuruseid $X$ ja $Y$ nimetatakse sõltumatuteks, kui:

$$F_{X,Y}(x,y) = F_X(x) \cdot F_Y(y)$$

- Samaväärne valem on $P(X \leq x, Y \leq y) = P(X \leq x) \cdot P(Y \leq y)$. Seega, juhuslikud suurused $X$ ja $Y$ on sõltumatud, kui sündmused $(X \leq x)$ ja $(Y \leq y)$ on sõltumatud iga $x$ ja $y$ korral.
- See definitsioon kehtib nii pidevate kui diskreetsete juhuslike suuruste korral. Tõepoolest, kui $X$ ja $Y$ on diskreetsed juhuslikud suurused, siis sõltumatuse definitsioonist järeldub, et

$$P(X = x_i, Y = y_i) = P(X = x_i) \cdot P(Y = y_i)$$

Pideva kahemõõtmelise juhusliku suuruse korral järeldub sõltumatuse üldisest definitsioonist, et pidevad juhuslikud suurused X ja Y on sõltumatud parajasti siis, kui kehtib

$$f_{X,Y}(x,y) = f_X(x) f_Y(y).$$

**Näide 44.** Olgu juhuslik vektor $(X, Y)$ ühtlase jaotusega ristkülikus $[a,b] \times [c,d]$. Kas saab näidata, et siis komponendid $X$ ja $Y$ on sõltumatud, ning $X \sim U(a,b)$ ja $Y \sim U(c,d)$?

**Lahendus:**
Kui $X$ või $Y$ väärtused asuvad väljaspool ristkülikut, siis $f_{X,Y}(x,y) = 0 = f_X(x) \cdot f_Y(y)$. Ristkülikus aga:

$$f_{X,Y}(x,y) = \frac{1}{S_D} = \frac{1}{(b-a) \cdot (d-c)} = \frac{1}{(b-a)} \cdot \frac{1}{(d-c)} = f_X(x) f_Y(y).$$

**Kahe pideva juhusliku suuruse funktsiooni keskväärtus.**

Olgu meil pidev kahemõõtmeline juhuslik vektor $(X,Y)$ ja funktsioon $g(X,Y) \to \mathbb{R}$. (Näiteks võib olla $g(X,Y) = X + Y$ või $g(X,Y) = XY$). Siis keskväärtus $Eg(X,Y)$ avaldub kui:

$$Eg(X,Y) = \int_{\infty}^{\infty} \int_{\infty}^{\infty} g(x,y) f_{X,Y}(x,y) dx dy.$$

On lihtne näidata, et ka pidevate juhuslike suuruste korral kehtib, et kui $X$ ja $Y$ on sõltumatud, siis $EXY = EX \cdot EY$.

### 3.7.3 Kovariatsioon ja korrelatsioon üldisel juhul.

Kui juhuslikud suurused ei ole sõltumatud, siis saab nendevahelist seost iseloomustada kovariatsiooni ja korrelatsiooni abil, mis on pidevate juhuslike suuruste korral defineeritud samamoodi nagu diskreetsete juhuslike suuruste korral.

Juhuslike suuruste $X$ ja $Y$ kovariatsiooniks nimetatakse suurust:

$$\operatorname{cov}(X,Y) = E(X - EX)(Y - EY),$$

ning samuti kehtib alternatiivne valem $\operatorname{cov}(X,Y) = E(XY) - EX \cdot EY$.

Korrelatsioonikordaja on samuti defineeritud kui:

$$\rho(X,Y) = \frac{\operatorname{cov}(X,Y)}{\sigma_X \sigma_Y},$$

kusjuures $-1 \leq \rho(X,Y) \leq 1$.

Kovariatsiooni leidmisel pideval juhul saame kasutada eeltoodud valemit $Eg(X,Y)$ leidmiseks:

$$\operatorname{cov}(X,Y) = \int_{\infty}^{\infty} \int_{\infty}^{\infty} (x - EX)(x - EY) f_{X,Y}(x,y) dx dy$$

või

$$\operatorname{cov}(X,Y) = \int_{\infty}^{\infty} \int_{\infty}^{\infty} xy f_{X,Y}(x,y) dx dy - EX \cdot EY.$$

# Peatükk 4

# Tõenäosusteooria piirteoreemid

1. Poissoni piirteoreem (5. loeng). Olgu $X_1, X_2, \ldots$ binoomjaotusega juhuslikud suurused, $X_n \sim B(n,p_n)$ ja leidku aset koondumine $EX_n = np_n \to \lambda > 0$. Siis binoomjaotuse tõenäosused koonduvad Poissoni jaotuse tõenäosusteks:
$$P(X_n = k) = C_n^k p_n^k (1-p_n)^{n-k} \to \frac{\lambda^k}{k!} e^{-\lambda},\ n \to \infty.$$
Praktikas tähendab see seda, et kui $X \sim B(n,p)$ ja $n$ on suur, kuid $p$ väike, nii et $np < 6$, siis võib eeldada, et $X$ on ligikaudu Poissoni jaotusega parameetriga $\lambda = np$. See teadmine muudab tõenäosuste arvutamise lihtsamaks.

2. Tsentraalne piirteoreem. Olgu $X_1, X_2, \ldots$ sõltumatud ja sama jaotusega juhuslikud suurused, nii et $EX_i = \mu$ ja $DX_i = \sigma^2 < \infty$ ning olgu $S_n = X_1 + X_2 + \ldots + X_n$. Ülesannete juures on oluline teada tsentraalse piirteoreemi järeldust, et:
$$\frac{S_n}{n} \sim AsN(\mu, \frac{\sigma}{\sqrt{n}}).$$
$AsN$ tähistab asümptootilist normaaljaotust ehk seda, et antud suurus koondub jaotuse järgi normaaljaotuseks. Seega kui $n$ on piisavalt suur, siis võib praktikas eeldada, et $\frac{S_n}{n}$ on ligikaudu normaaljaotusega.

3. Moivre-Laplace piirteoreem on tsentraalse piirteoreemi erijuht juhul kui $X_i$ on Bernoulli jaotusega, st $X_i \sim Be(p)$ ja seega $S_n \sim B(n,p)$. Et nüüd $\sigma^2 = DX_i = p(1-p)$, siis:
$$\frac{S_n - np}{\sqrt{np(1-p)}} \sim AsN(0,1)$$
ning samuti
$$S_n \sim AsN\big(np, \sqrt{np(1-p)}\big) \quad \text{ja} \quad \frac{S_n}{n} \sim AsN\big(p, \sqrt{\frac{p(1-p)}{n}}\big).$$
Praktikas tähendab see seda, et kui $n$ on suur ja $p$ ei ole 0 või 1 lähedal, nt $np(1-p) > 10$, siis võib binoomjaotuse tõenäosuste leidmisel kasutada normaaljaotust. Seda teadmist kasutame ka usaldusvahemiku leidmiseks osakaalule (suurte valimite korral).
Tuleb ka tähele panna, et binoomjaotus on diskreetne jaotus, kuid normaaljaotus pidev jaotus. Seetõttu tuleb tõenäosuste arvutamisel kasutada *pidevus-parandust*. Näiteks kui binoomjaotusega $Y$ korral soovime leida tõenäosust $P(Y = 10)$, siis normaaljaotusega lähendamisel peame leidma tõenäosuse $P(9{,}5 < Y \leq 10{,}5)$.

**Ülesanne 1.** 18-20-aastastel koroonaviirusega nakatunud noortel on tõenäosus haiglaravi vajamiseks 0,1% (Eesti andmed 2021-2022). Leia tõenäosus, et 5000 nakatunud 18-20-aastase noore hulgast: a) ei vaja mitte keegi haiglaravi; b) vajavad haiglaravi vähemalt 2 inimest.

**Ülesanne 2.** Olgu juhuslik valim $X_1, X_2, \ldots, X_{100}$, kusjuures $X_i$ on sõltumatud Poissoni jaotusega juhuslikud suurused $X_1 \sim Po(\lambda)$. Millega võrduvad valimikeskmise $\bar{X}$ keskväärtus ja dispersioon? Millise jaotusega on $\bar{X}$ *ligikaudu*? Milline võiks olla ligikaudne $(1-\alpha)\%$ usaldusvahemik üldkogumi parameetrile $\lambda$?

**Ülesanne 3.** Seemnete idanevus on 90%. Leia tõenäosus, et 900-st istutatud seemnest idaneb

1. vähemalt 800 seemet;
2. 790 kuni 830 seemet (kaasaarvatud).
3. täpselt 800 seemet.

# Peatükk 5

# Statistika põhimõisted

## 5.1 Üldkogum ja valim.

### Üldkogum ja valim. Valimi olulisemate arvkarakteristikute leidmine.

Olulisemad valiminäitajad, mida kursuse läbinu võiks osata leida, on:

**Valimikeskmine** $\bar{x}$ on konkreetse valimi väärtuste põhjal leitud aritmeetiline keskmine:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

**Valimidispersioon** $s^2$ (vahel ka $\hat{\sigma}^2$) on valimikeskmise suhtes arvutatud hälvete ruutude summa jagatuna $(n-1)$-ga:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Alternatiivne (ja tihti arvutuslikult lihtsam) valem valimidispersiooni arvutamiseks:

$$s^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right) = \frac{n}{n-1}(\overline{x^2} - \bar{x}^2), \qquad \text{kus} \quad \overline{x^2} = \frac{1}{n}\sum_{i=1}^{n} x_i^2$$

**Valimi standardhälve** on ruutjuur valimidispersioonist: $s = \sqrt{s^2}$.

**Valimi mediaan** leitakse kui järjestatud valimi keskpunkt – kas keskmise vaatluse väärtus järjestatud valimis (paarituarvulise valimisuuruse $n$ korral) või kahe keskmise vaatluse keskmine (paarisarvulise $n$ korral).

**Valimi mood** on kõige sagedamini esinev väärtus valimis.

**Ülesanne 1.** Juhusliku valimi väärtused on esitatud järgmise tabeli abil:

| $x_i$ | 1 | 2 | 3 | 4 | 6 |
|---|---|---|---|---|---|
| esinemiste arv | 26 | 9 | 8 | 7 | 1 |

Leida valimi keskväärtus, standardhälve, mood ja mediaan.

**Ülesanne 2.** Ühe valimi kohta esitati järgmised andmed: $n = 5$, $\bar{x} = 3{,}4$, mediaan $m = 3$, dispersioon $s^2 = 2{,}3$ ning miinimum (minimaalne väärtus valimis) 2. Sinna valimisse lisati veel viis vaatlust, kõik väärtusega 0. Esita kõik toodud näitajad uue valimi korral.

**Ülesanne 3.** Kooli õppejuht arvutas 29 abituriendi matemaatika keskmise hinde ja dispersiooni, ning sai tulemusteks vastavalt 3,98 ja 3,2. Hiljem andmeid üle kontrollides selgus, et ühe õpilase õppeaasta matemaatika keskmine hinne oli arvutustest kogemata välja jäetud. Pärast 30. õpilase matemaatika keskmise hinde lisamist selgus, et abiturientide matemaatika keskmine hinne oli 3,95. Leia valimisse lisatud 30. õpilase matemaatika keskmine hinne ja selle 30-elemendilise valimi dispersioon.

## 5.2 Objektid ja tunnused. Tunnuste tüübid.

## 5.3 Andmefail ja selle loomise põhimõtted.

## 5.4 Valimi jaotuse uurimine ja visualiseerimine.

### 5.4.1 Mittearvulised tunnused: sagedustabelid ja diagrammid

### 5.4.2 Arvulised tunnused ja nende jaotuse graafiline uurimine

### 5.4.3 Valimikeskmine ja teised keskmist iseloomustavad arvulised näitajad

## 5.5 Valimikeskmine ja teised valimi arvkarakteristikud kui juhuslikud suurused. Valimikeskmise ja valimist leitud osakaalu asümptootiline jaotus.

## 5.6 Usaldusvahemik valimikeskmisele ja valimist leitud osakaalule. Usaldusvahemiku leidmise üldised põhimõtted.

## 5.7 Hüpoteeside testimise üldised põhimõtted.

Olgu $\theta$ üks üldkogumi parameeter ja olgu $\hat{\theta}$ tema hinnang juhuvalimi põhjal. Lisaks olgu teada, et $n$ kasvades läheneb $\hat{\theta}$ jaotus normaaljaotusele. Seega on $\hat{\theta}$ asümptootilise normaaljaotusega. Olgu ka $\sigma_{th\hat{e}ta}$ hinnangu $\hat{\theta}$ standardhälve ehk standardviga. Sellisel juhul on statistik:

$$Z = \frac{\hat{\theta} - \theta}{\sigma_{th\hat{e}ta}}$$

asümptootilise normaaljaotusega ehk $Z \sim AsN(0,1)$.

Seda fakti kasutatakse enamike kaasaegses matemaatilises statistikas kasutusel olevate statistiliste testide puhul. Järgnevalt selgitamegi selliste testide põhimõtteid.

## Usaldusvahemik valimikeskmisele ja osakaalule

## Usaldusvahemik üldkeskmisele.

- Valimikeskmine $\bar{x}$ on nihketa hinnanguks üldkogumi keskväärtusele ehk üldkeskmisele $\mu$.
- Hinnangu $\bar{x}$ täpsust iseloomustab **keskväärtuse standardviga**, mis on leitav kui:

$$\hat{\sigma}_{\bar{x}} = \frac{s}{\sqrt{n}}.$$

  ($\hat{\sigma}_{\bar{x}}$ on hinnanguks valimikeskmise kui juhusliku suuruse standardhälbele).

- Tsentraalse piirteoreemi tõttu teame, et $n$ suurenedes läheneb valimikeskmise jaotus normaaljaotusele, ehk kirjutame $\bar{X} \sim AsN(\mu, \frac{\sigma}{\sqrt{n}})$. ($AsN$: asümptootiline normaaljaotus).
- Seetõttu saame leida **suurtes valimites** ($n > 50$) üldkeskmise $(1-\alpha)\cdot 100\%$ usaldusvahemiku kui:

$$I_\mu = \bar{x} \pm \bar{z}_{\frac{\alpha}{2}} \cdot \hat{\sigma}_{\bar{x}},$$

  kus $\bar{z}_{\frac{\alpha}{2}}$ on standardse normaaljaotuse $\frac{\alpha}{2}$- täiendkvantiil.

- **Väikese valimi** korral tuleb usaldusvahemiku leidmisel kasutada t-jaotuse täiendkvantiili, ehk:

$$I_\mu = \bar{x} \pm \bar{t}_{\frac{\alpha}{2},n-1} \cdot \hat{\sigma}_{\bar{x}}.$$

  Väikese valimi korral saab keskväärtusele sellisel moel usaldusintervalli leida aga vaid siis, kui saame eeldada ligikaudset normaaljaotust (kontrolltöö ülesannetes lugege see eeldus täidetuks, juhul kui pole eraldi mainitud).

**Ülesanne 1.** Ühte restorani olid veebilehel hinnanud 101 klienti, skaalas 1 kuni 5 punkti. Saadud punktide jaotus on toodud järgmises tabelis:

| Punkte | Isikuid |
|---|---|
| 1 | 6 |
| 2 | 5 |
| 3 | 12 |
| 4 | 38 |
| 5 | 40 |

1. Leia keskmine restoranile antud punktide arv, selle dispersioon ja standardhälve.
2. Leia keskväärtuse 95% usaldusvahemik.
3. Oletame, et väldid neid restorane, mille keskmine hinnang on alla 3,5 punkti. Kui restorani hinnanud 121 klienti saab pidada juhuvalimiks, kas siis on tõenäoline, et selle restorani tegelik keskmine hinnang on alla 3,5? (Otsusta usaldusvahemiku põhjal)
4. Oletame, et käid ise ka selles restoranis ja lisad veebilehele hinnanguks 4 punkti. Kommenteeri ilma arvutamata, kuidas muutuvad keskväärtus ja standardhälve, ning kas usaldusvahemik muutub kitsamaks, laiemaks või jääb samaks.

## Usaldusvahemik osakaalule.

- Üldkogumi osakaal $p$ on samal ajal ka Bernoulli jaotusega juhusliku suuruse keskväärtus, mille nihketa hinnanguks on vastav valimikeskväärtus, ehk valimist leitud osakaal $\hat{p} = \frac{k}{n}$, kus $n$ on objektide koguarv ja $k$ on huvipakkuvat tüüpi objektide arv (mille osakaalu soovitakse leida).
- Osakaalu $\hat{p}$ standardviga on leitav kui:
$$\hat{\sigma}_{\hat{p}} = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$
- **Suure valimi** korral saame leida $(1-\alpha)\cdot 100\%$ usaldusvahemiku üldkogumi osakaalule $p$ kui:
$$I_p = \hat{p} \pm \bar{z}_{\frac{\alpha}{2}} \cdot \hat{\sigma}_{\hat{p}}.$$
Loengus ja praktikumis tutvustati ka väikese valimi jaoks sobivat usaldusvahemikku. Kontrolltöös ja eksamil võib osakaalu usaldusvahemiku puhul alati eeldada, et valim on piisavalt suur ülaltoodud valemi kasutamiseks.

**Ülesanne 2.** Eesti kooliõpilaste tervisekäitumise uuringu (2022) valimis osales 781 13-aastast poissi, kellest oli ülekaalulisi 203.

1. Leia ülekaaluliste protsent ja selle 95% usaldusvahemik 13-aastaste poiste seas.
2. Vt järgmisi väiteid. Kas toodud andmed on kooskõlas mõlemaga, mitte kumbagiga või ühega neist (millisega?). Põhjenda oma vastust.
   - Ülekaaluliste osakaal 13-aastaste poiste seas võib ulatuda kolmandikuni.
   - Hinnanguliselt umbes veerand 13-aastastest poistest on ülekaalulised.
3. Kui ülekaaluliste osakaal on umbes 25%, siis kui suur peaks olema valim, et 95% usaldusintervall selle osakaalu hindamiseks oleks laiusega 0,04 (ehk siis ±2%)?

## Kahe keskmise/osakaalu võrdlemine usaldusvahemike abil

## Usaldusvahemik kahe üldkeskmise vahele.

- **Suurte ja sõltumatute valimite korral** ($n_1 \geq 50$ ja $n_2 \geq 50$) on usaldusvahemik keskväärtuste vahe $\mu_1 - \mu_2$ jaoks ligikaudsel usaldusnivool $(1-\alpha)$ järgmine:
$$I_{\mu_1-\mu_2} = (\bar{x} - \bar{y}) \pm \bar{z}_{\frac{\alpha}{2}} \cdot s^*,$$
kus kus $\bar{x}, \bar{y}$ on vastavate valimite keskmised, $\bar{z}_{\frac{\alpha}{2}}$ on standardse normaaljaotuse $\alpha/2$-täiendkvantiil ning
$$s^* = s_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}} = \sqrt{(\frac{1}{n_1}+\frac{1}{n_2})\frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-2}}.$$
Siin $s_p^2$ on kahe valimi ühine dispersioon, mis on leitav eraldi dispersioonide kaalutud keskmisena: $s_p^2 = \frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-2}$ ning standardhälve $s_p = \sqrt{s_p^2}$.
- **Kui valimid on väikesed ($n_1 < 50$ ja/või $n_2 < 50$), aga ligikaudse normaaljaotusega**, siis kehtib:
$$I_{\mu_1-\mu_2} = (\bar{x} - \bar{y}) \pm \bar{t}_{\frac{\alpha}{2};n_1+n_2-2} \cdot s^*,$$
kus $\bar{t}_{\frac{\alpha}{2};n_1+n_2-2}$ on Studenti t-jaotuse (vabadusastmetega $df = n_1+n_2-2$) $\alpha/2$-täiendkvantiil ning $s^*$ on leitav nii nagu ülalpool.

- **Kui kahe valimi varieeruvus on väga erinev** (standardhälbed erinevad enam kui 2 korda), siis tuleks ülaltoodud valemites kasutada:
$$s^* = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}.$$

## Usaldusvahemik kahe osakaalu vahele.

- Sõltumatute suurte valimite korral on intervall kahe üldkogumi osakaalude vahele $p_1 - p_2$ ligikaudsel usaldusnivool $(1-\alpha)$:
$$I_{\hat{p}_1-\hat{p}_2} = \hat{p}_1 - \hat{p}_2 \pm \bar{z}_{\frac{\alpha}{2}} \cdot s_p^*,$$
kus $\hat{p}_1$ ja $\hat{p}_2$ on vastavad osakaalud valimtes suurustega $n_1$ ja $n_2$ ning:
$$s_p^* = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}.$$

**Ülesanne 3.** (Lahendatud praktikumis) Võrdleme aine raames aastal 2023 ja 2024 ankeedile vastanud tudengite seas informaatikatudengeid teistega (aastal 2023 vastas ankeedile 80 informaatika- ja 80 teiste erialade tudengit; aastal 2024 vastas ankeedile 9 informaatika ja 84 teiste erialade tudengit). Järgnevas tabelis on toodud kahe tunnuse keskmised ja standardhälbed neis kahes grupis ja lisaks gruppide suurused (need erinevad, sest kõik ei vastanud igale küsimusele).

| | eriala | | | | | |
|---|---|---|---|---|---|---|
| | informaatika | | | muu | | |
| tunnus | $\bar{x}$ | $s$ | $n$ | $\bar{x}$ | $s$ | $n$ |
| sportimine nädalas (tunde) | 2,82 | 2,58 | 88 | 3,38 | 3,01 | 165 |
| telefoniaeg (*screen time*) päevas (tunde) | 3,45 | 1,75 | 82 | 4,10 | 1,96 | 159 |

Leia kummagi tunnuse jaoks:

1. 95% usaldusvahemik keskväärtusele eraldi nii informaatika- kui teiste tudengite seas. Kas tundub, et vaadeldavad rühmad erinevad selle tunnuse osas?
2. 95% usaldusvahemik kahe keskväärtuse vahele selle tunnuse osas. Milline on teie otsus erinevuse kohta nüüd?

**Ülesanne 4.** Aastal 2023 tudengite seas läbi viidud ankeetküsitluse põhjal võrreldi telefoni ekraaniaega tudengite seas, kes elavad oma vanematekodus, nendega, kes elavad ühiselamus. Ankeetküsitlusele vastanud tudengitest 29 elavad oma vanematekodus, nende keskmine telefoni ekraaniaeg oli 3,4 tundi päevas ja standardhälve 1,8 tundi. Ühiselamus elab 46 tudengit, nende keskmine ekraaniaeg on 3,8 tundi, standardhälbega 1,9 tundi. Leia 95% usaldusvahemik kahe keskmise vahele. Kuidas saadud vahemikku tõlgendada?

**Ülesanne 5.** Eesti kooliõpilaste tervisekäitumise uuringu (2022) valimis osales 839 13-aastast tüdrukut, kellest 533 ütlesid, et nad tegelevad vähemalt 2 tundi nädalas spordiga. Samas uuringus osales ka 736 15-aastast tüdrukut, kellest 456 ütlesid, et tegelevad vähemalt 2 tundi nädalas spordiga.

1. Leia ka 95% usaldusvahemik kahe osakaalu vahele. Kas kaks osakaalu erinevad oluliselt? Milline on maksimaalne erinevus kahe vanuserühma vahel üldkogumis, mis veel oleks kooskõlas selle usaldusvahemikuga?
2. Kui nii ühes kui teises vanusegrupis oleks 2400 uuritavat ning mõlemad osakaalud oleks sellised nagu praeguses valimis, kas usaldusvahemik osakaalude vahele sisaldaks väärtust 0?

## Statistilised hüpoteesid.

**Statistiline hüpotees** on väide üldkogumi kohta. Enamasti väidetakse midagi üldkogumi jaotuse parameetrite (nt keskväärtus) kohta.

**Nullhüpotees,** $H_0$ kirjeldab tavaliselt seni kehtinud olukorda, selle sisuks on üldkogumi vastavus teatud standardile (tihti väidab ka mingi seose või erinevuse puudumist);

**Sisukas (alternatiivne) hüpotees,** $H_1$ kirjeldab olukorda, mis uurijat huvitab – seda väidet soovitakse "tõestada" (st otsida sellele tõendust valimi põhjal).

**Teststatistik** on valimi põhjal leitav suurus, mis mõõdab erinevust nullhüpoteesi alusel oodatavate tulemuste ja valimis tegelikult ilmnenud tulemuste vahel. Teststatistik on juhuslik suurus.

- Teststatistik on konstrueeritud nii, et $H_0$ kehtimisel on tema jaotus teada – näiteks võib see olla standardne normaaljaotus $N(0,1)$.
- Hüpoteeside kontrollil antakse tõenäosuslik hinnang sellele, kas valimi põhjal arvutatud teststatistiku väärtus võis pärineda sellest jaotusest.
- Kui teststatistiku väärtus on antud jaotuse suhtes äärmuslik (kuulub nn **kriitilisse piirkonda**), siis saab $H_0$ kummutada ja vastu võtta sisuka hüpoteesi $H_1$.

**Teststatistiku kriitiline piirkond** on teststatistiku väärtuste piirkond $C$, mis viib null-hüpoteesi kummutamisele. Kriitilise piirkonna piiri nimetatakse **kriitiliseks väärtuseks**.
*Näiteks kui* $C = (z^*; \infty)$*, siis* $z^*$ *on kriitiline väärtus.*

**Statistiline test** on kontrollireegel (algoritm), kus teststatistiku (nt $Z$) väärtuse langemine kriitilisse piirkonda $C$ viib null-hüpoteesi kummutamisele:

$$\text{kui} \quad Z \in C \;\Rightarrow\; \text{kummutada } H_0$$

**Statistilise testi olulisuse nivoo** $\alpha$ on tõenäosus, et teststatistik $Z$ langeb nullhüpoteesi kehtimisel kriitilisse piirkonda:

$$\alpha = P(Z \in C | H_0).$$

**Olulisuse tõenäosus** ehk p-väärtus (*ingl. p-value*), tähist. $p$, on tõenäosus, et teststatistik omandab $H_0$ kehtimisel kas sama või veel äärmuslikuma väärtuse võrreldes antud valimiga. Kui $p \leq \alpha$, siis järelikult langeb teststatistik kriitilisse piirkonda ja võetakse vastu $H_1$.

Olulisuse nivoo määratakse enne uuringut (enamasti on ta kokkuleppeliselt 0,05, kuid kasutusel on ka 0,1, 0,01 jt väärtused) ja olulisuse nivoo määrab kriitilise piirkonna.

Näiteks kui $H_0$ kehtimisel $Z \sim N(0,1)$, siis kriitiline piirkond võib koosneda näiteks vahemikest $(-\infty; -\bar{z}_{\frac{\alpha}{2}})$ ja $(\bar{z}_{\frac{\alpha}{2}}; \infty)$ ja seega kuulub teststatistiku väärtus $z$ kriitilisse piirkonda, kui $|z| > \bar{z}_{\frac{\alpha}{2}}$ (siin $\bar{z}_{\frac{\alpha}{2}}$ on kriitiliseks väärtuseks).

## Hüpoteeside kontrollimine üldkogumi keskväärtuse kohta.

Võimalikud hüpoteeside paarid:

| | | |
|---|---|---|
| $H_0 : \mu = \mu_0$ (1) | $H_0 : \mu \leq \mu_0$ (2) | $H_0 : \mu \geq \mu_0$ (3) |
| $H_1 : \mu \neq \mu_0$ | $H_1 : \mu > \mu_0$ | $H_1 : \mu < \mu_0$ |

(1): lihthüpoteesid; (2, 3): liithüpoteesid.

**Suur valim ($n > 50$).**

- Teststatistik:
$$Z = \sqrt{n}\frac{\bar{X} - \mu_0}{S},$$
kus $\bar{X}$ on valimi keskväärtus ja $S$ on valimi standardhälve.
- Teststatistiku jaotus $H_0$ kehtimisel: $Z \sim AsN(0,1)$.

Otsustamine lihthüpoteeside (1) korral:

- Otsustusreegel: kui $|Z| \geq \bar{z}_{\frac{\alpha}{2}}$, siis võtta vastu $H_1$, vastasel juhul jääda $H_0$ juurde.
- Olulisuse tõenäosus: $p = 2 \cdot (1 - \Phi(|Z|))$, kus $\Phi()$ on standardse normaaljaotuse jaotusfunktsioon.

Otsustamine liithüpoteeside (2, 3) korral:

- Otsustusreegel: variant (2) korral võtta vastu $H_1$, kui $Z \geq \bar{z}_\alpha$; variant (3) korral, kui $Z \leq -\bar{z}_\alpha$; vastasel juhul jääda $H_0$ juurde.
- Olulisuse tõenäosus variant (2) korral: $p = 1 - \Phi(Z)$; variant (3): $p = \Phi(Z)$.

**Väike, (ligikaudu) normaaljaotusega valim ($n < 50$).**

- Teststatistik (sama mis enne):
$$T = \sqrt{n}\frac{\bar{X} - \mu_0}{S}.$$
- Teststatistiku jaotus $H_0$ kehtimisel: $T \sim t(n-1)$.
- Otsustusreegel lihthüpoteeside korral: kui $|T| \geq \bar{t}_{\frac{\alpha}{2},n-1}$, siis võtta vastu $H_1$, vastasel juhul jääda $H_0$ juurde.
- Otsustusreegel liithüpoteeside korral: võtta vastu $H_1$ variant (2) korral, kui $T \geq \bar{t}_{\alpha,n-1}$ ja variandi (3) korral kui $T \leq -\bar{t}_{\alpha,n-1}$.
- Olulisuse tõenäosus leitakse sarnaselt suure valimiga, kuid standardse normaaljaotuse jaotusfunktsiooni asemel kasutatakse $t(n-1)$-jaotust.

Kokkuvõttes võib hüpoteeside testimise reeglid ühe keskväärtuse kohta esitada järgmise tabelina (seda tabelit saab kasutada ka kontrolltöö ajal):

| | | kriitiline piirkond(kummutatakse $H_0$) | | |
|---|---|---|---|---|
| valim: | teststatistik | $H_0 : \mu = \mu_0$ | $H_0 : \mu \leq \mu_0$ | $H_0 : \mu \geq \mu_0$ |
| suur $n$, suvaline jaotus | $Z = \sqrt{n}\frac{\bar{X} - \mu_0}{S}$ | $\lvert Z\rvert > \bar{z}_{\frac{\alpha}{2}}$ | $Z > \bar{z}_\alpha$ | $Z < -\bar{z}_\alpha$ |
| väike $n$, normaaljaotus | $T = \sqrt{n}\frac{\bar{X} - \mu_0}{S}$ | $\lvert T\rvert > \bar{t}_{\frac{\alpha}{2},n-1}$ | $T > \bar{t}_{\alpha,n-1}$ | $T < -\bar{t}_{\alpha,n-1}$ |

## Kahe üldkogumi keskväärtuste võrdlemine

Võimalikud hüpoteeside paarid:

| | | |
|---|---|---|
| $H_0 : \mu_1 = \mu_2$ (1) $H_1 : \mu_1 \neq \mu_2$ | $H_0 : \mu_1 \leq \mu_2$ (2) $H_1 : \mu_1 > \mu_2$ | $H_0 : \mu_1 \geq \mu_2$ (3) $H_1 : \mu_1 < \mu_2$ |

Kahe üldkogumi võrdlemisel peab meil olema kaks valimit kummagist üldkogumist.

Testimine põhineb kahe valimikeskmise $\bar{X}_1$ ja $\bar{X}_2$ võrdlusel, võttes arvesse nende vahe $\bar{X}_1 - \bar{X}_2$ standardhälvet:

$$S^* = S_p\sqrt{\frac{1}{n_1} + \frac{1}{n_2}},$$

kus

$$S_p = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}.$$

Kui kahe valimi standarddhälbed erinevad vähemalt 2 kords, siis kasutatakse:

$$S^* = \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}.$$

**Suured ja sõltumatud valimid ($n_1 \geq 50$ ja $n_2 \geq 50$).**

- Teststatistik:
$$Z = \frac{\bar{X}_1 - \bar{X}_2}{S^*}.$$
- Teststatistiku jaotus $H_0$ kehtimisel: $Z \sim AsN(0,1)$.

Otsustamine lihthüpoteeside (1) korral:

- Otsustusreegel: kui $\lvert Z\rvert \geq \bar{z}_{\frac{\alpha}{2}}$, siis võtta vastu $H_1$, vastasel juhul jääda $H_0$ juurde.
- Olulisuse tõenäosus: $p = 2 \cdot (1 - \Phi(\lvert Z\rvert))$, kus $\Phi()$ on standardse normaaljaotuse jaotusfunktsioon.

Otsustamine liithüpoteeside (2, 3) korral:

- Otsustusreegel: variant (2) korral võtta vastu $H_1$, kui $z \geq \bar{z}_\alpha$; variant (3) korral, kui $z \leq -\bar{z}_\alpha$; vastasel juhul jääda $H_0$ juurde.
- Olulisuse tõenäosus variant (2) korral: $p = 1 - \Phi(Z)$; variant (3): $p = \Phi(Z)$.

**Väikesed, sõltumatud ja ligikaudu normaaljaotusega valimid ($n_1 < 50$ või $n_2 < 50$).**

- Teststatistik:
$$T = \frac{\bar{X}_1 - \bar{X}_2}{S^*}.$$
- Teststatistiku jaotus $H_0$ kehtimisel: $T \sim t(n_1 + n_2 - 2)$.
- Otsustusreegel lihthüpoteeside korral: kui $|T| \geq \bar{t}_{\frac{\alpha}{2},n_1+n_2-2}$, siis võtta vastu $H_1$, vastasel juhul jääda $H_0$ juurde.
- Otsustusreegel liithüpoteeside korral: võtta vastu $H_1$ variant (2) korral, kui $T \geq \bar{t}_{\alpha,n_1+n_2-2}$ ja variandi (3) korral kui $T \leq -\bar{t}_{\alpha,n_1+n_2-2}$.
- Olulisuse tõenäosus leitakse sarnaselt suure valimiga, kuid standardse normaaljaotuse jaotusfunktsiooni asemel kasutatakse $t(n_1 + n_2 - 2)$-jaotust.

Kokkuvõttes võib hüpoteeside testimise reeglid kahe keskväärtuse võrdlemiseks esitada järgmise tabelina (seda tabelit ja alltoodud $s^*$ valemeid saab kasutada ka kontrolltöö ajal):

| | | kriitiline piirkond(kummutatakse $H_0$) | | |
|---|---|---|---|---|
| valim: | teststatistik | $H_0 : \mu_1 = \mu_2$ | $H_0 : \mu_1 \leq \mu_2$ | $H_0 : \mu_1 \geq \mu_2$ |
| suur $n$, suvaline jaotus | $Z = \frac{\bar{x}_1 - \bar{x}_2}{s^*}$ | $\lvert Z\rvert > \bar{z}_{\frac{\alpha}{2}}$ | $Z > \bar{z}_\alpha$ | $Z < -\bar{z}_\alpha$ |
| väike $n$, normaaljaotus | $T = \frac{\bar{x}_1 - \bar{x}_2}{s^*}$ | $\lvert T\rvert > \bar{t}_{\frac{\alpha}{2},n_1+n_2-2}$ | $T > \bar{t}_{\alpha,n_1+n_2-2}$ | $T < -\bar{t}_{\alpha,n_1+n_2-2}$ |

$s^* = \sqrt{(\frac{1}{n_1} + \frac{1}{n_2})\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}}$, kui $s_1 \approx s_2$ (erinevus vähem kui 2-kordne).

$s^* = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$, kui $s_1 \neq s_2$ (erinevus enam kui 2-kordne).

**Ülesanne 6.** Võrdleme telefoni ekraaniaega tudengite seas, kes elavad oma vanematekodus, nendega, kes elavad ühiselamus. Ankeetküsitlusele vastanud tudengitest 29 elavad oma vanematekodus, nende keskmine telefoni ekraaniaeg oli 3,4 tundi päevas ja standardhälve 1,8 tundi. Ühiselamus elab 46 tudengit, nende keskmine ekraaniaeg on 3,8 tundi, standardhälbega 1,9 tundi.

1. Leia 95% usaldusvahemik kahe keskmise vahele. Kuidas saadud vahemikku tõlgendada?
2. Püstita hüpoteesid ja kontrolli neid olulisuse nivool 0,05. Mida järeldad?
3. Kas sinu otsus oleks erinev, kui olulisuse nivoo oleks 0,2?
4. Milline probleem võib tekkida sellest, kui olulisuse nivood suurendatakse – st kasutatakse $\alpha = 0{,}05$ asemel $\alpha = 0{,}2$?

## Hüpoteesid osakaalude kohta

Olgu valim $X_1, X_2, \ldots, X_n$ selline, et $X_i$ on sõltumatud Bernoulli jaotusega juhuslikud suurused: $X_i \sim Be(p)$. Sellisel juhul $EX = p$, mis on ka väärtuse $X_i = 1$ osakaaluks üldkogumis. Seetõttu on sellise valimi keskväärtus ühtlasi hinnanguks üldkogumi osakaalule, ehk $\bar{x} = \hat{p}$ ja saame osakaalude kohta hüpoteeside testimisel kasutada Tsentraalse piirteoreemi erijuhtu ehk Moivre-Laplace piirteoreemi.

### Hüpoteesid ühe osakaalu kohta

Olgu $p$ sündmuse $(X = 1)$ osakaal üldkogumis ehk tõenäosus $p = P(X = 1)$ ja olgu $p_0$ nullhüpoteesis näidatud tõenäosus. Võimalikud hüpoteeside paarid on siis:

| | | |
|---|---|---|
| $H_0 : p = p_0$<br>$H_1 : p \neq p_0$ (1) | $H_0 : p \leq p_0$<br>$H_1 : p > p_0$ (2) | $H_0 : p \geq p_0$<br>$H_1 : p < p_0$ (3) |

**Suur valim:** $np_0(1 - p_0) > 10$**.**

(Väikese valimi juhtu me siin kursuses ei käsitle, seega võib ülesannete puhul eeldada, et tegemist on suure valimiga.)

- Teststatistik:
$$Z = \sqrt{n} \cdot \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)}},$$
- Teststatistiku jaotus $H_0$ kehtimisel: $Z \sim AsN(0,1)$.
- Otsustusreeglid on samad mis suure valimi keskväärtuse puhul (alltoodud tabelis).
- Olulisuse tõenäosus lihthüpoteeside korral: $p = 2 \cdot (1 - \Phi(|z|))$, kus $\Phi()$ on standardse normaaljaotuse jaotusfunktsioon. Liithüpoteesid, variant (2): $p = 1 - \Phi(z)$; variant (3): $p = \Phi(z)$.

| | | kriitiline piirkond(kummutatakse $H_0$) | | |
|---|---|---|---|---|
| valim: | teststatistik | $H_0 : p = p_0$ | $H_0 : p \leq p_0$ | $H_0 : p \geq p_0$ |
| suur valim: $np_0(1 - p_0) > 10$ | $Z = \sqrt{n} \cdot \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)}}$ | $\lvert Z\rvert > \bar{z}_{\frac{\alpha}{2}}$ | $Z > \bar{z}_\alpha$ | $Z < -\bar{z}_\alpha$ |

**Hüpoteeside kontroll kahe osakaalu võrdlemiseks suurtes valimites**

Olgu meil kaks üldkogumit ning olgu sündmuse $(X = 1)$ osakaal esimeses üldkogumis $p_1$ ja teises $p_2$.
*Nt kui juhuslik suurus $Y = 1$ esimese üldkogumi objektide puhul ning $Y = 2$ teises üldkogumis, siis $p_1 = P(X = 1|Y = 1)$ ja $p_2 = P(X = 1|Y = 2)$.*

Võimalikud hüpoteeside paarid on siin:

| | | |
|---|---|---|
| $H_0 : p_1 = p_2$<br>$H_1 : p_1 \neq p_2$ (1) | $H_0 : p_1 \leq p_2$<br>$H_1 : p_1 > p_2$ (2) | $H_0 : p_1 \geq p_2$<br>$H_1 : p_1 < p_2$ (3) |

Olgu meil kaks valimit kummastki üldkogumist suurustega vastavalt $n_1$ ja $n_2$, milles me hindame valimi osakaalusid $\hat{p}_1$ ja $\hat{p}_2$. Samuti eeldame, et $min(n_j p_j(1 - p_j)) > 10$ $(j = 1, 2)$.

- Teststatistik $Z$ leitakse eeldusel, et kehtib $H_0 : p_1 - p_2 = 0$ ehk $p_1 = p_2 = p$:

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\hat{s}_p^*} \sim AsN(0,1),$$

  kus

$$\hat{s}_p* = \sqrt{\hat{p}(1-\hat{p})\big(\frac{1}{n_1} + \frac{1}{n_2}\big)} \quad \text{ja} \quad \hat{p} = \frac{n_1\hat{p}_1 + n_2\hat{p}_2}{n_1 + n_2}.$$

- Otsustusreeglid ja olulisuse tõenäosuse leidmine on sarnased kõigile teistele juhtudele, kus $Z \sim AsN(0,1)$ (vt tabelit ülal).

**Ülesanne 7.** Eesti kooliõpilaste tervisekäitumise uuringu (2022) valimis osales 743 11-aastast poissi, kellest 590 ütlesid, et nad tegelevad vähemalt 2 tundi nädalas spordiga. Samas uuringus osales ka 848 13-aastast poissi, kellest 632 ütlesid, et tegelevad vähemalt 2 tundi nädalas spordiga.

1. Leia nende protsent koos 95% usaldusvahemikuga 11-aastaste poiste seas, kes tegelevad vähemalt 2 tundi nädalas spordiga.
2. Leia nende protsent koos 95% usaldusvahemikuga 13-aastaste poiste seas, kes teevad vähemalt 2 tundi nädalas sporti. Kas kahe usaldusvahemiku põhjal saab otsustada, et sporditegijate osakaal kahes vanuserühmas erineb oluliselt?
3. Testi, kas vähemalt kaks tundi nädalas sporti tegevate poiste osakaal kahes vanuserühmas erineb oluliselt. (Vali ise olulisuse nivoo). Tõlgenda tulemust.
4. Kui kaks gruppi erineks vaid 4% võrra (sama valimi suuruse ja sama keskmise protsendi juures), kas otsus erinevuse kohta jääks samaks?

## Sagedused: usaldusvahemik sagedusele Poissoni jaotuse eeldusel; kahe sageduse võrdlemine

- Olgu meil juhuslik valim $X_1, X_2, \ldots, X_n$, kus $X_i \sim P(\lambda)$. Tüüpiliselt on sellises valimis vaatlusteks teatud sagedused (millegi/kellegi arvud). Sellisel juhul:

$$\hat{EX} = \hat{DX} = \hat{\lambda} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

- Kui $\lambda > 20$, siis on Poissoni jaotus üsna lähedane normaaljaotusele, st $X_i \sim AsN(\lambda, \sqrt{\lambda})$ ja seega saame leida vahemiku, kuhu kuulub 95% üldkogumi väärtustest kui: $\hat{\lambda} \pm 1{,}96\sqrt{\lambda}$.

- Kui $n\lambda > 20$, siis on ligikaudne $(1-\alpha)\%$ usaldusvahemik üldkogumi parameetrile $\lambda$ leitav kui:

$$\hat{\lambda} \pm \bar{z}_{\alpha/2}\sqrt{\frac{\hat{\lambda}}{n}}.$$

- Olgu meil kaks valimit kahest Poissoni jaotusega üldkogumist: $X \sim P(\lambda_1)$ ja $Y \sim P(\lambda_2)$ ning olgu nende valimite suurused vastavalt $n_1$ ja $n_2$. Siis hüpoteeside: $H_0 : \lambda_1 = \lambda_2$ ja $H_0 : \lambda_1 \neq \lambda_2$ testimiseks sobiv teststatistik on:

$$Z = \frac{\hat{\lambda}_1 - \hat{\lambda}_2}{\sqrt{\frac{\hat{\lambda}_1}{n_1} + \frac{\hat{\lambda}_2}{n_2}}}.$$

- $H_0$ kehtimisel: $Z \sim AsN(0,1)$. Seega otsustatakse $H_0$ kummutada olulisuse nivool $\alpha$, kui $|Z| > \bar{z}_{\frac{\alpha}{2}}$.

## Hii-ruut test sõltumatuse testimiseks sagedustabelis

- Uurimaks seost kahe mittearvulise tunnuse vahel koostatakse esmalt kahemõõtmeline sagedustabel:

| $Y$ / $X$ | $y_1$ | $y_2$ | $\dots$ | $y_j$ | $\dots$ | $\sum$ |
|---|---|---|---|---|---|---|
| $x_1$ | $n_{11}$ | $n_{12}$ | $\dots$ | $n_{1j}$ | $\dots$ | $n_{1.}$ |
| $x_2$ | $n_{21}$ | $n_{22}$ | $\dots$ | $n_{2j}$ | $\dots$ | $n_{2.}$ |
| $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ |
| $x_i$ | $n_{i1}$ | $n_{i2}$ | $\dots$ | $n_{ij}$ | $\dots$ | $n_{i.}$ |
| $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ | $\dots$ |
| $\sum$ | $n_{.1}$ | $n_{.2}$ | $\dots$ | $n_{.j}$ | $\dots$ | 1 |

- Testimaks tunnuste $X$ ja $Y$ sõltumatust, saab kasutada (Pearsoni) hii-ruut testi ($\chi^2$-test). $\chi^2$-teststatistik avaldub kujul:

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{v}\frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

kus $O_{ij} = n_{ij}$ on vaadeldud sagedus reas $i$ ja veerus $j$, ning
$E_{ij}$ on keskmine oodatav sagedus reas $i$ ja veerus $j$, nullhüpoteesi kehtimisel, mis avaldub kui:

$$E_{ij} = \frac{n_{i.}n_{.j}}{n}.$$

- $H_0$ kehtimisel on statistik on $\chi^2$-jaotusega vabadusastmete arvuga
$df = (r-1) \times (v-1)$, kus $r$ on ridade arv tabelis ja $v$ veergude arv.

**Hii-ruut test ja otsustusreegel praktikas:**

1. Koosta sagedustabel.
2. Leia statistiku väärtus $\chi^2$ vastavalt ülaltoodud valemile ja vabadusastmete arv kui $df = (r-1)\cdot(v-1)$.
3. Võrdle saadud väärtust $\chi^2_{df}$-jaotuse $\alpha$-täiendkvantiili väärtusega $\bar{\chi}^2_{\alpha,df}$ (vt tabelit konspekti lõpus).
4. Kui $\chi^2 > \bar{\chi}^2_{\alpha,df}$, siis saad võtta vastu sisuka hüpoteesi $X_1$ ja otsustada, et kahe tunnuse vahel on oluline seos; vastasel juhul tuleb jääda $H_0$ juurde (kaks tunnust on sõltumatud).
5. Olulisuse tõenäosuse ehk p-väärtuse leidmisel leia, milliste $\chi^2_{df}$-jaotuse täiendkvantiilide vahele jääb valimist leitud statistiku väärtus. Testi $p$-väärtus jääb siis vastavate $\alpha$-väärtuste vahele.

# Ülesannete vastused ja lahenduse vihjed.

**V:**

1. Poissoni piirteoreem: $\lambda = np = 5000 \cdot 0{,}001 = 5$; $P(X = 0) = e^{-5} = 0{,}0067$; $P(X \geq 2) = 1 - P(X < 2) = 1 - 0{,}0067 \cdot (1 + 5) \approx 0{,}960$

2. $E(\bar{X}) = \frac{1}{n}\sum_i E(X_i) = \lambda$; $\quad D(\bar{X}) = \frac{1}{n^2}\sum_i D(X_i) = \frac{1}{n}\lambda$.

   Tsentraalse piirteoreemi tõttu: $\bar{X} \sim AsN(\lambda, \sqrt{\frac{\lambda}{n}})$,

   Seega saame suure valimi korral ligikaudse $(1-\alpha)\%$ usaldusvahemik üldkogumi parameetrile $\lambda$, kui:

   $$\bar{x} \pm \bar{z}_{\alpha/2}\sqrt{\frac{\bar{x}}{n}},$$

   sest $\bar{x}$ on nihketa hinnanguks keskväärtusele ja seega ka parameetrile $\lambda$, mis on ühtlasi ka dispersioon.

3. Kasutades Moivre-Laplace piirteoreemi ning arveastades pidevus-parandusega, saame (a) 0,879; (b) 0,977; (c) 0,024 (vt. ka loeng 9, slaid 23)

4. $\bar{x} = 2$, $s = 1{,}249$, $mood = mediaan = 1$.

5. $n_* = 10$, $\bar{x}_* = \frac{3{,}4 \cdot 5}{10} = 1{,}7$, mediaan $m_* = (0 + 2)/2 = 1$, miinimum 0

   Dispersiooni leidmisel võib kasutada valemit:

   $$s^2 = \frac{n}{n-1}(\overline{x^2} - \overline{x}^2).$$

   Esialgse valimi korral saame: $2{,}3 = \frac{5}{4}(\overline{x^2} - 3{,}4^2)$, millest $\overline{x^2} = \frac{4}{5} \cdot 2{,}3 + 3{,}4^2 = 13{,}4$. Uue valimi korral on seega $\overline{x^2}_* = 13{,}4 \cdot 510 = 6{,}7$. Nüüd leiame uue valimi dispersiooni:

   $$s_*^2 = \frac{10}{9}(6{,}7 - 1{,}7^2) \approx 4{,}23.$$

6. Lisatud väärtus on 3,08 ja dispersioon $\approx 3{,}11666$.

7. (a) $\bar{x} = 4$; $s^2 = 1{,}26$; $s \approx 1{,}12$; (b) $(3{,}78; 4{,}22)$; (c) Usaldusvahemiku põhjal võib otsustada, et keskmine hinnang ei ole alla 3,5.
   (d) Keskväärtus jääb samaks, standardhälve väheneb ja valim suureneb, seega muutub usaldusvahemik veidi kitsamaks;

8. (a) 25,9%, $(22{,}9\%; 29{,}1\%)$
   (b) Andmed on kooskõlas teise väitega, kuid ei ole esimesega, sest 1/3 ei jää vahemikku, kuid 25% jääb.
   (c) $n = 1.96^2 * 0.75 * 0.25/0.02^2 \approx 1800$

9. Selle ülesande puhul saame eeldada, et valim on piisavalt suur normaaljaotuse kasutamiseks.
   **Sportimine:**
   (a) 95% usaldusvahemikud kummalegi keskmisele eraldi: informaatika: $(2{,}28; 3{,}36)$ ja teised: $(2{,}92; 3{,}84)$. Kattuvus on suur, ei tundu olevat olulist erienvust.
   (b) Kahe keskmise vahe on $-0.56$ ja 95% usaldusvahemikuga: $(-1{,}30; 0{,}18)$.
   **Ekraaniaeg:**
   (a) 95% usaldusvahemikud kummalegi keskmisele eraldi: informaatika: $(3{,}07; 3{,}83)$ ja teised: $(3{,}80; 4{,}40)$. Kattuvus on üsna väike (kuigi on olemas).
   (b) Kahe keskmise vahe on $-0.65$ tundi ja 95% usaldusvahemikuga: $(-1{,}15; -0{,}15)$. Et see vahemik ei kata väärtust 0, võib öelda et informaatikatudengid veedavad vähem aega telefoniekraani taga kui teste erialade tudengid.

10. Eeldades, et $n$ on väike (ja et ekraaniaeg on ligikaudu normaaljaotusega): $(-0{,}48; 1{,}28)$. (Suure $n$ eeldusel $(-0{,}47; 1{,}27)$)
    Et usaldusvahemik katab väärtust 0, ei saa väita, et vanematekodus olevate tudengite keskmine ekraaniaeg erineks ühiselamus elavate tudengite omast.

11. (a) $(-3{,}2\%; 6{,}4\%)$ Maksimaalselt võiks vanemas rühmas olla sporditegijate osakaal 6,4% võrra madalam.
    (b) $1{,}96 \cdot SE = 1{,}96 \cdot 0{,}014 \approx 0{,}027 > 0{,}015$. Seega sisalduks 0 endiselt usaldusvahemikus.

12. (a) Eeldades, et $n$ on väike: $(-0{,}48; 1{,}28)$. (Suure $n$ eeldusel $(-0{,}47; 1{,}27)$)
    (b) $H_0 : \mu_1 = \mu_2$, $H_1 : \mu_1 \neq \mu_2$. Teststatistik $T \approx 0{,}91$, $\bar{t}_{0{,}025,73} \approx \bar{t}_{0{,}025,70} = 1{,}99$. Et $0{,}91 < 1{,}99$, siis ei saa $H_0$ kummutada. Seega ei saa otsustada, et kodus ja ühikas elavate tudengite keskmine telefoniaeg oleks erinev.
    (c) Otsus jääb samaks, sest $\bar{t}_{0{,}1,70} = 1{,}29$ ja $0{,}91 < 1{,}29$.
    (d) Suureneb I liiki vea tõenäosus ehk tõenäosus et me ekslikult kummutame $H_0$ juhul kui ta tegelikkuses kehtib.

13. (a) 79,4%, (76,5%; 82,3%)
    (b) 73,8%, (70,7%; 76,8%) (usaldusvahemikud kattuvad, aga kumbki protsent ei sisaldu teises vahemikus - võib olla oluline erinevus)
    (c) $Z = 2{,}62$, $p = 0{,}009$ (oluline erinevus, kui olulisuse nivoo on nt 0,05)
    (d) Et $0.04/0.022 \approx 1{,}85$, siis enam ei otsustaks olulise erinevuse üle.

# Tabelid

## Standardse normaaljaotuse jaotusfunktsiooni $\Phi(x)$ väärtused.

**Standardse normaaljaotuse jaotusfunktsioon $\Phi(x)$**

| | 0 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |

## Studenti t-jaotuse täiendkvantiilid $\bar{t}_{\alpha;df}$

$\alpha = P(X > \bar{t}_{\alpha;df})$, kus $X \sim t(df)$

| | $\alpha$ | | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| df | 0.25 | 0.2 | 0.15 | 0.1 | 0.075 | 0.05 | 0.025 | 0.01 | 0.005 | 0.0025 | 0.001 | 0.0005 | 0.00005 |
| 4 | 0.74 | 0.94 | 1.19 | 1.53 | 1.78 | 2.13 | 2.78 | 3.75 | 4.60 | 5.60 | 7.17 | 8.61 | 15.54 |
| 5 | 0.73 | 0.92 | 1.16 | 1.48 | 1.70 | 2.02 | 2.57 | 3.36 | 4.03 | 4.77 | 5.89 | 6.87 | 11.18 |
| 6 | 0.72 | 0.91 | 1.13 | 1.44 | 1.65 | 1.94 | 2.45 | 3.14 | 3.71 | 4.32 | 5.21 | 5.96 | 9.08 |
| 7 | 0.71 | 0.90 | 1.12 | 1.41 | 1.62 | 1.89 | 2.36 | 3.00 | 3.50 | 4.03 | 4.79 | 5.41 | 7.88 |
| 8 | 0.71 | 0.89 | 1.11 | 1.40 | 1.59 | 1.86 | 2.31 | 2.90 | 3.36 | 3.83 | 4.50 | 5.04 | 7.12 |
| 9 | 0.70 | 0.88 | 1.10 | 1.38 | 1.57 | 1.83 | 2.26 | 2.82 | 3.25 | 3.69 | 4.30 | 4.78 | 6.59 |
| 10 | 0.70 | 0.88 | 1.09 | 1.37 | 1.56 | 1.81 | 2.23 | 2.76 | 3.17 | 3.58 | 4.14 | 4.59 | 6.21 |
| 11 | 0.70 | 0.88 | 1.09 | 1.36 | 1.55 | 1.80 | 2.20 | 2.72 | 3.11 | 3.50 | 4.02 | 4.44 | 5.92 |
| 12 | 0.70 | 0.87 | 1.08 | 1.36 | 1.54 | 1.78 | 2.18 | 2.68 | 3.05 | 3.43 | 3.93 | 4.32 | 5.69 |
| 13 | 0.69 | 0.87 | 1.08 | 1.35 | 1.53 | 1.77 | 2.16 | 2.65 | 3.01 | 3.37 | 3.85 | 4.22 | 5.51 |
| 14 | 0.69 | 0.87 | 1.08 | 1.35 | 1.52 | 1.76 | 2.14 | 2.62 | 2.98 | 3.33 | 3.79 | 4.14 | 5.36 |
| 15 | 0.69 | 0.87 | 1.07 | 1.34 | 1.52 | 1.75 | 2.13 | 2.60 | 2.95 | 3.29 | 3.73 | 4.07 | 5.24 |
| 16 | 0.69 | 0.86 | 1.07 | 1.34 | 1.51 | 1.75 | 2.12 | 2.58 | 2.92 | 3.25 | 3.69 | 4.01 | 5.13 |
| 17 | 0.69 | 0.86 | 1.07 | 1.33 | 1.51 | 1.74 | 2.11 | 2.57 | 2.90 | 3.22 | 3.65 | 3.97 | 5.04 |
| 18 | 0.69 | 0.86 | 1.07 | 1.33 | 1.50 | 1.73 | 2.10 | 2.55 | 2.88 | 3.20 | 3.61 | 3.92 | 4.97 |
| 19 | 0.69 | 0.86 | 1.07 | 1.33 | 1.50 | 1.73 | 2.09 | 2.54 | 2.86 | 3.17 | 3.58 | 3.88 | 4.90 |
| 20 | 0.69 | 0.86 | 1.06 | 1.33 | 1.50 | 1.72 | 2.09 | 2.53 | 2.85 | 3.15 | 3.55 | 3.85 | 4.84 |
| 21 | 0.69 | 0.86 | 1.06 | 1.32 | 1.49 | 1.72 | 2.08 | 2.52 | 2.83 | 3.14 | 3.53 | 3.82 | 4.78 |
| 22 | 0.69 | 0.86 | 1.06 | 1.32 | 1.49 | 1.72 | 2.07 | 2.51 | 2.82 | 3.12 | 3.50 | 3.79 | 4.74 |
| 23 | 0.69 | 0.86 | 1.06 | 1.32 | 1.49 | 1.71 | 2.07 | 2.50 | 2.81 | 3.10 | 3.48 | 3.77 | 4.69 |
| 24 | 0.68 | 0.86 | 1.06 | 1.32 | 1.49 | 1.71 | 2.06 | 2.49 | 2.80 | 3.09 | 3.47 | 3.75 | 4.65 |
| 25 | 0.68 | 0.86 | 1.06 | 1.32 | 1.49 | 1.71 | 2.06 | 2.49 | 2.79 | 3.08 | 3.45 | 3.73 | 4.62 |
| 26 | 0.68 | 0.86 | 1.06 | 1.31 | 1.48 | 1.71 | 2.06 | 2.48 | 2.78 | 3.07 | 3.43 | 3.71 | 4.59 |
| 27 | 0.68 | 0.86 | 1.06 | 1.31 | 1.48 | 1.70 | 2.05 | 2.47 | 2.77 | 3.06 | 3.42 | 3.69 | 4.56 |
| 28 | 0.68 | 0.85 | 1.06 | 1.31 | 1.48 | 1.70 | 2.05 | 2.47 | 2.76 | 3.05 | 3.41 | 3.67 | 4.53 |
| 29 | 0.68 | 0.85 | 1.06 | 1.31 | 1.48 | 1.70 | 2.05 | 2.46 | 2.76 | 3.04 | 3.40 | 3.66 | 4.51 |
| 30 | 0.68 | 0.85 | 1.05 | 1.31 | 1.48 | 1.70 | 2.04 | 2.46 | 2.75 | 3.03 | 3.39 | 3.65 | 4.48 |
| 35 | 0.68 | 0.85 | 1.05 | 1.31 | 1.47 | 1.69 | 2.03 | 2.44 | 2.72 | 3.00 | 3.34 | 3.59 | 4.39 |
| 40 | 0.68 | 0.85 | 1.05 | 1.30 | 1.47 | 1.68 | 2.02 | 2.42 | 2.70 | 2.97 | 3.31 | 3.55 | 4.32 |
| 50 | 0.68 | 0.85 | 1.05 | 1.30 | 1.46 | 1.68 | 2.01 | 2.40 | 2.68 | 2.94 | 3.26 | 3.50 | 4.23 |
| 60 | 0.68 | 0.85 | 1.05 | 1.30 | 1.46 | 1.67 | 2.00 | 2.39 | 2.66 | 2.91 | 3.23 | 3.46 | 4.17 |
| 70 | 0.68 | 0.85 | 1.04 | 1.29 | 1.46 | 1.67 | 1.99 | 2.38 | 2.65 | 2.90 | 3.21 | 3.44 | 4.13 |
| 80 | 0.68 | 0.85 | 1.04 | 1.29 | 1.45 | 1.66 | 1.99 | 2.37 | 2.64 | 2.89 | 3.20 | 3.42 | 4.10 |
| 90 | 0.68 | 0.85 | 1.04 | 1.29 | 1.45 | 1.66 | 1.99 | 2.37 | 2.63 | 2.88 | 3.18 | 3.40 | 4.07 |
| 100 | 0.68 | 0.85 | 1.04 | 1.29 | 1.45 | 1.66 | 1.98 | 2.36 | 2.63 | 2.87 | 3.17 | 3.39 | 4.05 |
| 150 | 0.68 | 0.84 | 1.04 | 1.29 | 1.45 | 1.66 | 1.98 | 2.35 | 2.61 | 2.85 | 3.15 | 3.36 | 4.00 |
| 200 | 0.68 | 0.84 | 1.04 | 1.29 | 1.45 | 1.65 | 1.97 | 2.35 | 2.60 | 2.84 | 3.13 | 3.34 | 3.97 |
| $\infty$ | 0.67 | 0.84 | 1.04 | 1.28 | 1.44 | 1.64 | 1.96 | 2.33 | 2.58 | 2.81 | 3.09 | 3.29 | 3.89 |

NB! Viimases reas on toodud standardse normaaljaotuse $N(0,1)$ täiendkvantiilid $\bar{z}_\alpha$, sest $t(\infty) = N(0,1)$.

## $\chi^2$-jaotuse täiendkvantiilide väärtused

Tabelis toodud täiendkvantiilid $\chi^2_{\alpha,df}$, kus *df* on vabadusastmete arv.

| | $P(X > x)$ | | | | | | |
|---|---|---|---|---|---|---|---|
| df | 0.5 | 0.1 | 0.05 | 0.025 | 0.01 | 0.005 | 0.001 |
| 1 | 0.45 | 2.71 | 3.84 | 5.02 | 6.63 | 7.88 | 10.83 |
| 2 | 1.39 | 4.61 | 5.99 | 7.38 | 9.21 | 10.60 | 13.82 |
| 3 | 2.37 | 6.25 | 7.81 | 9.35 | 11.34 | 12.84 | 16.27 |
| 4 | 3.36 | 7.78 | 9.49 | 11.14 | 13.28 | 14.86 | 18.47 |
| 5 | 4.35 | 9.24 | 11.07 | 12.83 | 15.09 | 16.75 | 20.52 |
| 6 | 5.35 | 10.64 | 12.59 | 14.45 | 16.81 | 18.55 | 22.46 |
| 7 | 6.35 | 12.02 | 14.07 | 16.01 | 18.48 | 20.28 | 24.32 |
| 8 | 7.34 | 13.36 | 15.51 | 17.53 | 20.09 | 21.95 | 26.12 |
| 9 | 8.34 | 14.68 | 16.92 | 19.02 | 21.67 | 23.59 | 27.88 |
| 10 | 9.34 | 15.99 | 18.31 | 20.48 | 23.21 | 25.19 | 29.59 |

**Mõned funktsioooni $e^{-x}$ ligikaudsed väärtused:**

| $x$ | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| $e^{-x}$ | 0.368 | 0.135 | 0.0498 | 0.0183 | 0.0067 |

(Neid võib minna vaja Poissoni jaotuse tõenäosuste arvutamisel)